



Université Claude Bernard



# Master 1 Bioinformatique

## Compte Rendu Travaux Pratiques

---

---

### Mapping – Expression - Épissage

Étudiant :

Albert NDOUR

Professeur :

Vincent LACROIX

13 mars 2025

## Table des matières

|          |                                                                          |           |
|----------|--------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                                      | <b>1</b>  |
| <b>2</b> | <b>Matériels et Méthodes</b>                                             | <b>1</b>  |
| 2.1      | Matériels . . . . .                                                      | 1         |
| 2.2      | Méthodes . . . . .                                                       | 2         |
| 2.2.1    | Quantification des exons et des transcrits. . . . .                      | 3         |
| 2.2.2    | Analyse différentielle d'expression et d'épissage . . . . .              | 5         |
| 2.2.3    | Visualisation . . . . .                                                  | 6         |
| <b>3</b> | <b>Résultats : liste de gènes différentiellement exprimés et épissés</b> | <b>6</b>  |
| <b>4</b> | <b>Figures IGV</b>                                                       | <b>7</b>  |
| <b>5</b> | <b>Conclusion</b>                                                        | <b>14</b> |

## Table des figures

|    |                                                                   |    |
|----|-------------------------------------------------------------------|----|
| 1  | Pipeline d'Analyse de l'Expression et de l'Épissage . . . . .     | 3  |
| 2  | Liste de gènes avec une baseMean>50 et exonBaseMean>100 . . . . . | 7  |
| 3  | Visualisation par défaut d'IGV du gène DDX5 . . . . .             | 8  |
| 4  | Visualisation par Sashimi plot du gène DDX5 . . . . .             | 9  |
| 5  | Visualisation par Sashimi plot du gène DDX17 . . . . .            | 9  |
| 6  | Visualisation par défaut d'IGV du gène ACTN4 . . . . .            | 10 |
| 7  | Visualisation par Sashimi plot du gène ACTN4 . . . . .            | 11 |
| 8  | Zoom sur l'exon 8 du gène ACTN4 . . . . .                         | 11 |
| 9  | Visualisation par défaut d'IGV plot du gène ATP5MC1 . . . . .     | 12 |
| 10 | Visualisation par Sashimi plot du gène ATP5MC1 . . . . .          | 13 |

## Liste des tableaux

|   |                                               |   |
|---|-----------------------------------------------|---|
| 1 | Données brutes de RNA-seq . . . . .           | 2 |
| 2 | Tableau des données et pourcentages . . . . . | 4 |

# 1 Introduction

L'épissage alternatif est un processus biologique fondamental qui contribue à la diversité du protéome en permettant à un seul gène de produire plusieurs isoformes d'ARN messager. Ce mécanisme complexe permet la régulation fine de l'expression génique à la fois au niveau qualitatif, en générant différentes formes d'ARN messager, et au niveau quantitatif, en modulant les niveaux d'expression de ces isoformes. Cette régulation précise de l'épissage alternatif joue un rôle important dans de nombreux processus biologiques. Dans le contexte du cancer du sein, la compréhension de l'épissage alternatif est particulièrement pertinente car il peut influencer la pathogenèse de la maladie en modifiant les produits géniques impliqués dans la prolifération cellulaire, l'apoptose et d'autres processus clés.

Dans cette étude, nous nous concentrons sur l'exploration des mécanismes moléculaires régulant à la fois l'expression génique et l'épissage alternatif. Les données utilisées proviennent d'une expérience de séquençage du transcriptome humain, réalisée sur la lignée cellulaire MCF-7, dérivée d'une femme atteinte de cancer du sein.

Dans cette optique, nous analysons les lectures RNA-seq de ces lignées cellulaires, totalisant un volume massif de 100 millions de séquences et plus avec une taille moyenne d'environ 100 nucléotides (taille d'une lecture), dans deux conditions avec deux réplicats pour chaque condition. Dans la première condition, les deux hélicases DDX5 et DDX17 ont été inhibées avec des siRNAs. Les siRNAs sont de petites séquences nucléotidiques qui vont cibler certains ARNs spécifiques grâce à la complémentarité de leur séquence. La deuxième condition est la condition contrôle. Nous cherchons à déterminer l'impact de ce silencing sur l'enroulement des protéines et d'autres processus moléculaires pertinents, en mettant l'accent sur l'expression génique moyenne et l'identification des événements d'épissage alternatif.

Pour analyser ces données, nous utilisons une combinaison d'outils bioinformatiques (STAR, Htseq-count, R, DESeq2, DEXSeq et IGV). Les lectures sont alignées sur la version hg19 du génome humain.

En combinant des approches expérimentales et bioinformatiques, notre objectif est de décrypter le rôle précis des protéines DDX5 et DDX17 dans la régulation de l'expression des gènes et de l'épissage alternatif, en particulier dans le contexte du cancer du sein et d'autres processus biologiques associés.

## 2 Matériels et Méthodes

### 2.1 Matériels

Les Données brutes de RNA-seq sur lesquelles nous avons travaillé sont réparties en deux conditions avec deux réplicats pour chaque condition.



TABLE 1 – Données brutes de RNA-seq

| <b>Condition 1 : siCTL_R1</b>     |                     |
|-----------------------------------|---------------------|
| R1                                | 59179730 séquences  |
| R2                                | 59750440 séquences  |
| Total                             | 118930170 séquences |
| <b>Condition 1 : siCTL_R2</b>     |                     |
| R1                                | 59179730 séquences  |
| R2                                | 56622585 séquences  |
| Total                             | 115502315 séquences |
| <b>Condition 2 : siDDX5_17_R1</b> |                     |
| R1                                | 53282458 séquences  |
| R2                                | 53738137 séquences  |
| Total                             | 107120595 séquences |
| <b>Condition 2 : siDDX5_17_R2</b> |                     |
| R1                                | 54099466 séquences  |
| R2                                | 54546167 séquences  |
| Total                             | 108545633 séquences |

## 2.2 Méthodes

Les données brutes avec lesquelles nous travaillons ont subi au préalable un contrôle qualité, après obtention de données de bonne qualité, nous pouvons passer au mapping qui consiste à aligner les lectures à un génome de référence. Pour effectuer cet alignement, nous avons besoin d'une méthode capable d'aligner les lectures qui peuvent être divisées en plusieurs parties, ce qu'on appelle un "spliced mapper".

Les spliced mapper sont traditionnellement classés en deux grandes catégories : les outils basés sur l'alignement sur l'exon (méthodes exon-first) et les outils qualifiés de "seed-and-extend".

L'alignement des lectures provenant de données de RNA-Seq présente une difficulté particulière : lorsque les lectures couvrent une jonction d'exons, elles doivent être alignées en plusieurs parties. Dans ces données, si le transcrit du gène parent est exprimé, il générera des lectures correspondant à ses exons ainsi qu'aux jonctions entre ces exons.

Lorsque nous alignons ces lectures sur le génome de référence, les lectures exoniques seront correctement alignées à leurs emplacements respectifs. Cependant, les lectures de jonction peuvent poser problème, car elles peuvent être mal alignées et correspondre à un pseudogène traité. Cela peut compliquer l'interprétation des données et nécessite une attention particulière lors de l'analyse des résultats d'alignement.

Lorsque nous travaillons sans annotation GTF (Gene Transfer Format), la méthode "exon-first" est souvent utilisée, où les lectures sont alignées en un seul bloc au génome de référence, définissant ainsi des clusters de lectures (correspondant à des exons). Cependant, nous disposons d'une annotation GTF dans ce TP, nous pouvons donc utiliser une approche seed-and-extend où les lectures sont d'abord alignées sur les jonctions d'exon, puis sur le génome. C'est au cours de cette étape que les sites d'épissage sont localisés. Cela permet de traiter les cas où à la fois le gène parent et le pseudogène sont exprimés,




FIGURE 1 – Pipeline d'Analyse de l'Expression et de l'Épissage

offrant ainsi une analyse plus complète et précise des données de RNA-seq. Ce type de méthode trouve généralement plus de nouvelles jonctions d'épissage. Dans nos travaux pratiques, nous avons utilisé la version hg38 du génome humain. Pour réaliser cet alignement, deux outils ont été recommandés : STAR (Spliced Transcripts Alignment to a Reference) et HISAT (Hierarchical Indexing for Spliced Alignment of Transcripts). Personnellement, j'ai opté pour STAR lors de notre séance de TP pour effectuer l'alignement des séquences. Une ligne correspond à un alignement.

### 2.2.1 Quantification des exons et des transcrits.

L'étape de quantification consiste à compter le nombre de lectures supportant les différentes isoformes d'un gène ou bien plus localement supportant les différents variants d'un événement d'épissage. La quantification des différentes isoformes et des événements d'épissage dépend fortement d'un alignement précis des séquences sur le génome de réf-

rence. Nous avons choisi HTSeq-count pour réaliser la quantification. Cet outil à partir d'un fichier BAM avec les alignements et d'un fichier GTF contenant les annotations, il compte pour chaque gène le nombre de lectures alignées qui chevauchent ses exons. Le choix final des paramètres dépend donc à la fois des données qu'on a à sa disposition.

— **Choix des Paramètres de HTSeq-count :**

- f bam : Format des données d'entrée ( ici au format BAM).
- r name : Puisque nous utilisons des données en pair-end, htseq-count s'attend à ce que tous les alignements pour les lectures d'une paire de lectures donnée apparaissent dans des enregistrements adjacents dans les données d'entrée. Nous avons d'abord trié par nom de lectures avant de faire le comptage.
- s no : Comme nos données de RNA-Seq n'ont pas été obtenues avec un protocole spécifique au brin, nous avons donc décidé de définir l'option -s no.
- t exon : Indique que nous nous intéressons aux exons. Type de fonctionnalité (3ème colonne du fichier GTF) à utiliser, toutes les fonctionnalités d'un autre type sont ignorées (par défaut, adapté à l'analyse RNA-Seq à l'aide d'un fichier Ensembl GTFexon : )
- i gene\_id : Utilise l'identifiant du gène comme identifiant pour le comptage.
- n 10 : Nombre de processus CPU parallèles à utiliser (ici 10). Cette option est utile pour traiter plusieurs fichiers d'entrée à la fois.

Pour une analyse d'expression différentielle précise, il est important d'avoir un pourcentage élevé de lectures qui sont correctement alignées sur un seul gène, sans ambiguïté.

TABLE 2 – Tableau des données et pourcentages

|                              | siCTL_R1             | siCTL_R2             | siDDX5_17_R1         | siDDX5_17_R2         |
|------------------------------|----------------------|----------------------|----------------------|----------------------|
| <b>Raw data</b>              | 118930170<br>(100%)  | 115502315<br>(100%)  | 107120595<br>(100%)  | 108545633<br>(100%)  |
| <b>__no_feature</b>          | 25358316<br>(27.39%) | 23246672<br>(25.57%) | 19049864<br>(17.80%) | 22122603<br>(26.57%) |
| <b>Ambiguës</b>              | 2211646<br>(2.42%)   | 2575980<br>(3.00%)   | 2604213<br>(2.43%)   | 2207990<br>(2.05%)   |
| <b>Trop faible Qualité</b>   | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         |
| <b>Non alignées</b>          | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         |
| <b>Alignement non unique</b> | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         | 0<br>(0.00%)         |
| <b>Mappées correctement</b>  | 91360208<br>(70.18%) | 89679663<br>(74.43%) | 85466518<br>(80.76%) | 84215040<br>(77.38%) |

Les données du Tableau 2 indiquent que généralement entre 70% et 80% de nos lectures sont alignées de manière non ambiguë. L'assignation des lectures à une région unique du génome peut être difficile et poser des problèmes pour la suite de l'analyse. En effet, il est difficile de savoir quoi faire avec les lectures qui s'alignent de manière exacte à plusieurs endroits du génome. Le plus souvent ces lectures sont mises de côté et ne sont donc pas utilisées pour la suite de l'analyse. Cela entraîne une perte de puissance pour les analyses statistiques de certaines régions du génome (comme les éléments répétés).

Si nous choisissons d'ignorer les lectures qui sont alignées sur plusieurs positions, chevauchant plusieurs gènes ou qui ne sont pas assignées à un gène spécifique, nous pouvons alors nous concentrer sur les lectures qui sont correctement alignées sur un seul gène. Ces lectures représentent la part la plus significative et fiable de nos données, ce qui est essentiel pour des analyses précises et fiables d'expression différentielle.

Pour comprendre pourquoi il est souhaitable d'avoir des lectures mappées sans ambiguïté dans une analyse d'expression différentielle, considérons deux gènes présentant une similarité de séquence, dont l'un est exprimé différemment de l'autre. Si une lecture correspond bien aux deux gènes, elle doit être rejetée, car si elle est comptée pour les deux gènes, cela peut conduire à une erreur. En comptant cette lecture pour les deux gènes, les lectures supplémentaires du gène exprimé différemment pourraient également conduire à l'identification erronée de l'autre gène comme étant exprimé différemment.

Un autre aspect important dans la conception de tests d'expression différentielle est de compter les fragments plutôt que les lectures, notamment dans le cas de données appariées. Cela est dû au fait que les deux partenaires provenant du même fragment d'ARN ne fournissent la preuve que d'un seul fragment d'ARN. Par conséquent, il est plus approprié de les compter qu'une seule fois dans l'analyse, afin d'éviter une surestimation des niveaux d'expression différentielle. Cette approche garantit une interprétation plus précise des résultats de l'analyse d'expression différentielle.

### 2.2.2 Analyse différentielle d'expression et d'épissage

Lors d'une analyse différentielle de l'ARN-Seq, un point important à prendre en compte est la variabilité biologique. Pour cela, nous avons utilisé deux des réplicats biologiques pour chaque condition pour bien tester si l'épissage est modifié entre deux conditions. Pour ce faire nous avons utilisé DESeq2 et DEXSeq. Ces outils sont essentiels pour identifier les variations dans l'expression génique ou exonique entre deux conditions expérimentales. Cependant, ils diffèrent dans leurs approches statistiques et leurs capacités à analyser les données. L'analyse a été faite sur les transcrits complets avec des outils DESeq2 et plus localement sur des événements d'épissage ou les exons avec des outils DEXSeq. DESeq2 est principalement utilisé pour détecter les gènes différentiellement exprimés entre deux conditions expérimentales. DEXSeq utilise le nombre de lectures par exons pour calculer les gènes avec un épissage différentiel entre deux conditions. Par contre, il ne donne pas d'information sur les événements, seulement sur les exons ou morceaux d'exons dont l'expression est modifiée.

#### Choix des paramètres de DESeq2

- Le prétraitement des données comprend l'élimination des gènes dont l'expression est très faible, fixée ici à moins de 10 comptes. Cette étape est cruciale pour exclure les gènes qui pourraient ne pas être détectés de manière fiable dans les échantillons.
- Ensuite, l'analyse différentielle est effectuée à l'aide du package DESeq2. Le choix d'un ajustement p-value de moins de 0,05 comme seuil de signification statistique est une pratique courante dans les analyses différentielles, indiquant une forte confiance dans les différences observées.
- De plus, le critère du Fold Change est utilisé pour évaluer l'ampleur du changement d'expression entre les conditions expérimentales. Un Fold Change supérieur à 1 (ou une valeur absolue du  $\log_2\text{FoldChange}$  supérieure à 1) indique un changement

d'expression substantiel, ce qui est également considéré comme un critère important dans la sélection des gènes différentiellement exprimés.

- Enfin, la condition d'une expression de base suffisamment élevée, définie comme une moyenne de l'expression du gène (baseMean) dépassant 50, est appliquée. Cette condition garantit que seuls les gènes avec une expression de base substantielle sont considérés comme pertinents dans l'analyse différentielle, évitant ainsi les faux positifs dus à des expressions très faibles.

### Choix des paramètres de DEXSeq

- Dans cette analyse, les paramètres ont été choisis de manière à identifier les gènes avec un épissage différentiel significatif. Plus précisément, les gènes ont été filtrés en fonction de leur baseMean, qui représente l'expression moyenne du gène sur tous les échantillons, avec une valeur minimale de 100 pour garantir une expression suffisamment élevée.
- De plus, seuls les gènes avec un ajustement p-value (padj) inférieur à 0,05 ont été considérés comme significativement différentiels.
- Enfin, un exonFoldChange supérieur à 1 a été utilisé comme critère pour identifier les changements d'épissage significatifs.

### 2.2.3 Visualisation

À partir des résultats d'analyse différentielle de DEXseq et DESeq2, nous mettons l'accent sur trois gènes sélectionnés, en espérant identifier des caractéristiques distinctives qui pourraient éclairer notre compréhension des mécanismes sous-jacents à la régulation de l'expression génique et de l'épissage alternatif. À travers la visualisation sur IGV, nous visons à explorer en détail la structure génomique de ces gènes, en examinant la couverture des lectures sur le génome, les jonctions exoniques, ainsi que les lectures individuelles. Cette approche nous permettra d'obtenir des informations précieuses sur la distribution des lectures et les modèles d'épissage, fournissant ainsi des indices sur la régulation de l'expression génique et de l'épissage alternatif dans les conditions expérimentales étudiées.

## 3 Résultats : liste de gènes différentiellement exprimés et épissés

Le résumé des résultats de l'analyse différentielle effectuée avec DESeq2 donne 29 633 gènes avec un comptage total non nul. Parmi ces gènes avec une p-value ajustée  $< 0.1$ , 444 gènes soit 1,5% ont un LFC (Log2 Fold Change) positif, ce qui signifie qu'ils sont régulés positivement dans la condition silencing par rapport à la condition contrôle. De même, 565 gènes soit 1,9% ont un négatif, ce qui signifie qu'ils sont régulés négativement la condition silencing par rapport à la condition contrôle. Aucune valeur aberrante n'a été détectée dans l'analyse. 6894 gènes (environ 23%) ont des comptages moyens inférieurs à 8, ce qui les classe comme des gènes à faible comptage.

Grâce à une sélection minutieuse des paramètres pour les analyses différentielles avec DESeq2 et DEXSeq, nous avons identifié un ensemble de gènes. Les critères de sélection incluent une p-value ajustée inférieure à 0,05, une baseMean supérieure à 50 pour DESeq2 et une exonBaseMean supérieure 100 pour DEXSeq, un exonFoldChange supérieur à 1,

ainsi qu'un log2FoldChange indiquant un changement d'expression substantiel entre les conditions expérimentales. Pour DESeq2 444 gènes ont été identifiés correspondant aux gènes différentiellement exprimés. Pour DEXSeq 568 gènes ont été identifiés correspondant aux gènes différentiellement exprimés.

Pour DEXSeq 568 gènes ont été identifiés comme présentant un épissage différentiel significatif entre les conditions expérimentales. En combinant ces critères, nous avons obtenu une liste finale de 29 gènes qui ont à la fois une p-value inférieure à 0.05, une couverture suffisante (baseMean>50 pour l'expression, exonBaseMean>100 pour l'épissage), répondant à des critères stricts d'expression, de différenciation significative et de régulation d'épissage. Ces gènes représentent des candidats prometteurs pour une analyse approfondie dans le contexte de notre étude.

| 1  | gene_name | groupID         | featureID | exonBaseMean     | padj                 | log2fold_siDDX5_17 | start     | end       |
|----|-----------|-----------------|-----------|------------------|----------------------|--------------------|-----------|-----------|
| 2  | ATP9A     | ENSG00000054793 | E001      | 3878.37941405282 | 4.99241746321932e-08 | -0.497507596629855 | 50213053  | 50217401  |
| 3  | DDX17     | ENSG00000100201 | E002      | 3076.39178851694 | 5.23913439277512e-07 | -0.481789657194307 | 38879469  | 38881681  |
| 4  | ASF1B     | ENSG00000105011 | E001      | 500.056320582867 | 7.4488327983124e-06  | -0.385974298440985 | 14230321  | 14231030  |
| 5  | CRTC1     | ENSG00000105662 | E019      | 114.480706311197 | 0.000652146548378564 | 0.521083398396968  | 18888763  | 18893004  |
| 6  | TRIM14    | ENSG00000106785 | E004      | 996.969444350201 | 0.00862528344842372  | -0.250242256209035 | 100846749 | 100849108 |
| 7  | RPL28     | ENSG00000108107 | E024      | 942.74772485416  | 0.000587265185896069 | 0.8681667355242    | 55900257  | 55902921  |
| 8  | DDX5      | ENSG00000108654 | E003      | 552.594740643048 | 0.00807769535257718  | -0.895315533547464 | 62496032  | 62496227  |
| 9  | DDX5      | ENSG00000108654 | E006      | 422.594452033172 | 9.76866232795073e-07 | 0.372695276193831  | 62496303  | 62496444  |
| 10 | DDX5      | ENSG00000108654 | E065      | 118.294134469202 | 1.45950350996938e-08 | 1.69462263283883   | 62500476  | 62500794  |
| 11 | SLC15A3   | ENSG00000110446 | E010      | 109.205207425865 | 0.0345202789070119   | 0.991692321291626  | 60707111  | 60708593  |
| 12 | TTL       | ENSG00000114999 | E003      | 128.958671610618 | 4.69785919855531e-10 | 0.948933973556183  | 113240717 | 113241507 |
| 13 | NXNL2     | ENSG00000130045 | E005      | 152.046374600825 | 0.000290543561957506 | -2.25255394658941  | 91159463  | 91159895  |
| 14 | NXNL2     | ENSG00000130045 | E007      | 471.016829466632 | 1.16044418117433e-15 | 0.692260920970685  | 91190002  | 91190704  |
| 15 | NXNL2     | ENSG00000130045 | E008      | 111.418123035438 | 0.0204897528202544   | 1.46460948667501   | 91198914  | 91199189  |
| 16 | ACTN4     | ENSG00000130402 | E008      | 189.229814671316 | 0.0224436355775149   | -0.835102447882485 | 39220088  | 39220460  |
| 17 | BRIP1     | ENSG00000136492 | E022      | 207.336040683885 | 0.00324891862851483  | 0.579528197949275  | 59924462  | 59924581  |
| 18 | PML       | ENSG00000140464 | E018      | 326.547130035026 | 1.14193212404398e-07 | -0.591926822944967 | 74317269  | 74320783  |
| 19 | CBR4      | ENSG00000145439 | E005      | 204.694572491759 | 1.02870294095617e-05 | -0.512392681120711 | 169908741 | 169911479 |
| 20 | SIGMAR1   | ENSG00000147955 | E001      | 185.293374938668 | 6.03679611642031e-06 | -0.351407022080553 | 34634719  | 34635479  |
| 21 | ATP5MC1   | ENSG00000159199 | E003      | 452.651194575808 | 6.77739527081069e-08 | 0.534565018751973  | 46973017  | 46973223  |
| 22 | LSS       | ENSG00000160285 | E006      | 559.420443035501 | 0.000236410358266346 | -0.397674127238274 | 47609039  | 47610696  |
| 23 | ELF3      | ENSG00000163435 | E033      | 452.153076562071 | 1.90373538948853e-07 | 0.675350354270973  | 201985138 | 201986316 |
| 24 | FAXDC2    | ENSG00000170271 | E002      | 635.494318606458 | 4.99241746321932e-08 | 0.584498821826251  | 154198054 | 154199309 |
| 25 | EHBP1L1   | ENSG00000173442 | E016      | 344.906275960093 | 1.2387559975763e-07  | -0.699928145297195 | 65349488  | 65351062  |
| 26 | ENDOV     | ENSG00000173818 | E061      | 176.715958151202 | 2.45529256950337e-12 | 2.22650897946407   | 78409933  | 78411881  |
| 27 | ARL10     | ENSG00000175414 | E008      | 261.224979788092 | 8.55432265939431e-07 | 0.739240541529075  | 175798725 | 175808912 |
| 28 | TMEM105   | ENSG00000185332 | E001      | 193.107874102986 | 9.8230469678762e-07  | 0.870056219148858  | 79285074  | 79287552  |
| 29 | CAPN8     | ENSG00000203697 | E025      | 195.664331064112 | 0.0378402145983263   | -0.511109531903612 | 223804600 | 223805983 |
| 30 | PHB2      | ENSG00000215021 | E003      | 123.936083312876 | 0.000494711880221138 | -2.04455031067448  | 7074627   | 7074847   |

FIGURE 2 – Liste de gènes avec une baseMean>50 et exonBaseMean>100

## 4 Figures IGV

Dans cette liste de gènes (Figure 2), nous observons tous ceux présentant des événements d'épissage significatifs et une expression différentielle d'après les analyse différentielles de DESeq2 et DEXSeq. Ce sont nos gènes d'intérêt que nous utilisons pour la visualisation sur IGV. Nous chercherons à identifier ce qui est pertinent à observer au niveau de leur expression et épissage.

### Analyse différentielle d'expression et d'épissage de DDX5 et DDX17

Nous effectuons un contrôle d'analyse différentielle d'expression et d'épissage en visualisant DDX5 et DDX17. Avec la Visualisation par le gène DDX5, on peut voir une différence significative est observée dans l'échelle d'expression de DDX5 entre la condition contrôle (4426-5748) et la condition de silencing de DDX5 et de DDX17 (702-988). La di-

minution de la couverture en condition de silencing prouve une réduction de l'expression de DDX5. Cette observation est cohérente avec l'objectif du silencing de DDX5.




FIGURE 3 – Visualisation par défaut d'IGV du gène DDX5

Pour vérifier la cohérence des résultats de DESeq2 et de DEXSeq, nous avons examiné les sashimi plot des gènes DDX17 et DDX5. Nous avons observé que tous les exons sont constitutifs ce qui prouve la cohérence avec l'annotation des gènes DDX17 et DDX5. On peut voir que le nombre de lectures qui soutiennent les jonctions d'exons a drastiquement chuté. Cette chute du nombre de lectures supportant les jonctions d'exons peut s'expliquer de différentes manières : Réduction de l'expression génique : Le silencing de DDX5 et de DDX17 peut avoir entraîné une réduction de l'expression globale de ces gènes, de transcrits moins nombreux et donc moins de lectures supportant les jonctions d'exons. Perturbation de l'épissage : Le silencing de DDX5 et DDX17 peut avoir perturbé les mécanismes de régulation de l'épissage, conduisant à une production aberrante de transcrits avec des jonctions d'exons incorrectes.




FIGURE 4 – Visualisation par Sashimi plot du gène DDX5




FIGURE 5 – Visualisation par Sashimi plot du gène DDX17

### Analyse différentielle d'expression et d'épissage du gène ACTN4

Le gène ACTN4 est retenu comme candidat après l'analyse différentielle par DESeq2 et DEXSeq. ACTN4 code pour l'alpha-actinine-4, une protéine qui se lie à l'actine et est impliquée dans la régulation de la dynamique du cytosquelette d'actine. Des études ont suggéré son implication dans la progression tumorale, l'invasion et la migration des cellules cancéreuses, en particulier dans le cancer du sein.

La représentation graphique (IVG) du gène ACTN4 révèle sa localisation sur le chromosome 19. Elle met en évidence une disparité dans le nombre de transcrits répertoriés entre deux références génomiques : RefSeq (2 transcrits) et Homosapiens GRCh37 (6




FIGURE 6 – Visualisation par défaut d'IGV du gène ACTN4

transcrits). Cette divergence peut résulter de différences dans l'annotation des gènes ou de l'inclusion de variants de transcrits dans GRCh37, qui offre une annotation plus exhaustive.

ACTN4 est constitué de 21 exons, et l'annotation des transcrits montre que l'exon 8 présente une variation alternative.

Les arcs rouges sur la figure indiquent les jonctions entre les exons, leur épaisseur étant proportionnelle au nombre de lectures soutenant ces jonctions. L'échelle d'expression révèle le nombre de lectures alignées à chaque position du génome. Nous observons une forte expression du gène ACTN4 dans toutes les conditions expérimentales, avec une expression plus élevée dans les réplicats de la condition contrôle (R1 [0-1349], R2 [0-1617]) que dans la condition de silencing de DDX5 et DDX17 (R1 [0-649], R2 [0-437]). La hauteur des pics de couverture des exons indique le nombre de lectures alignées sur chacun d'eux. Une couverture plus importante traduit une expression plus soutenue du gène. En comparant la couverture entre les exons et entre les différentes conditions expérimentales, nous constatons une expression globale plus marquée du gène dans la condition contrôle par rapport à la condition de silencing de DDX5 et DDX17.

Le Sashimi plot aide à mieux comprendre comment fonctionne ce gène. L'analyse du sashimi plot offre une vue d'ensemble des événements d'épissage pour toutes les conditions expérimentales, permettant ainsi d'identifier les jonctions dont l'inclusion ou l'exclusion d'exons est affectée par les conditions. Cette analyse permet de distinguer les exons constitutifs des exons alternatifs.




FIGURE 7 – Visualisation par Sashimi plot du gène ACTN4

Dans le cadre de l'analyse différentielle d'épissage avec DEXSeq, l'exon 8 du gène ACTN4 a été identifié comme un candidat. L'examen attentif du sashimi plot a révélé que les exons 8 sont mutuellement exclusifs, ce qui indique la coexistence de deux isoformes distinctes.




FIGURE 8 – Zoom sur l'exon 8 du gène ACTN4

Pour le réplicat 1 de la condition contrôle, l'exclusion de cet exon est soutenue par 55 lectures, tandis que son inclusion est soutenue par 892 lectures. De manière similaire,

En revanche, pour la condition de silencing, l'inclusion de cet exon est soutenue par 460 lectures pour le réplicat 1 et par 227 lectures pour le réplicat 2. Cette observation est corroborée par les annotations des différents transcrits où cet exon est parfois présent et parfois absent. Ainsi, lors du silencing de DDX5 et DDX17, on observe une nette réduction du nombre de lectures soutenant l'inclusion de l'exon 8 par rapport aux conditions contrôles.

## Analyse différentielle d'expression et d'épissage du gène ATP5MC1

La figure IVG du gène ATP5MC1 montre que ce gène se situe sur le chromosome 17 sur le bras long (q) et contient cinq exons.

Plusieurs transcrits ont été annotés pour le gène ATP5MC1 tant dans le génome de référence RefSeq que dans le génome de référence Homosapiens GRCh37. L'échelle d'expression révèle une forte expression du gène ATP5MC1 dans toutes les conditions expérimentales, avec une expression deux fois plus élevée dans la condition de silencing de

DDX5 et DDX17 (R1 [0-3281], R2 [0-2581]) que dans les réplicats de la condition contrôle (R1 [0-1244], R2 [0-1145]).

On observe des fluctuations de couverture à l'intérieur d'un même exon, pouvant être attribuées à des facteurs tels que le taux de GC ou liées à des problèmes de séquençage illumina. Une couverture plus élevée témoigne d'une expression plus soutenue du gène. En comparant la couverture entre les exons et entre les différentes conditions expérimentales, on constate que l'expression globale du gène est plus importante dans la condition de silencing de DDX5 et DDX17 que dans la condition contrôle.




FIGURE 10 – Visualisation par Sashimi plot du gène ATP5MC1

Après avoir filtré les comptages des transcrits très rares dans le Sashimi plot, nous avons observé une régulation potentielle de l'épissage de certains exons du gène ATP5MC1 par DDX5 et DDX17. Au début du gène, la présence d'un exon alternatif semble être influencée par ces protéines, comme en témoigne une augmentation du nombre de lectures soutenant son inclusion dans la condition de silencing. De plus, nous avons constaté que l'exon 3 présente des voies d'échappement variées vers l'exon 4, vraisemblablement dues à la présence de sites accepteurs alternatifs de type "nag nag".

Dans le Sashimi plot, les exons 2 et 3 ont été identifiés comme des exons alternatifs. L'inclusion de l'exon 2 est significativement plus élevée dans la condition de silencing de DDX5 et DDX17, suggérant leur implication dans sa régulation. De même, l'exon 3 a été identifié comme une cible d'épissage différentiel, avec une augmentation du nombre de lectures soutenant son inclusion dans la condition de silencing. Ces observations suggèrent que DDX5 et DDX17 pourraient jouer un rôle dans la régulation de l'exclusion de ces exons.

En outre, nous avons observé un doublement du nombre de lectures soutenant l'inclusion de l'exon 4, un exon constitutif, dans la condition de silencing, ce qui suggère également une régulation de l'exclusion de cet exon par DDX5 et DDX17.

## 5 Conclusion

En conclusion, cette étude révèle l'impact significatif du silencing des protéines DDX5 et DDX17 sur l'expression et l'épissage de gènes clés, tels que ACTN4 et ATP5MC1, dans le contexte du cancer du sein. Une baisse notable de l'expression de DDX5 et DDX17 suite au silencing a été observée, associée à des altérations d'épissage, suggérant leur rôle potentiel dans la régulation de l'épissage alternatif.

Dans le cas d'ACTN4, une diminution de l'expression a été constatée après silencing, accompagnée d'une réduction de l'inclusion de l'exon 8, indiquant une implication probable de DDX5 et DDX17 dans l'épissage de cet exon.

Quant à ATP5MC1, une augmentation de l'expression a été remarquée après silencing, avec une élévation du nombre de lectures supportant l'inclusion des exons 2, 3 et 4. Ces résultats suggèrent une implication potentielle de DDX5 et DDX17 dans la régulation de l'épissage des exons 2, 3 et 4 de ce gène. Cette régulation pourrait avoir des implications importantes dans la biologie fonctionnelle de ATP5MC1, soulignant l'importance de DDX5 et DDX17 dans le contrôle de l'épissage génique et dans la progression du cancer du sein.

En synthèse, cette étude ouvre la voie à de nouvelles recherches sur le rôle spécifique de DDX5 et DDX17 dans le cancer du sein, et offre des perspectives prometteuses pour l'identification de nouvelles cibles thérapeutiques dans cette maladie et d'autres pathologies associées à des perturbations de l'épissage génique.