



Université Claude Bernard Lyon 1



Master 1 Bio-Informatique

Rapport de Stage

Développement d'une interface interactive
pour l'analyse transcriptomique bulk RNASeq

Etudiant :

Albert NDOUR

Maitres de Stage :

Dr Marie-Cécile MICHALLET

Dr Roxane POMMIER

Lieux de Stage :

Centre de Recherche en Cancérologie de Lyon / Centre Léon Bérard

Équipe de Recherche :

Immunosurveillance du cancer et ciblage thérapeutique
(responsable : Dr Christophe Caux)

Plateforme Bioinformatique :

Plateforme Bioinformatique Gilles Thomas
(responsable : Anthony Ferrari)

23 juin 2024



Résumé

Depuis plusieurs décennies, les avancées en biologie moléculaire et en techniques de séquençage ont révolutionné la compréhension du cancer du sein. Ce dernier demeure un problème de santé publique. Les neutrophiles, en tant que cellules immunitaires, jouent un rôle clé dans le microenvironnement tumoral et leur étude transcriptomique est essentielle pour élucider leur fonction dans la progression tumorale.

L'objectif principal de ce stage était de développer une interface interactive pour la bio-analyse de données transcriptomiques RNAseq bulk. Cet outil permet aux biologistes d'identifier les gènes et les voies moléculaires discriminantes entre différentes conditions d'intérêt, en particulier dans le contexte du cancer du sein et de l'évolution fonctionnelle des neutrophiles au cours de la progression tumorale.

Les données utilisées proviennent d'un modèle murin de cancer du sein MMTV-NeuT. L'interface interactive, développée avec Shiny, intègre plusieurs types d'analyses, y compris l'analyse non-supervisée, l'expression différentielle, et l'enrichissement de voies. Les utilisateurs peuvent visualiser les résultats à travers divers outils graphiques tels que des volcano plots, des clustering hiérarchique (heatmaps) et des analyses d'enrichissement (ORA, GSEA, ssGSEA).

Le développement de cet outil a impliqué la collecte et l'intégration de métadonnées cliniques et de données d'expression. Les métadonnées cliniques, obtenues à partir de fichiers texte, contiennent des informations cruciales sur les échantillons, telles que le type cellulaire, le stade de développement et le génotype. Les données d'expression, issues de pseudo-alignement Salmon au format tximport, comprennent les comptages (counts) pour l'analyse différentielle avec DESeq2 et les valeurs d'abondance des gènes exprimées en TPM pour les visualisations.

Les résultats de cette étude montrent que l'interface permet une analyse facile et conviviale des données transcriptomiques, facilitant ainsi l'interprétation biologique des résultats. Les avantages et limites de l'outil sont discutés, avec des perspectives d'amélioration pour future application.

Mots clés : Cancer du sein, Neutrophiles, Microenvironnement tumoral, Transcriptomique, RNA-seq, Analyse d'expression différentielle, Interface, Modèle murin MMTV-NeuT, Shiny, Analyse non-supervisée, Enrichissement de voies, Volcano plot, Heatmap, Métadonnées cliniques, Pseudo-alignement Salmon, tximport, DESeq2, TPM, Progression tumorale.

Table des matières

1	Introduction	2
1.1	Cancer du Sein	2
1.2	Les Neutrophiles	3
1.3	Problématique	4
2	Matériels et Méthodes	5
2.1	Caractérisation du modèle murin MMTV-NeuT	5
2.2	Données utilisées	6
2.3	Présentation des différents types d’analyses à intégrer dans l’interface . . .	6
2.3.1	Analyse non-supervisée et approche multidimensionnelle	6
2.3.2	Expression différentielle et enrichissement en voies spécifiques . . .	7
2.3.3	Scores de signatures transcriptionnelles	7
2.3.4	Visualisation et mise en forme intégrative des résultats	7
2.4	Pipeline d’analyse non supervisée et d’Analyse d’expression différentielle .	8
2.5	Développement de l’interface interactive	9
2.5.1	Choix de la technologie (Shiny)	9
3	Résultats	9
3.1	Présentation de l’interface développée	10
3.1.1	Panneaux de sélection des échantillons et paramètres	10
3.1.2	Inputs	10
3.1.3	Panneau Principal	11
3.1.4	Sortie d’Erreur	11
3.2	Fonctionnalités et visualisations proposées	12
3.3	Exemples d’utilisation et d’interprétation des résultats	16
4	Discussion/Perspectives	20
4.1	Avantages et limites de l’interface	20
4.1.1	Avantages	20
4.1.2	Limites	20
4.2	Perspectives d’amélioration et de développement futur	20
4.3	Retour d’expérience sur les compétences acquises	21
5	Conclusion	21
6	Bibliographie et Références	23
7	Annexes	24

Table des figures

1	Caractérisation histologique et moléculaires du cancer du sein chez l'Homme	2
2	Caractérisation du modèle de souris MMTV-NeuT relatant la tumoro- genèse mammaire	5
3	Données d'échantillonnage utilisées	6
4	Pipeline d'analyse non supervisée et d'analyse d'expression différentielle . .	8
5	Page d'accueil de l'interface	10
6	condition expérimentale	12
7	condition contrôle	12
8	log2FoldChange	12
9	p-value	12
10	Sortie Volcano Plot	13
11	Sortie Heatmap	13
12	Table des gènes	13
13	Analyse d'enrichissement	14
14	Sortie table des résultats pour la collection Hallmark	14
15	Sortie pathways Hallmark	15
16	Sortie Table	15
17	Exemple de sortie du pathway HALLMARK _A DIPOGENESIS	16
18	Volcano plot Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late . .	17
19	Heatmap Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late	18
20	Table des gènes les plus différentiellement exprimés : Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late	18
21	Hallmark les plus significatifs	19
22	Top Pathways	19
23	Table d'enrichissement	19
24	Enrichissement plot pour le pathway HALLMARK_ADIPOGENESIS . . .	19

Liste des tableaux

1	Logiciel R version 4.1.0 (2021-05-18), les packages utilisés et leurs fonction- nalités	24
---	--	----



Liste des abréviations

- DE - *Expression différentielle (Differential Expression)*
- RNA-Seq - *Séquençage d'ARN (RNA Sequencing)*
- GSEA - *Analyse d'enrichissement de gènes (Gene Set Enrichment Analysis)*
- ORA - *Analyse de sur-représentation de voies (Over-Representation Analysis)*
- TPM - *Transcripts Per Million*
- UI - *Interface Utilisateur (User Interface)*
- CSS - *Feuilles de style en cascade (Cascading Style Sheets)*
- HTML - *Langage de balisage hypertexte (HyperText Markup Language)*
- MMTV-NeuT - *Modèle murin de cancer du sein (Mouse Mammary Tumor Virus - Neu)*
- ER - *Récepteurs aux œstrogènes (Estrogen Receptors)*
- PR - *Récepteurs à la progestérone (Progesterone Receptors)*
- HER2/ERBB2 - *Récepteur au facteur de croissance épidermique humain 2 (Human Epidermal Growth Factor Receptor 2)*
- TNBC - *Cancer du sein triple négatif (Triple-Negative Breast Cancer)*
- ROS - *Espèces réactives de l'oxygène (Reactive Oxygen Species)*
- MDSCs - *Cellules suppressives myéloïdes (Myeloid-Derived Suppressor Cells)*
- PMN-MDSCs - *Cellules suppressives dérivées des neutrophiles (Polymorphonuclear Myeloid-Derived Suppressor Cells)*
- G-MDSCs - *Cellules suppressives dérivées des granulocytes (Granulocytic Myeloid-Derived Suppressor Cells)*
- M-MDSCs - *Cellules suppressives dérivées des monocytes (Monocytic Myeloid-Derived Suppressor Cells)*
- TANs - *Neutrophiles associés aux tumeurs (Tumor-Associated Neutrophils)*
- N1 - *Neutrophiles de type 1*
- N2 - *Neutrophiles de type 2*
- TGF- β - *Facteur de croissance transformant bêta (Transforming Growth Factor Beta)*
- IFN- β - *Facteur de nécrose tumorale bêta (Interferon Beta)*

1 Introduction

1.1 Cancer du Sein

Dans le monde, le cancer du sein reste un problème de santé publique majeur, avec environ 2,3 millions de nouveaux cas et environ 700 000 décès en 2020, faisant de lui la première cause de mortalité par cancer chez la femme. En France, plus de 900 000 personnes sont atteintes de cancer du sein, représentant 33% des nouveaux cas de cancer chez les femmes en 2023.[1, 2]

L'incidence du cancer du sein est modulée par une combinaison complexe de facteurs génétiques et non génétiques. Parmi ces facteurs, l'âge se distingue comme le principal facteur de risque. En effet, l'incidence du cancer du sein augmente significativement après la ménopause. D'autres facteurs incluent les antécédents familiaux, l'obésité, la consommation d'alcool et l'exposition aux œstrogènes.

Les cancers du sein se forment à partir de l'épithélium lobulaire ou canalaire. Ils sont classifiés selon l'histologie et la propagation des cellules cancéreuses des canaux ou des lobules dans le stroma environnant. Le carcinome canalaire *in situ* est la forme pré-invasive la plus commune, représentant 10 à 30% des cas évoluant en cancer invasif. Ce dernier est un ensemble hétérogène divisé selon la morphologie cellulaire : le carcinome canalaire infiltrant (60 à 75% des cas) et le carcinome lobulaire invasif (10 à 15% des tumeurs) [3].

Les lésions pré-invasives constituent des anomalies histologiques où les cellules cancéreuses se regroupent dans les canaux ou les lobules avant de rompre la membrane basale. Ces lésions sont divisées en deux types : les hyperplasies atypiques et les carcinomes *in situ*, bien que ces deux lésions soient difficiles à distinguer histologiquement. Dans les deux cas, les canaux sont partiellement ou complètement remplis par les cellules cancéreuses, formant principalement des foyers isolés ou de petits clusters. La forme invasive du cancer du sein correspond à une forme anarchique où les membranes basales sont rompues [3].




FIGURE 1 – Caractérisation histologique et moléculaire du cancer du sein chez l'Homme

Les cancers du sein sont stratifiés par l'expression des récepteurs aux œstrogènes (ER), aux progestérones (PR) et au facteur de croissance épidermique humain (HER2/ERBB2). L'expression de ces trois récepteurs donne lieu à différents groupes de patients : les cancers du sein ER+ (70% des cas), les cancers du sein HER2+ (15% des cas) et les cancers du sein triple négatifs (TNBC, 15% des cas), qui n'expriment aucun des trois récepteurs et sont parmi les plus agressifs(Fig 1). Cinq sous-types moléculaires ont été déterminés[3] :

- **Luminale A** : Cancer du sein ER^{+/+}PR^{+/+} associé à une forte expression de la signature de gènes luminaux.
- **Luminale B** : Cancer du sein ER^{+/+} avec une faible expression de la signature de gènes luminaux mais une forte expression de gènes associés à la prolifération.
- **HER2** : Amplification du gène HER2 sur le chromosome 17q12 associée à une expression intermédiaire de la signature de gènes luminaux.
- **Basale** : Tumeurs fortement prolifératives surexprimant les cytokératines basales, avec une faible expression de la signature de gènes luminaux, dont 80% sont des cancers du sein TNBC.
- « **Basal-like** » : Forte expression des kératines 5 et 17, de la laminine et de FABP7, avec une absence d'expression des récepteurs hormonaux mais une surexpression du récepteur EGFR.

Les options de traitement pour le cancer du sein varient selon le stade et le sous-type moléculaire. La thérapie ciblée avec des anticorps monoclonaux comme le trastuzumab (Herceptin) a considérablement amélioré le pronostic des patientes atteintes de cancer du sein HER2+, représentant environ 15% des cas. La chimiothérapie reste un traitement de première ligne pour de nombreux sous-types, bien que son efficacité soit limitée par les effets secondaires et l'émergence de résistances.

Alors que les immunothérapies par inhibition des points de contrôle immunitaires ont montré des résultats prometteurs dans d'autres cancers comme le mélanome et le cancer du poumon non à petites cellules (NSCLC), leur efficacité reste modeste dans le cancer du sein. Cela souligne la nécessité de mieux comprendre les mécanismes d'échappement tumoral et d'identifier de nouvelles cibles thérapeutiques, notamment en explorant le rôle des neutrophiles et leur hétérogénéité fonctionnelle au cours de la progression tumorale.

1.2 Les Neutrophiles

Les neutrophiles, cellules immunitaires innées, jouent un rôle crucial dans la réponse inflammatoire et dans divers contextes pathologiques, y compris le cancer. Ils sont abondants dans le sang et peuvent infiltrer les tissus inflammatoires, y compris les tumeurs.

Les neutrophiles sont essentiels dans la défense contre les infections en participant activement à la destruction des agents pathogènes et à la réponse inflammatoire. Ils sont également bénéfiques dans la réparation des surfaces épithéliales ayant été endommagées par l'inflammation en impactant la vascularisation ainsi que le remodelage de la matrice extracellulaire.[6]

Ils constituent la première ligne de défense contre les pathogènes et jouent donc un rôle clé dans le retour à l'homéostasie tissulaire. Ils sont principalement décrits en contexte infectieux pour leurs fonctions classiques, telles que la phagocytose, la dégranulation, la sécrétion de cytokines et de chimiokines et d'agents anti-microbiens, la production de ROS (Reactive Oxygen Species), la NETose et enfin la trogocytose. L'ensemble de ces fonctions dépendent de son activation et donc de l'environnement associé.

Il a été démontré chez l'Homme et chez la souris que la neutropénie (diminution anormale du nombre de neutrophiles) est associée à une diminution de la capacité de réparation des lésions cutanées [7, 8]. Les neutrophiles libèrent des facteurs de croissance (e.g. Vascular Endothelial Growth Factor (VEGF), Epidermal Growth Factor (EGF) et Platelet-Derived Growth Factor (PDGF)) jouant un rôle essentiel dans la prolifération cellulaire, la différenciation et la migration des cellules impliquées dans la régénération tissulaire.

✦ **Classifications historiques des neutrophiles :**

L'hétérogénéité des neutrophiles dans le cancer soulève des divergences et des désaccords dans la littérature concernant leur nomenclature, leurs rôles et leurs caractéristiques biologiques. Historiquement, les neutrophiles ont été classés selon différentes approches :

➤ ① **PMN-MDSCs et GMDSCs**

Les MDSCs sont des cellules myéloïdes immatures ayant la capacité d'inhiber les fonctions anti-tumorales des cellules immunitaires effectrices présentes dans le microenvironnement tumoral.

Les sous-populations de MDSCs chez la souris :

- G-MDSCs (granulocytiques)
- M-MDSCs (monocytiques)

Les sous-populations de MDSCs chez l'Homme :

- PMN-MDSCs (polymorphonucléaires)
- M-MDSCs (monocytiques)
- e-MDSCs (stade précoce)

D'autres marqueurs ont été proposés pour mieux distinguer les sous-populations, mais leur spécificité reste controversée. Il existe des problématiques autour de cette nomenclature : Manque de consensus sur les marqueurs définissant les MDSCs et une confusion fréquente entre neutrophiles et PMN/G-MDSCs sans validation de leurs propriétés suppressives. Mais un consensus récent propose de renommer les PMN/G-MDSCs en "neutrophiles immunosuppresseurs" pour plus de clarté.[3]

➤ ② **N1 versus N2**

Les neutrophiles associés aux tumeurs (TANs) ont été classés en deux catégories fonctionnelles :

- **Les neutrophiles de type 1 (N1) aux propriétés anti-tumorales.** Ils possèdent des propriétés anti-tumorales notamment des fonctions cytotoxiques, d'apoptose des cellules tumorales, d'inhibition de métastases et de potentialisation des réponses anti-tumorales des effecteurs adaptatifs
- **Les neutrophiles de type 2 (N2) aux propriétés pro-tumorales.** Ils possèdent des propriétés pro-angiogéniques, favorisant l'invasion métastatique et l'immunosuppression

Une conversion fonctionnelle de N1 vers N2 favorisée par le TGF- β , à l'inverse, l'IFN- β polarise les N2 vers un phénotype N1.

Les neutrophiles, connus pour leur faible teneur en ARN et leur courte durée de vie, posent des défis pour les analyses transcriptomiques. Des études récentes ont révélé des différences significatives entre les neutrophiles circulants et ceux infiltrant les tumeurs, suggérant une adaptation aux microenvironnements spécifiques.

1.3 **Problématique**

Le microenvironnement tumoral du cancer du sein est complexe, avec diverses cellules immunitaires, notamment les neutrophiles. Des données générées dans le modèle murin MMTV- NeuT, qui développe des tumeurs mammaires suite à la surexpression de l'oncogène Neu (homologue murin de HER2), montrent une certaine plasticité du neutrophile

avec un rôle plutôt anti-tumoral aux stades précoces de la tumorigenèse, et pro-tumoral aux stades tardifs. Les mécanismes moléculaires impliqués restent à élucider.

Afin de caractériser le profil transcriptomique des neutrophiles présents aux stades précoce et tardif de la tumorigenèse, du RNAseq bulk a été généré dans le modèle murin MMTV-Neu (voir « données générées »).

L'objectif principal de ce stage était de développer une interface interactive pour la bio-analyse de données transcriptomiques RNAseq bulk, permettant aux biologistes d'identifier les gènes et les voies moléculaires discriminantes entre différentes conditions d'intérêt, en particulier dans le contexte du cancer du sein et de l'évolution fonctionnelle des neutrophiles au cours de la progression tumorale. Cette interface interactive intégrera diverses analyses, telles que l'analyse non supervisée et l'approche multidimensionnelle, l'expression différentielle et l'enrichissement en voies spécifiques, les scores de signatures transcriptionnelles, ainsi que la visualisation et la mise en forme intégrative des résultats.

2 Matériels et Méthodes

2.1 Caractérisation du modèle murin MMTV-NeuT

Le modèle murin MMTV-NeuT, à partir duquel les données RNASeq ont été générées, permet d'étudier la progression tumorale mammaire depuis les stades précoces jusqu'aux stades tardifs. Dans ce modèle, les souris femelles Balb/c expriment l'oncogène Neu (homologue murin de HER2) sous le contrôle du promoteur MMTV (Mouse Mammary Tumor Virus). Les souris NeuT⁺ développent spontanément des tumeurs mammaires au cours de leur croissance jusqu'à 25 semaines d'âge, tandis que les souris contrôles NeuT⁻ n'expriment pas l'oncogène et ne développent pas de tumeur. Chez ces souris contrôles NeuT⁻, seuls des aspects de développement mammaire normal sont observés (Figure 2).




FIGURE 2 – Caractérisation du modèle de souris MMTV-NeuT relatant la tumorigenèse mammaire

2.2 Données utilisées

L'étude a utilisé le modèle murin transgénique MMTV-NeuT pour générer des données transcriptomiques permettant d'analyser l'évolution fonctionnelle des neutrophiles au cours de la progression tumorale mammaire. Un RNA-seq a été réalisé sur différents types cellulaires issus de souris NeuT⁺ et NeuT⁻ aux stades précoce et tardif du développement tumoral (Figure 3) :

1. Tissu mammaire entier (bulk, cellules vivantes totales)
2. Cellules épithéliales mammaires triées (Epi)
3. Neutrophiles infiltrant la glande mammaire (Neutro-MG)
4. Neutrophiles de la moelle osseuse (Neutro-BM)
5. Neutrophiles sanguins (Neutro-Blood)

Pour s'assurer d'une couverture suffisante des neutrophiles, qui contiennent peu d'ARN, ils ont été séquencés indépendamment sur une lame de séquençage dédiée.

Ce jeu de données multi-tissus et multi-stades, comprenant soixante et onze(71) échantillons au total, permet d'investiguer les caractéristiques transcriptomiques des neutrophiles issus de différents organes (glande mammaire, moelle osseuse, sang) aux stades précoce et tardif de la tumorigenèse mammaire. Cette approche offre une vision globale et intégrée des changements moléculaires associés à l'évolution fonctionnelle des neutrophiles et de leur impact sur la progression tumorale.




FIGURE 3 – Données d'échantillonnage utilisées

2.3 Présentation des différents types d'analyses à intégrer dans l'interface

L'interface interactive que nous avons développé permet d'effectuer différents types d'analyses sur les données transcriptomiques RNASeq, afin d'identifier les gènes et les voies moléculaires clés impliqués dans les fonctions pro- et anti-tumorales des neutrophiles au cours de la progression du cancer du sein. Les principales analyses à intégrer sont les suivantes :

2.3.1 Analyse non-supervisée et approche multidimensionnelle

Ces analyses exploratoires non-supervisées, telles que l'Analyse en Composantes Principales (ACP) et les méthodes de clustering, permettront de visualiser la structure des

données et d'identifier d'éventuels regroupements naturels d'échantillons en fonction de leur profil d'expression génique global.

Voici le texte formaté en deux sous-sections spécifiques comme demandé :

2.3.2 Expression différentielle et enrichissement en voies spécifiques

Analyse d'expression différentielle et ORA : L'analyse d'expression différentielle, avec l'outil DESeq2, identifiera les gènes différentiellement exprimés entre les conditions d'intérêt. L'analyse ORA (Over-Representation Analysis) permettra ensuite de relier ces gènes dérégulés à des voies de signalisation biologiques connues en évaluant la sur-représentation statistique des gènes différentiellement exprimés dans des ensembles de gènes prédéfinis.

Analyse GSEA : L'analyse GSEA (Gene Set Enrichment Analysis) sera réalisée pour évaluer la significativité statistique de l'enrichissement des voies biologiques. Contrairement à l'ORA, GSEA prend en compte tous les gènes, pas seulement ceux différentiellement exprimés, en les classant selon leur niveau d'expression. GSEA calcule un score d'enrichissement (ES) pour chaque ensemble de gènes en parcourant la liste ordonnée, augmentant une statistique de somme cumulée lorsqu'un gène appartient à l'ensemble et la diminuant lorsqu'il n'y appartient pas. Cette approche permet de détecter des changements subtils mais cohérents dans l'expression des gènes au sein de voies biologiques.

2.3.3 Scores de signatures transcriptionnelles

Le calcul de scores de signatures transcriptionnelles spécifiques, via des méthodes comme ssGSEA (single-sample Gene Set Enrichment Analysis) fournira une représentation synthétique du niveau d'activation de processus biologiques d'intérêt dans chaque échantillon.

2.3.4 Visualisation et mise en forme intégrative des résultats

L'interface proposera différentes visualisations interactives (ACP, heatmaps, ORA, GSEA, ssGSEA, etc.) pour explorer de manière intégrée les résultats des différentes analyses. Un soin particulier sera apporté à l'ergonomie et à la convivialité de l'interface pour faciliter l'interprétation biologique par les biologistes.

2.4 Pipeline d'analyse non supervisée et d'Analyse d'expression différentielle




FIGURE 4 – Pipeline d'analyse non supervisée et d'analyse d'expression différentielle



2.5 Développement de l'interface interactive

2.5.1 Choix de la technologie (Shiny)

Le choix de la technologie Shiny pour l'analyse des données et la construction des différentes figures sous R est justifié par plusieurs raisons, basées sur les caractéristiques et avantages de Shiny :

Simplicité et accessibilité Shiny permet de créer des interfaces interactives avec une syntaxe intuitive, idéale pour les utilisateurs de R.

Architecture flexible Shiny a une architecture composée de l'interface utilisateur (UI) et du serveur, offrant flexibilité et modularité dans le développement de l'outil.

Intégration avec R Shiny s'intègre parfaitement avec R, utilisant tous les packages et fonctionnalités de R pour l'analyse et la visualisation de données (Cf section annexes pour les packages utilisés).

Interactivité et réactivité Shiny permet des interactions en temps réel et des mises à jour automatiques des sorties, offrant une expérience utilisateur fluide.

Déploiement facile Shiny offre des options de déploiement simples, comme shinyapps.io et Shiny Server, facilitant la distribution de l'outil au besoin.

Personnalisation et extensibilité Shiny permet une personnalisation poussée de l'interface avec HTML, CSS et des packages complémentaires, créant des applications esthétiques et fonctionnelles.

3 Résultats

La conception de l'interface n'est pas encore complète, la partie « Analyse différentielle » est terminée mais la partie « Analyse non-supervisée » est encore en cours de conception. Nous présentons ce que nous avons réalisé jusqu'à aujourd'hui dans cette section Résultats.

La figure 5 présente l'interface Shiny conçue pour effectuer une analyse d'expression différentielle (DE) sur des données RNA-Seq, avec des visualisations telles que des graphiques de type "**Volcano Plot**", "**Heatmap**", et des analyses d'enrichissement (**ORA et GSEA**). L'interface permet à l'utilisateur de sélectionner les conditions expérimentales testées et contrôles, ainsi que d'ajuster les paramètres de l'analyse (log2FoldChange et p-value ajustée).




FIGURE 5 – Page d'accueil de l'interface

3.1 Présentation de l'interface développée

L'interface présente deux panneaux : un panneau latéral(gauche) et un panneau principal(droite)

3.1.1 Panneaux de sélection des échantillons et paramètres

Deux listes déroulantes permettent de sélectionner le type de cellule (Neutrophiles/Cellules épithéliales/Cellules vivantes) avec leur origine tissulaire (MO, BM. ...), et les stades de la tumorigenèse (précoce, tardif) pour les conditions expérimentales (NeuT⁺) et les conditions de contrôle (NeuT⁻). Les options incluent une boîte d'actions, un format de texte pour le nombre de conditions sélectionnées et la possibilité de sélections multiples.

3.1.2 Inputs

Les données utilisées comprennent les métadonnées cliniques chargées à partir d'un fichier texte et les données d'expression de pseudo-alignement Salmon au format tximport chargées à partir d'un fichier RDS .

1. Les données d'expression de pseudo-alignement Salmon au format tximport contiennent :
 - **abundance** : les valeurs d'abondance des gènes exprimées en TPM (*Transcripts Per Million*)
 - **counts** : les comptages, qui représentent le nombre de lectures alignées sur chaque gène
 - **length** : la longueur de chaque gène
2. Les métadonnées cliniques pour chaque échantillon contiennent des informations sur :
 - **Genotype** : le génotype de l'échantillon (NeuT⁺ et NeuT⁻)
 - **Stage** : le stade de développement (Early et Late)
 - **Tissu** : le type de tissu(sang, glande mammaire, moelle Osseuse)
 - **Cell_type** : le type cellulaire (neutrophiles, cellules épithéliales, cellules vivantes(bulk))



— **Sample** : l'identifiant de l'échantillon

Ces métadonnées permettent de regrouper les échantillons en conditions expérimentales testées et contrôles pour les différentes analyses.

Les échantillons

Les entrées (conditions expérimentales testées et les contrôles) sont définies par des couleurs distinctes (Cf Fig6 et 7) :

- ☐ Deux panneaux bien distincts avec des couleurs de fond différentes :
 - ☐ vert clair pour le panneau de Contrôle.
 - ☐ rouge clair pour le panneau de Condition expérimentale testée.
- ☐ Chaque panneau offre la possibilité de sélectionner le type de cellule et le stade/génotype du modèle murin, à la fois pour la condition expérimentale testée et le contrôle.

Les paramètres

Deux listes déroulantes permettent de choisir les seuils de valeur p ajustée et de fold change pour filtrer les gènes différentiellement exprimés.

- ✿ Une possibilité de choisir le seuil de p-value ajustée.(Cf Fig 8)
- ✿ Une possibilité de choisir le seuil de log2 Fold Change.(Cf Fig 9)

Boutons d'action

- ☞ Un bouton ***Run Analysis*** pour lancer l'analyse.
- ☞ Un bouton ***Update View*** pour mettre à jour la sélection.

3.1.3 Panneau Principal

Ce panneau principal contient plusieurs onglets. Le premier onglet (**Project Description**) affiche une image descriptive du projet, tandis que les autres onglets présentent les résultats des analyses effectuées. Les détails sur ces onglets se trouvent dans la section ***Fonctionnalités et Visualisation***.

3.1.4 Sortie d'Erreur

Une sortie d'erreur est présente pour afficher les messages d'erreur éventuels.

SUPERVISED ANALYSIS(DE)

FIGURE 6 – condition expérimentale

SUPERVISED ANALYSIS(DE)

FIGURE 7 – condition contrôle

SUPERVISED ANALYSIS(DE)

FIGURE 8 – log2FoldChange

SUPERVISED ANALYSIS(DE)

FIGURE 9 – p-value

3.2 Fonctionnalités et visualisations proposées

Fonctionnalités L'analyse des gènes différentiellement exprimés a été réalisée avec DE-Seq2. Les critères de sélection sont une valeur p ajustée inférieure à la valeur spécifiée dans les paramètres (p-value par défaut 0.05) et une valeur absolue de log2 fold change supérieure à la valeur spécifiée (par défaut 0).

Volcano Plot et Clustering hiérarchique

Pour le volcano plot : ggplot est utilisé pour construire ce volcano plot qui permet de visualiser les gènes différentiellement exprimés en fonction de leur significativité statistique ($-\log_{10}(\text{padj})$) et de leur amplitude de changement d'expression (log2FoldChange)

Pour 1 clustering hiérarchique : une matrice contenant les données d'expression génique différentielle à représenter dans la heatmap. Les gènes (lignes) et les échantillons (colonnes) sont regroupés par similarité d'expression. La méthode de clustering Ward.D et la distance euclidienne sont utilisées pour regrouper les gènes et les échantillons.

SUPERVISED ANALYSIS(DE)




FIGURE 10 – Sortie Volcano Plot

SUPERVISED ANALYSIS(DE)




FIGURE 11 – Sortie Heatmap

SUPERVISED ANALYSIS(DE)

Gene	Log2FoldChange	Padj	Regulation
Krt8	9.09e+00	1.66e-03	Up-regulated
Ccn1s2a	7.80e+00	7.64e-04	Up-regulated
Kit	7.66e+00	2.34e-03	Up-regulated
Fgfr2	7.24e+00	1.77e-02	Up-regulated
Lima1	7.15e+00	2.66e-03	Up-regulated
Cd2ap	7.06e+00	1.94e-03	Up-regulated
Mtge8	7.04e+00	2.92e-02	Up-regulated
Prep	7.02e+00	2.75e-03	Up-regulated
Magi1	6.99e+00	3.18e-02	Up-regulated
Myo10	6.94e+00	8.98e-03	Up-regulated

FIGURE 12 – Table des gènes

Analyse de sur-représentation de voies de signalisation (ORA)

Les gènes différentiellement exprimés (DE) identifiés par l'analyse différentielle ne fournissent qu'une liste de gènes sans donner de contexte biologique. L'analyse de sur-représentation de voies de signalisation (ORA) permet de relier ces gènes à des processus biologiques connus en identifiant les voies de signalisation et les processus biologiques sur-représentés parmi les gènes DE. En identifiant les voies sur-représentées, l'ORA peut révéler les mécanismes moléculaires et les processus biologiques potentiellement perturbés ou activés dans la condition étudiée, aidant ainsi à comprendre les bases moléculaires du phénotype observé. Les analyses de sur-représentation de voies de signalisation(ORA)

à partir des gènes différentiellement exprimés ont été effectuées en utilisant la base de données MSigDB (version 7.4) pour la souris. Les collections suivantes ont été incluses :

- **H** : hallmark gene sets
- **C2** : curated gene sets :
 - ① **C2.CGP** : chemical and genetic perturbations
 - ② **C2.CP** : canonical pathways
- **C5** : gene ontology (GO)

Les résultats d'enrichissement ont été générés indépendamment pour chaque collection de gènes et corrigés pour les comparaisons multiples à l'aide de la méthode Benjamini-Hochberg(BH).

Les résultats d'enrichissement sont affichés dans des graphiques et des tableaux pour chaque collection, séparément pour les gènes sur-exprimés (UP) et sous-exprimés (DOWN).




FIGURE 13 – Analyse d'enrichissement

Show 10 entries

Description	GeneRatio	BgRatio	p.adjust	geneID
All	All	All	All	All
HALLMARK_OXIDATIVE_PHOSPHORYLATION	42/2343	191/21801	2.37e-04	Hsd17b10/Alp5g3/Acaa2/Fxn/Nqo2/Ndufv1/Cyba/Mrgp15/Ndufb8/Pdha/Alp5e/Uqor10/Cox7a2/Timm10/Maoab/Ech1/Ndufa4/Cpt1c/Cox5a/Uppro/Ndufb3/Acadl/Retsat/Ndufb2/Ethd8
HALLMARK_MYC_TARGETS_V1	44/2343	219/21801	7.89e-04	Hdgf/Pamrd1/Pwp1/Tjms/Cct4/Hnmpa3/Pamb3/Hsp90aa1/Cct3/Ran/Nolc1/Lsm7/Eprs/Top1/Sabp1/Psma6/Psmc6/Hdac1/Polr2/Txn14a/Odc1/Xpot/Snmpb2/Cox5a/Cul1/Tandp/U2af1k
HALLMARK_ADIPOGENESIS	50/2343	265/21801	8.97e-04	Atf3/Slc1a5/Acaa2/Ubiqin2/Snoga/Abca2/Mpst/Slc19a1/Dhcr7/Mrp15/Nmt1/Pgm1/Fabp4/Ddt/Ptcd3/Hbch/Rmdn3/Arat/Cidea/Phldb1/Mch2/Mtar2/Cavin3/Cavin2/Itpa3/Adcy6/Uqor1
HALLMARK_E2F_TARGETS	42/2343	239/21801	1.17e-02	Rpa3/Smc1a/Gins4/Pds5a/Pim2/Nasp/Brcal/Pik4/Rfc3/Lig1/Cse1/Ran/Nolc1/Pds5b/Rbbp7/Pole4/Arp32e/Smc6/Phad1/Chk2/Lyar/H2ac10/Polea/Pold2/Tubg1/Upt1/Zw10/Adf1a/Tubg
HALLMARK_G2M_CHECKPOINT	44/2343	264/21801	2.14e-02	Slc38a1/Syngap1/Smc1a/Numa1/Pds5a/Cdc7/Prim2/Nasp/Pik4/Neik2/Cend1/H2bc21/Nolc1/Mtt2/Pds5b/Trpo2/Dmd/Srsf10/Nup50/H2ac10/Polea/H2bc14/Atf5/Kif5a/Kmt5a/Odc1/Uck
HALLMARK_DNA_REPAIR	29/2343	170/21801	6.76e-02	Rpa3/Ubp3b/Polr1d/Rfc3/Tjms/Ulg1/Ddb2/Pole4/Nudb9/Polh/Adcy6/Erc55/Ak4/Polr2e/Gt2h5/Cetn2/Pom121/Ak1/Nbx1/Ada7ag101/Pde4c/Nme1/Rnf7/Rbx1/Pps37d/Polr2d/Dguok/Agc
HALLMARK_FATTY_ACID_METABOLISM	34/2343	212/21801	8.12e-02	Hsd17b10/Eci2/Acaa2/Bivra/Hsp90aa1/Hbch/Cidea/Gstz1/Reep5/Maoab/Aldh9a1/Ech1/Kmt5a/Odc1/Cpt1c/Acads/Moea/Acadl/Retsat/Sms/Hmgcs1/Ethdv/Hsdhb/Fh1/Uros/Cd1d1/Ox
HALLMARK_MTORC1_SIGNALING	38/2343	245/21801	8.24e-02	Slc1a5/Ldr/Alp5g3/Mthkd2/Prdx2/Dhcr7/Nmt1/Pgm1/Slc1/Eprs/Txnd3/Cct6a/Psmc6/Syt12/Ilg5b/Hmba/Ak4/Ppa1/Tubg1/Psat1/Ii30/Pitpnb/Pamrd12/Pik3r2/Tubg2/Tuba1b/Shn
HALLMARK_MYC_TARGETS_V2	12/2343	58/21801	1.05e-01	Pik4/Slc19a1/Utp20/Nolc1/Las1/Grnd1/Rabepk/Phb/Prmt3/Tb2tm/Srm/Aimp2
HALLMARK_EPITHELIAL_MESENCHYMAL_TRANSITION	40/2343	280/21801	1.89e-01	P3h2/Snai2/Cxcl2/Col6a1/Spp1/Cdgh1/Cdthrc1/Igfbp10/Eln/Col5a2/Alp1/Snib1/Cadm1/Col12a1/Pmepa1/Igfb5/Lama3/Col4a6/Igfb2b/Tnfrsf11b/Sfrp1/Lamc1/Serpine1/Gja1/Gpc1/Ln

Showing 1 to 10 of 50 entries

FIGURE 14 – Sortie table des résultats pour la collection Hallmark

Analyse d'enrichissement global de voies de signalisation (GSEA)

Contrairement à l'analyse de sur-représentation (ORA) qui se concentre uniquement sur les gènes différentiellement exprimés de manière significative, la GSEA considère tous les gènes dans leur ordre de classement basé sur leur niveau d'expression différentielle. Cela permet de détecter des signaux subtils au niveau des voies qui pourraient être manqués par l'ORA.

Certaines voies peuvent être perturbées de manière coordonnée, avec de nombreux gènes montrant des changements d'expression modestes mais cohérents. La GSEA est capable de détecter ces voies en considérant l'ensemble des gènes plutôt que de se concentrer uniquement sur les gènes les plus différentiellement exprimés.

Au lieu de simplement déterminer si une voie est sur-représentée ou non, la GSEA calcule un score d'enrichissement continu qui capture l'ampleur du dysfonctionnement de la voie, permettant une interprétation plus nuancée.

L'analyse d'enrichissement global de voies de signalisation (GSEA) est effectuée via le package **fgsea** en utilisant la liste de rangs pour l'ensemble des gènes(calculée pour chaque gène en utilisant la différence des moyennes d'expression entre les deux conditions, divisée par la somme des écarts-types) et les collections de voies de signalisation récupérées à partir de MSigDB

Les résultats de l'analyse GSEA sont affichés dans des graphiques et des tableaux, avec des options pour sélectionner soit une collection entière de voies de signalisation soit le pathway précis que l'on souhaite testé




FIGURE 15 – Sortie pathways Hallmark




FIGURE 16 – Sortie Table




FIGURE 17 – Exemple de sortie du pathway $HALLMARK_{ADIPOGENESIS}$

visualisations proposées La visualisation des résultats se trouve dans les onglets suivants :

- **Project Description** : Affiche une image descriptive du projet.
- **Volcano Plot** : Affiche un graphique de type "Volcano Plot" et des sorties textuelles pour le nombre de gènes différentiellement exprimés, le nombre d'échantillons dans les conditions expérimentale testée et contrôle.
- **Heatmap** : Affiche un graphique de type "Heatmap" illustrant le clustering hiérarchique des gènes différentiellement exprimés.
- **Top Genes Table** : Affiche un tableau interactif des gènes.
- **ORA** : Contient deux menus déroulants ("UP" et "DOWN") pour afficher les résultats de l'analyse d'enrichissement pour les gènes sur-exprimés("UP") et sous-exprimés("DOWN"), respectivement. Chaque menu contient des onglets pour différentes collections (Hallmark, C2.CGP, C2.CP, C5) avec des graphiques et des tableaux de données.
- **GSEA** : Le panneau latéral contient un bouton pour choisir une collection, un bouton pour entrer le nom d'une voie, et un bouton pour soumettre. Le panneau principal contient trois onglets : "Top Pathways", "Enrichment Table" et "Enrichment Plot".

3.3 Exemples d'utilisation et d'interprétation des résultats

Sélection des conditions expérimentales et de contrôle

Pour définir les groupes à comparer dans l'analyse d'expression différentielle, commençons par sélectionner les conditions expérimentales et de contrôle :

① condition expérimentale testée :

- ✓ Type de cellule : Neutro_MG : Neutrophiles de la glande mammaire
- ✓ Stade de la souris : NeuT_Late : Souris qui développent spontanément des tumeurs mammaires au stade tardif (25 semaines d'âge)

② Condition contrôle :

- ✓ Type de cellule : Neutro_Blood : Neutrophiles circulants (du sang)

- ✓ Stade de la souris : NeuT_Late : Souris qui développent spontanément des tumeurs mammaires au stade tardif (25 semaines d'âge)

Volcano Plot

Après avoir lancé l'analyse, on peut visualiser le graphique volcano qui représente les gènes différentiellement exprimés en fonction de leur fold change ($=1$) et de leur valeur p ajustée ($=0.05$). (Fig 18) Pour les conditions sélectionnées on a 5 échantillons pour chaque condition, les gènes sur-exprimés (UP=2069) sont représentés en jaune foncé, tandis que les gènes sous-exprimés (DOWN=535) sont représentés en bleu foncé. Les gènes non significatifs sont représentés en gris. Le graphique volcano permet d'identifier




FIGURE 18 – Volcano plot Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late

rapidement les gènes les plus différentiellement exprimés entre les conditions. Les gènes situés dans les coins supérieurs gauche et droit sont les plus intéressants, car ils présentent une forte différence d'expression ($\log_2\text{FoldChange}$ élevé) et une signification statistique élevée (valeur p ajustée faible).

Heatmap

La heatmap offre une représentation visuelle des niveaux d'expression des gènes différentiellement exprimés à travers les échantillons (Fig 19). Les couleurs qui tirent vers rouge indiquent une expression élevée, tandis que les couleurs qui tirent vers bleu indiquent une expression faible. Cette heatmap permet d'identifier les profils d'expression des gènes et de détecter




FIGURE 19 – Heatmap Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late

les regroupements (clusters) d'échantillons ou de gènes présentant des similitudes d'expression. Cette visualisation peut aider à identifier des sous-groupes d'échantillons ou des ensembles de gènes co-régulés.

Table des gènes les plus différentiellement exprimés

La table interactive affiche les gènes les plus différentiellement exprimés (Fig 20). L'utilisateur peut facilement explorer cette table, filtrer ou trier les résultats et obtenir des informations détaillées sur chaque gène, telles que le nom du gène, le fold change, la valeur p ajustée, etc. Cette table permet d'identifier rapidement les gènes les plus pertinents pour

Project Description Volcano Plot **Heatmap** Top Genes Table ORA GSEA

Show 10 entries Search:

Gene	Log2FoldChange	Padj	Regulation
ND4L	8.91e+00	9.20e-03	Up-regulated
Papln	8.04e+00	4.78e-04	Up-regulated
Aqp5	7.80e+00	5.53e-04	Up-regulated
Cnmd	7.27e+00	2.23e-02	Up-regulated
Igfbp5	6.84e+00	6.23e-04	Up-regulated
Arhgap32	6.80e+00	2.23e-04	Up-regulated
Fastkd2	6.66e+00	1.02e-04	Up-regulated
Adam12	6.64e+00	2.51e-04	Up-regulated
Prex2	6.53e+00	1.30e-03	Up-regulated
Nphp3	6.51e+00	1.16e-04	Up-regulated

Showing 1 to 10 of 16,346 entries

Previous 1 2 3 4 5 ... 1,635 Next

FIGURE 20 – Table des gènes les plus différentiellement exprimés : Neutro_MG & NeuT_Late vs Neutro_Blood & NeuT_Late

Analyses d'enrichissement (ORA et GSEA)

Les résultats d'enrichissement fournissent des informations précieuses sur les mécanismes biologiques sous-jacents aux changements d'expression observés, aidant ainsi à comprendre les processus impliqués dans le phénomène étudié.




FIGURE 22 – Top Pathways




FIGURE 24 – Enrichissement plot pour le pathway HALL-MARK_ADIPOGENESIS



4 Discussion/Perspectives

4.1 Avantages et limites de l'interface

L'interface est conçue pour effectuer une analyse d'expression différentielle supervisée spécifique et pour visualiser les résultats de manière interactive. Elle offre plusieurs avantages et présente quelques limites :

4.1.1 Avantages

- ✓ **Convivialité** : L'interface est pratique et conviviale, facilitant l'utilisation même pour les utilisateurs ayant peu d'expérience en bioinformatique.
- ✓ **Validation des entrées** : Des mécanismes de validation des entrées utilisateur sont intégrés pour éviter les erreurs et les comportements indésirables en cas de valeurs incorrectes.

4.1.2 Limites

- ✗ **Spécificité des données** : L'interface est limitée aux analyses d'expression différentielle supervisée spécifique et ne permet pas d'effectuer ces analyses sur d'autres types de données.
- ✗ **Performance** : Selon la taille des données et les ressources système disponibles, l'interface pourrait rencontrer des problèmes de performance, en particulier pour les analyses d'enrichissement qui peuvent être coûteuses en termes de calcul.
- ✗ **Fonctionnalités avancées** : Actuellement, l'interface ne propose pas de fonctionnalités avancées telles que l'exportation des résultats, la personnalisation des graphiques (comme la possibilité de choisir la couleur des axes), ou l'intégration avec d'autres outils d'analyse.

4.2 Perspectives d'amélioration et de développement futur

L'interface offre une base solide pour l'analyse d'expression différentielle, mais plusieurs améliorations sont envisagées pour optimiser l'outil et étendre ses fonctionnalités :

Documentation

- ✎ Ajouter une documentation détaillée du code, des fonctions et des paramètres utilisés pour faciliter la compréhension, la maintenance et l'extension de l'outil par d'autres développeurs.

Flexibilité des analyses

- ✎ Permettre à l'utilisateur de choisir d'autres types d'analyses (par exemple, l'analyse d'expression non supervisée ou supervisée) et de personnaliser davantage les paramètres d'analyse selon ses besoins spécifiques.



Optimisation des performances

- ✎ Évaluer et optimiser les performances de l'outil, en particulier pour les analyses d'enrichissement qui peuvent être coûteuses en termes de calcul, en utilisant des techniques de parallélisation ou de pré-calcul.

Fonctionnalités avancées

- ✎ Ajouter des fonctionnalités avancées telles que l'exportation des résultats dans différents formats(xls, png...) et la personnalisation des graphiques (choix des couleurs, etc.).

4.3 Retour d'expérience sur les compétences acquises

Le développement de cet outil Shiny pour l'analyse d'expression différentielle supervisée a permis d'acquérir et de renforcer plusieurs compétences importantes :

- ➡ **Programmation en R** : Une meilleure maîtrise du langage de programmation R, de ses structures de données et de ses packages spécialisés dans l'analyse de données transcriptomiques et la visualisation.
- ➡ **Analyse de données transcriptomiques** : Une compréhension approfondie des concepts et des méthodes d'analyse d'expression différentielle, d'enrichissement de gènes et de voies de signalisation, ainsi que de la gestion et du traitement des données de séquençage d'ARN.
- ➡ **Développement d'applications web** : Une expérience pratique dans le développement d'applications web interactives avec le framework Shiny, incluant la conception d'interfaces utilisateur, la gestion des entrées et des sorties, et l'intégration de visualisations de données.
- ➡ **Gestion de projet** : Une meilleure compréhension des étapes de développement d'un projet, de la planification à la mise en œuvre, en passant par la documentation et les tests.
- ➡ **Collaboration et communication** : Une expérience de travail en équipe, de communication avec les parties prenantes et de présentation des résultats de manière claire et concise.
- ➡ **Résolution de problèmes** : Une capacité renforcée à identifier et résoudre les problèmes techniques, à déboguer le code et à trouver des solutions créatives aux défis rencontrés.
- ➡ **Apprentissage continu** : Une motivation pour l'apprentissage continu et la mise à jour des connaissances dans un domaine en constante évolution, tel que l'analyse de données transcriptomiques et le développement d'applications web.

5 Conclusion

Au cours de ce stage, un outil Shiny pour l'analyse d'expression différentielle a été développé avec succès. Cet outil offre une interface conviviale permettant aux utilisateurs de sélectionner les conditions expérimentales et de contrôle, de visualiser les résultats sous différentes formes (graphiques volcano, heatmaps, tableaux de gènes différentiellement exprimés), et de réaliser des analyses d'enrichissement de gènes et de voies de signalisation.

Le développement de cet outil a nécessité une compréhension approfondie des concepts et des méthodes d'analyse d'expression différentielle, d'enrichissement de gènes et de voies de signalisation, ainsi que la maîtrise de langages de programmation tels que R et de frameworks de développement d'applications web comme Shiny.

L'outil développé revêt une importance particulière dans le domaine de l'analyse de données transcriptomiques, en particulier pour les chercheurs biologistes travaillant sur l'expression différentielle des gènes et l'identification des voies de signalisation impliquées dans des processus biologiques ou des pathologies.

Cet interface conviviale facilite aux biologistes l'analyse et l'interprétation des données de séquençage du transcriptome des neutrophiles. Il permettra d'étudier en profondeur le rôle des utilisateurs la possibilité d'explorer les mécanismes moléculaires sous-jacents aux changements d'expression observés, ouvrant ainsi de nouvelles perspectives pour la compréhension des processus biologiques des neutrophiles dans le cancer du sein. Enfin, cet outil représente une contribution importante au domaine de la bioinformatique et de l'analyse de données transcriptomiques, en offrant une solution accessible et performante pour l'analyse d'expression différentielle supervisée.



6 Bibliographie et Références

Références

- [1] Łukasiewicz, Sergiusz et al. “Breast Cancer-Epidemiology, Risk Factors, Classification, Prognostic Markers, and Current Treatment Strategies-An Updated Review.” *Cancers* vol. 13,17 4287. 25 Aug. 2021, doi :10.3390/cancers13174287
- [2] Henriques, Beatriz et al. “Immunotherapy in Breast Cancer : When, How, and What Challenges?.” *Biomedicines* vol. 9,11 1687. 14 Nov. 2021, doi :10.3390/biomedicines9111687
- [3] Manuela PEREIRA ABRANTES : Hétérogénéité des neutrophiles et leurs écosystèmes dans l’immunosurveillance au cours de la tumorigenèse. Immunologie et Oncologie. Université Claude Bernard Lyon 1, (2023).
- [4] Pacôme Lecot. Caractérisation des neutrophiles circulants et associés aux tumeurs aux stades précoces et tardifs de la tumorigenèse. Immunothérapie. Université de Lyon, (2020). Français. fNNT : 2020LYSE1147ff. fftel-03351405f
- [5] Gentles, Andrew J et al. “The prognostic landscape of genes and infiltrating immune cells across human cancers.” *Nature medicine* vol. 21,8 (2015) : 938-945. doi :10.1038/nm.3909
- [6] Phillipson, Mia, and Paul Kubes. “The Healing Power of Neutrophils.” *Trends in immunology* vol. 40,7 (2019) : 635-647. doi :10.1016/j.it.2019.05.001.
- [7] Devalaraja, R M et al. “Delayed wound healing in CXCR2 knockout mice.” *The Journal of investigative dermatology* vol. 115,2 (2000) : 234-44. doi :10.1046/j.1523-1747.2000.00034.x
- [8] Gutiérrez-Fernández, Ana et al. “Increased inflammation delays wound healing in mice deficient in collagenase-2 (MMP-8).” *FASEB journal : official publication of the Federation of American Societies for Experimental Biology* vol. 21,10 (2007) : 2580-91. doi :10.1096/fj.06-7860com



7 Annexes

Package	Version	Fonctionnalités
shiny	1.8.0	Créer des applications web interactives directement à partir de R.
DESeq2	1.34.0	Analyse d'expression différentielle des données RNA-Seq. Normalisation des données RNA-Seq.
org.Mm.eg.db	3.14.0	Annotations pour les gènes de la souris.
EnhancedVolcano	1.12.0	Crée des volcans pour visualiser les résultats d'expression différentielle.
ggplot2	3.4.4	Visualisation de données basé sur la grammaire des graphiques.
ComplexHeatmap	2.10.0	Crée des heatmaps complexes avec des annotations.
circize	0.4.15	Utilisé pour la visualisation de données circulaires.
readr	2.1.4	Pour lire des données rectangulaires (rapides et conviviales).
tximport	1.22.0	Importation de données de quantification de transcriptome.
AnnotationDbi	1.56.2	Fournit des outils pour la gestion des bases de données d'annotations.
clusterProfiler	4.2.2	Outils pour l'analyse statistique et la visualisation de profils fonctionnels.
msigdb	7.5.1	Fournit des collections de gènes pour l'analyse d'enrichissement.
ExperimentHub	2.2.1	Accès à des ressources de données expérimentales.
msigdb	1.2.0	Fournit des collections de gènes pour l'analyse d'enrichissement.
GSEABase	1.56.0	Fournit des classes et des méthodes pour l'analyse d'enrichissement de gènes.
stats	4.1.0	Fournit des fonctions statistiques de base.
factoextra	1.0.7	Extraction et la visualisation des résultats d'analyses multivariées.
ggrepel	0.9.3	Pour créer des étiquettes de texte qui ne se chevauchent pas dans ggplot2.
annotables	0.1.91	Fournit des tables d'annotations pour les gènes.
dplyr	1.1.4	Outils pour la manipulation de données.
patchwork	1.1.3	Combine plusieurs graphiques ggplot2 en un seul.
GSVA	1.42.0	Outils pour l'analyse de variation de l'ensemble de gènes.
plyr	1.8.9	Pour le fractionnement, l'application et la combinaison de données.
magrittr	2.0.3	Fournit des opérateurs pour rendre le code R plus lisible.
DT	0.31	Permet de créer des tables interactives.
fgsea	1.20.0	Fournit des outils pour l'analyse d'enrichissement de gènes.
shinyWidgets	0.8.6	Fournit des widgets supplémentaires pour les applications Shiny.

TABLE 1 – Logiciel R version 4.1.0 (2021-05-18), les packages utilisés et leurs fonctionnalités