

RÉPUBLIQUE DU SÉNÉGAL



Un Peuple-Un But-Une Foi

Ministère de l'Enseignement Supérieure de la Recherche et de l'Innovation



UNIVERSITÉ CHEIKH ANTA DIOP DE DAKAR

FACULTÉ DES SCIENCES ET TECHNIQUES

DÉPARTEMENT DE MATHÉMATIQUES ET INFORMATIQUE

Section Informatique

MÉMOIRE DE MASTER BIO-INFORMATIQUE

**Variations Génétiques et Histoire Évolutive
du gène Pol du VIH-1 au Sénégal**

Présenté et soutenu par :

Albert NDOUR

Encadré par :

**Dr Mame Ndew MBAYE
Dr Seydina Issa DIOP**

Année Académique 2021-2022

Dédicaces :

Je dédie ce travail à :

Tous les membres de ma famille, Je vous dois toute réussite sur ce bas monde, vous m'avez légué plus de valeurs que de biens matériels. Naître dans une famille est un don, vous en êtes la preuve. Soyez richement bénis.

A tous mes amis et connaissances ! en particulier ceux qui sont partis à la fleur de l'âge : Léopold Gana FAYE et Alassane SOW, je m'incline devant leurs mémoires et implore la miséricorde de Dieu pour le repos de leurs âmes.

Remerciements :

Comment rendrai-je au Seigneur tout le bien qu'il m'a fait ?

J'élèverai la coupe du salut, j'invoquerai le nom du Seigneur.

Je t'offrirai le sacrifice d'action de grâce, j'invoquerai le nom du Seigneur.

Je tiendrai mes promesses au Seigneur, oui, devant tout son peuple.

Ps 115, 12-13, 17-18.

Je tiens à remercier chaleureusement :

Toute l'équipe de DEFAR-SCI, particulièrement à Monsieur Seydina Issa DIOP qui a accepté d'encadrer mon mémoire et qui a mis à ma disposition toutes ses compétences, son expérience et ses services pour l'aboutissement de cette présente étude. Je lui dois beaucoup pour toutes les connaissances qu'il m'a apportées et pour sa grande rigueur scientifique dont je tire profit, Monsieur DIOP Issa restera pour moi le modèle du bon chercheur. Merci encore M. DIOP !

Madame Mame Ndew Mbaye MBOUP et Madame Mame Salane Thiam BASSE, mes co-encadrantes, pour m'avoir encouragé et soutenu pour le bon déroulement de ce travail, Monsieur Pape Adama MBOUP, pour son soutien sans faille.

Tout le corps professoral qui a participé à ma formation depuis le scolaire jusqu'à l'université.

Je remercie enfin les membres du jury pour avoir bien voulu évaluer ce travail.

Résumé :

Objectif :

Évaluer le potentiel génétique du gène Pol et son dynamisme moléculaire pour établir son profil génétique et mieux comprendre son histoire évolutive

Concevoir :

La parenté des virus dans une grande base de données (**Los Alamos**) de séquences **pol** générées à partir d'individus infectés par le VIH-1 au Sénégal a été reconstruite par des analyses phylogénétiques.

Méthode :

Dans le cadre de notre étude, les séquences nucléiques et les données associées ont été recueillies à partir de la base de données publique **LosAlamos**. Cette collecte cible les échantillons de séquences du VIH-1 (complètes et/ou partielles) d'origine géographique Sénégalaise. La région génomique d'intérêt est **pol [2253-3554]** relativement à la séquence de référence (**HXB2**), la taille minimale des séquences à collecter est fixée à 500 nucléotides. L'ensemble des séquences a été filtré aux fins d'éliminer celles qui sont redondantes, les séquences provenant de la même source individuelle (identité de séquence à 100% synonyme de doublons) ont été identifiées et la séquence la plus ancienne sera considérée dans l'échantillon final. L'alignement de séquence a été effectué par **MUSCLE** et le Nettoyement de cet alignement avec **Gblocks**. Des phylogénies basées sur le maximum de parcimonie et les distances génétiques ont ensuite été effectuées à partir de **MEGA11** puis par R afin de comparer les deux arbres générés avec ces deux méthodes et deux outils différents.

Résultats :

Sur les 971 séquences pol téléchargées à partir de la base de données Los Alamos, 2020. Un alignement de séquence et une inspection manuelle nous a permis de retenir 33 séquences du gène pol. Des topologies identiques ont été obtenues avec les différents arbres produits avec différentes méthodes et avec des valeurs bootstrap bien soutenues. Ceci renseigne sur les liens épidémiologiques entre les différents sous-types et leur relation évolutive. De plus, l'Analyse Phylogénétique du ratio $\frac{dN}{dS}$ a permis de détecter un certain nombre de mutations susceptibles d'être responsables de résistances antirétrovirales.

Mots Clés : VIH-1, gène Pol, Potentiel génétique, Histoire évolutive, LosAlamos, Sénégal, Analyse phylogénétique du Ratio, taux de mutation synonyme, taux de mutation non-synonyme, HXB2

Abstract :

Objective:

To assess the genetic potential of the Pol gene and its molecular dynamism in order to establish its genetic profile and better understand its evolutionary history

Design:

Virus relatedness in a large database (Los Alamos) of pol sequences generated from HIV-1 infected individuals in Senegal was reconstructed by phylogenetic analyses.

Method :

In our study, nucleic acid sequences and associated data were collected from the LosAlamos public database. This collection targets HIV-1 sequence samples (complete and/or partial) of Senegalese geographical origin. The genomic region of interest is pol [2253-3554] relative to the reference sequence (HXB2), the minimum size of the sequences to be collected is set at 500 nucleotides. All sequences were filtered to eliminate redundant sequences, sequences from the same individual source (100% sequence identity synonymous with duplicates) were identified and the oldest sequence will be considered in the final sample. Sequence alignment was performed by MUSCLE and the alignment was cleaned up with Gblocks. Phylogenies based on maximum parsimony and genetic distances were then performed using MEGA11 and then R to compare the two trees generated with these two methods and two different tools.

Results :

Of the 971 pol sequences downloaded from the Los Alamos, 2020 database. A sequence alignment and manual inspection allowed us to retain 33 pol gene sequences. Identical topologies were obtained with the different trees produced with different methods and with well supported bootstrap values. This provides information on the epidemiological links between the different subtypes and their evolutionary relationship. In addition, the Phylogenetic Analysis of the $\frac{dN}{dS}$ ratio allowed the detection of a number of mutations that could be responsible for antiretroviral resistance.

Keywords : HIV-1, Pol gene, Genetic potential, Evolutionary history, LosAlamos, Senegal, Phylogenetic analysis of the ratio, synonymous mutation rate, non-synonymous mutation rate, HXB2

Liste des Figures :

Figure 1 : Schéma organisationnel du VIH

Figure 2 : Carte Génétique du VIH-1

Figure 2 : Les quatre groupes du VIH-1

Figure 4 : Subdivision du VIH-1

Figure 5 : Répartition géographique en Afrique du VIH-1 selon la région génomique d'intérêt de notre étude [2253-3554].

Figure 6 : Diagrammes de répartition des formes recombinantes et des sous-types de la région génomique d'intérêt [2253-3554] de la souche de référence HXB2 du VIH-1 prises isolément.

Figure 7 : Diagramme de répartition de l'ensembles du jeu de données de la région génomique d'intérêt [2253-3554] selon le génome de référence HXB2 du VIH-1.

Figure 8 : Arbre phylogénétique du gène pol du VIH-1 au Sénégal.

Figure 9 : Analyse de parcimonie maximale des séquences du gène Pol du VIH-1 d'origine sénégalaise.

Figure 10 : Phylogénie du ratio $\frac{dN}{dS}$ de chacune des branches, construite à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise.

Figure 11 : Arbre du taux de mutation dS (taux de mutation synonyme) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise.

Figure 12 : Arbre du taux de mutation dN (taux de mutaion non synonyme) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise

Figure 13 : Arbre phylogénétique de l'ensemble des séquences du jeu de données (903 séquences)

Figure 14 : Arbre phylogénétique de l'ensemble des séquences du jeu de données (903 séquences) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise

Table des Matières

<i>Dédicaces :</i>	2
<i>Remerciements :</i>	2
Résumé :	3
Abstract :	4
Liste des Figures :	5
I INTRODUCTION	8
1. Contexte de l'étude	9
2. Structure et constitution du VIH-1	10
3. Diversité génétique du VIH-1	12
3.1 Le groupe M du VIH-1	12
3.1.1 Sous-types et sous-sous-types du groupe M	12
3.1.2 Recombinants du groupe M et formes recombinantes circulantes	13
3.2 Les Groupes N, O, et P du VIH-1	14
3.3 Diversité, et estimation de l'histoire du gène pol VIH-1	15
4. Répartition géographique.....	15
5. La Phylogénie moléculaire	16
5.1 L'horloge moléculaire	17
5.1.1 Définition	17
5.1.2 Mutation/substitution, polymorphisme/divergence	17
5.1.3 La théorie neutraliste de l'évolution	18
(L'équilibre mutation/dérive)	18
5.2 Représentation d'une phylogénie moléculaire	20
5.3 Vocabulaire de la phylogénie moléculaire ^[7]	20
5.4 Les types d'arbres phylogénétiques	22
❖ Cladogramme.....	22
❖ Phylogramme	22
❖ Chronogramme	23
5.5 Méthodes de construction des arbres phylogénétiques ^[9]	23
5.6 Estimation de la robustesse des arbres Bootstrap	24
5.6.1 Interprétation du Bootstrap.....	24
III. MATÉRIELS ET MÉTHODES	24
1. Logiciels et Outils Bio-informatiques.....	24

2. Échantillonnage et Collecte de données	25
3. Confirmation des sous-types	26
4. Présentation du jeu de données	26
5. Reconstruction Phylogénétique	27
5.1 Création de dataset	27
5.2 Analyses basées sur la distance avec le logiciel R.....	28
5.3 Analyses basées sur le maximum de vraisemblance avec le logiciel R.....	29
6. Analyse phylogénétique du ratio dN/dS ^[10]	29
6.1. Calcul du ratio dN/dS par codeml	30
6.2 Détection de codons sous pression de sélection par codeml	31
IV. RÉSULTATS.....	31
1. Evolution du gène pol	31
2. Résultats de l'Analyse Phylogénétique du ratio dN/dS	34
3. Résultat de la détection de codons sous pression de sélection	37
4. Relation évolutive du gène pol au Sénégal.....	39
Références	45
Webographie.....	46
Annexes	46

I INTRODUCTION

Depuis son identification dans les pays développés au début des années 1980, le syndrome de l'immunodéficience acquise (SIDA) a entraîné un total de 11,7 millions de décès, dont 4,0 millions de femmes et 2,7 millions d'enfants. Selon l'Organisation mondiale de la santé, 5,8 millions de personnes ont été infectées par le virus de l'immunodéficience humaine (VIH) rien qu'en 1997, et 30,6 millions de personnes vivent actuellement avec l'infection par le VIH. Le VIH a été identifié comme l'agent causal du SIDA en 1983.^[1]

Le nombre de personnes nouvellement infectées par le VIH chaque année a diminué de 40% depuis 1998. Près de 3 millions de personnes avaient contracté le virus en 1998. En 2018, le nombre de nouvelles infections s'élevait à 1,7 million, ce qui correspond à environ 5 000 cas par jour. L'Afrique subsaharienne est la région la plus touchée, avec environ 25 millions d'individus, soit 71% des personnes vivant avec le VIH/SIDA dans le monde.

Le nombre de personnes vivant avec le VIH dans le monde est passé de 7,9 millions en 1990 à 37,9 millions aujourd'hui. Cependant, grâce à l'augmentation de la couverture du traitement du VIH, le nombre de décès est passé de 1,7 million par an en 2005 à 770 000 en 2018. Environ 23 millions de personnes (soit 61 % des personnes vivant avec le VIH) ont eu accès au traitement du VIH en 2018.^[2]

Les femmes sont les plus vulnérables à l'infection au VIH, et le groupe le plus touché sont les travailleuses du sexe (TS) avec une prévalence de 34,9%. Vient ensuite les hommes ayant des relations avec des hommes (HSH) avec une prévalence de 17,7%, puis les clients des TS (7,3%), enfin les usagers de drogues injectables 3%.

Dès lors Virus de l'Immunodéficience Humaine (VIH) constitue l'épicentre des problématiques majeures de la recherche académique en épidémiologie. Le virus est très vite devenu endémique dans plusieurs régions du monde du fait du déficit de prévention.

L'histoire évolutive du VIH ainsi que sa diversité génétique continuent avec son lot de questionnements bénéficiant d'énormes efforts du monde de la recherche académique.

Au moment où l'ère de la pression sélective des médicaments antirétroviraux (ARV) présente des enjeux dans le domaine sanitaire et économique, nous nous sommes intéressés à évaluer la diversité génétique du gène **pol** du VIH-1 au Sénégal.

L'objectif général de notre étude a été de pouvoir établir la relation génétique entre les différentes souches d'origine sénégalaise. De plus, nous avons calculé la pression de sélection naturelle sur les différentes séquences du gène pol analysés.

Ainsi nous avons pu évaluer le potentiel génétique du gène pol et son dynamisme moléculaire pour établir son profil génétique et mieux comprendre son histoire évolutive.

Notre étude a été effectuée en deux étapes : Sur la première partie, nous avons établi les distances évolutives du gène **pol** du VIH-1 en construisant une phylogénie moléculaire et une seconde partie qui étudie la diversité des mutations responsables des résistances aux antirétroviraux par une méthode d'analyse phylogénétique du ratio $\frac{dN}{dS}$.

1. Contexte de l'étude

Une des caractéristiques du VIH-1 est sa vaste diversité génétique qui émane principalement de multiples facteurs tels que le taux de réplication virale rapide, le taux de mutation élevé, les événements de recombinaison au cours de la réplication, les cas de doubles et/ou multiples infections, la pression immunitaire sélective chez l'hôte et la pression médicamenteuse. Il est également établi que cette diversité génétique a de multiples implications sur plusieurs aspects tels que le diagnostic, la surveillance virologique, et le développement de vaccins.

La région génétique du VIH-1 la plus appropriée pour l'analyse phylogénétique est une question cruciale et fait encore l'objet de débats. Cependant, comme il existe relativement peu de séquences complètes disponibles et d'analyses phylogénétiques limités par le coût du séquençage, le matériel de base approprié et par la puissance de calcul, la longueur de la séquence et la région génétique de choix doivent être soigneusement examinées ensemble afin de garantir un signal phylogénétique fort. Ainsi, la région couvrant les gènes de la protéase et de la Reverse Transcriptase est régulièrement séquencée dans le contexte clinique des tests génotypiques de résistance aux médicaments.

Au regard de ce qui précède, nous portons notre étude sur la région génomique d'intérêt allant de **2253 à 3554 sur le génome HXB2**

2. Structure et constitution du VIH-1

La structure du VIH comporte ^[3] :

- Une **enveloppe virale** constituée d'une double bicouche lipidique et de deux sortes de glycoprotéines : gp120 et gp41. La molécule gp41 traverse la bicouche lipidique tandis que la molécule gp120 occupe une position plus périphérique : elle joue le rôle de récepteur viral de la molécule membranaire CD4 des cellules hôte. L'enveloppe virale dérive de la cellule hôte : il en résulte qu'elle contient quelques protéines membranaires de cette dernière, y compris des molécules du complexe majeur d'histocompatibilité.
- Un **core viral** ou **nucléocapside**, qui inclut une couche de protéine p17 et une couche plus profonde de protéines p24.
- Un **génome** constitué de deux copies d'ARN simple brin associées à deux molécules de transcriptase inverse (p64) et à d'autres protéines enzymatiques (protéase p10 et intégrase p32)




Figure 1 : Schéma organisationnel du VIH ^[3]

Quand on s'intéresse à la structure génomique du **VIH-1** et particulièrement sur les gènes et les produits génétiques on retrouve trois gènes essentiels sur la région codante de ce rétrovirus ^[3] :

- Le gène **GAG** est la région génomique codant pour les protéines de capsid (antigènes spécifiques de groupe). Le précurseur est la protéine myristoylée p55, qui est

transformée en protéines p17 (MAtrix), p24 (Capsid), p7 (NucleoCapsid) et p6, par la protéase virale. Gag s'associe à la membrane plasmique, où l'assemblage du virus a lieu. Le précurseur Gag de 55 kDa joue un rôle dans l'assemblage viral.

- Le gène **POL** de la région génomique codant pour les enzymes virales protéase, transcriptase inverse et intégrase. Ces enzymes sont produites sous la forme d'une polyprotéine précurseur Gag-Pol, qui est traitée par la protéase virale ; le précurseur Gag-Pol est produit par décalage de cadre ribosomique près de l'extrémité 3' de gag.
- Le gène **ENV** est la région génomique codant pour les Glycoprotéines virales produites comme précurseur (gp160), qui est traité pour donner un complexe non covalent de la glycoprotéine externe gp120 et de la glycoprotéine transmembranaire gp41. Les protéines gp120-gp41 matures sont liées par des interactions non covalentes et sont associées sous forme de trimère à la surface cellulaire. Une quantité substantielle de gp120 peut être trouvée libérée dans le milieu. gp120 contient le site de liaison du récepteur CD4 et les sept récepteurs de chimiokines à domaine transmembranaire qui servent de corécepteurs pour le VIH-1.





Figure 2 : Carte Génétique du VIH-1 [3]

Ces gènes font l'objet de beaucoup de mutations et ces mutations entraînent la naissance de types et de sous-types aux côtés desquels coexistent des formes recombinantes originaires de la recombinaison entre deux virus coinfectant un même individu.

3. Diversité génétique du VIH-1

Les efforts pour contrôler l'épidémie due au VIH-1 se sont fortement concentrés sur les études de la biologie, de la biochimie et de la biologie structurale du virus et sur les interactions entre les antirétroviraux (ARV) et les nouveaux médicaments candidats. Bien que ces médicaments retardent la progression de la maladie, ils ne l'empêchent pas, car l'infection conduit facilement à des mutants résistants aux médicaments. Ce qui diversifie davantage la génétique du VIH-1. Cette diversité génétique du VIH-1, en particulier en Afrique, est également un facteur potentiellement important favorisant la résistance naturelle ou l'émergence des résistances à certains ARV.



Ainsi on distingue quatre types de catégories actuellement utilisées pour désigner les principales lignées du VIH-1 : groupes (types), sous-types, sous-sous-types et les formes recombinantes. D'un point de vue phylogénétique, les groupes actuellement définis sont au nombre de quatre : M, N, O, P.

Figure 3 : Les quatre groupes du VIH-1

3.1 Le groupe M du VIH-1

Le groupe M du VIH-1, qui prédomine dans l'épidémie mondiale de VIH/SIDA, peut être subdivisé en sous-types, en sous-sous-types et en formes recombinantes (uniques et circulantes).

3.1.1 Sous-types et sous-sous-types du groupe M

On pense que les sous-types et les sous-sous-types du groupe M ont divergé chez l'homme à la suite d'une seule transmission chimpanzé-humain. Les sous-types du groupe M du VIH-1 sont

des groupes ou des clades de séquences du VIH-1 associés phylogénétiquement et sont étiquetés en sous-type (A–D, F–H, J, K) et sous-sous-types (A1 à A4, F1 et F2). Les séquences au sein de n'importe quel sous-type ou sous-sous-type sont plus similaires les unes aux autres qu'aux séquences d'autres sous-types dans l'ensemble de leurs génomes. Ces sous-types représentent différentes lignées de VIH et ont certaines associations géographiques. Étant donné que les sous-types ont été définis à l'origine uniquement sur la base de fragments du génome du VIH-1, dans certains cas, aucune séquence prototype intacte n'était disponible (les anciens sous-types E et I, par exemple, qui sont tous deux désormais définis comme des formes recombinantes circulantes). De plus, les virus au sein d'un sous-type peuvent évoluer à des vitesses différentes, et il peut également y avoir des différences de vitesse entre différents sous-types, en particulier dans certaines régions limitées du génome.




Figure 4 : Subdivision du VIH-1

3.1.2 Recombinants du groupe M et formes recombinantes circulantes

Tous les rétrovirus ont une propension à se recombiner avec d'autres rétrovirus relativement proches, et les VIH ne font pas exception. Le génome viral est conditionné en deux copies d'ARN ss et si une cellule donnée est infectée par deux génomes viraux différents (provenant de la même souche ou de souches différentes), il y a de fortes chances que certains virions

s'emballent une copie de chacun de ces deux virus. Si les deux souches appartiennent à des sous-types différents du groupe VIH-1 M, le résultat peut être un génome mosaïque composé de régions de chacun des deux sous-types, du fait que la reverse transcriptase virale s'engage dans un changement de modèle ou sautant d'un génome empaqueté à l'autre, pendant la transcription inverse, après que les génomes co-emballés entrent dans une nouvelle cellule.

Les génomes recombinants inter-sous-types sont courants, mais nombre d'entre eux ne se trouvent que chez le patient individuel doublement infecté (ou infecté de manière multiple) chez lequel ils sont apparus. Un tel recombinant est appelé une forme recombinante unique (URF). Si un virus recombinant inter-sous-type est transmis à de nombreuses personnes, il devient l'une des souches circulantes dans l'épidémie de VIH, et il peut être classé comme une « forme recombinante circulante (CRF) ». Les CRF représentent des génomes recombinant du VIH-1 qui ont infecté trois personnes ou plus qui ne sont pas épidémiologiquement apparentées, de sorte qu'on peut supposer qu'ils ont une contribution épidémiologiquement pertinente à l'épidémie du groupe M du VIH-1. Les formes recombinantes circulantes sont étiquetées avec des chiffres plutôt qu'avec des lettres, et numérotées dans l'ordre dans lequel elles ont d'abord été décrites de manière adéquate. Il existe à ce jour des formes recombinantes (CRF01 à CRF51) et de nombreuses formes recombinantes uniques (URF). ^[3]

3.2 Les Groupes N, O, et P du VIH-1

Les groupes M, N, O et P du VIH-1, ainsi que les virus d'immunodéficience simienne (SIV) des chimpanzés et des gorilles, font tous partie de la famille SIVcpz au sein des lentivirus des primates. Rappelons que le SIVcpz est le résultat de transmissions inter-espèces et de recombinaisons de deux virus : le SIVrcm et le SIVmus/mon/gsn. ^[4]

Le groupe N est une forme très particulière du virus qui n'a été identifiée que chez quelques individus au Cameroun. N est parfois appelé **Not-M**, **Not-O**, parfois aussi le "nouveau" groupe, et on pense également qu'il provient d'une transmission de chimpanzé. Les sous-types au sein du groupe N ne sont pas encore clairement définis. Très peu d'isolats ont été identifiés et séquencés.

Le groupe O, parfois appelé groupe « aberrant », comme le groupe M contient des virus très divers, mais est encore relativement rarement trouvé. On pense qu'il provient d'une transmission à l'homme par le gorille sauvage. La diversification intra-groupe commence une

fois que le virus transmis commence à se développer dans la population humaine après chaque événement de transfert interspécifique. Les sous-types au sein du groupe **O** ne sont pas encore définis, bien que la diversité des séquences au sein du groupe **O** soit presque aussi grande que la diversité des séquences dans le groupe **M**.

3.3 Diversité, et estimation de l'histoire du gène pol VIH-1

Une des caractéristiques majeures du VIH-1 est sa vaste diversité génétique qui émane principalement de fortes mutations. Cette diversité génétique résulte d'un taux élevé de la réplication couplée à une faible fidélité de la transcriptase inverse mais aussi aux phénomènes de recombinaison qui s'interfèrent en présence de deux virus. Les impacts sur le diagnostic sérologique, et la charge virale jouent aussi un rôle véritable sur cette diversité et notamment sur la réponse au traitement antirétroviral.

En effet, la région du génome du VIH-1 la plus touchée par les mutations est le gène pol, particulièrement la région couvrant la **Protéase** et la **Transcriptase inverse (nucléotides 2253 à 3554 des coordonnées HXB2)**. Dans cette région, on répertorie le maximum de mutations responsable de résistance aux ARV. Cela se justifie par le fait que parmi les antirétroviraux qui sont utilisés pour le traitement des patients, les majeures parties sont dirigés contre la Transcriptase Inverse (RT) et la Protéase. En revanche, cette région couvrant les gènes de la protéase et de la RT est régulièrement séquencée dans le contexte clinique des tests génotypiques de résistance aux médicaments et un grand nombre de données est en cours d'être généré. Cette région génétique du VIH-1 est plus appropriée pour l'analyse phylogénétique car elle garantit un signal phylogénétique fort.

4. Répartition géographique

Comme toute épidémie, l'infection à VIH a non seulement une histoire du point de vue de son évolution temporelle, mais aussi de sa géographie selon son inscription spatiale et ses itinéraires de propagation. L'approche géographique s'applique en premier lieu à apprécier dans les échelles d'observation l'impact de l'infection, à identifier des territoires infectés ou épargnés, à reconnaître les discontinuités spatiales de prévalence et d'incidence. Ainsi le VIH de type 1 et de type 2 sont répandus en Afrique subsaharienne en raison des contextes géographiques distincts. Le VIH-2 est principalement documenté en Afrique de l'Ouest et

centrale, mais l'infection par le VIH-1 est largement répandue à travers le continent. Du point de vue sous-typique, le sous-types **C** est largement dominant dans le continent Africain.




Figure 5 : Répartition géographique en Afrique du VIH-1 selon la région génomique d'intérêt de notre étude [2253-3554]. (Voir carte de l'Afrique en annexe)

On peut voir que le sous-type C prédomine largement le continent africain avec une représentativité de 51% selon la région génomique d'intérêt [2253-3554], s'en suit la forme recombinante circulante CRF02_AG avec une représentativité de 10.8%. Cette dernière prédomine largement au Sénégal avec une représentativité de 54%.

5. La Phylogénie moléculaire

Les progrès du séquençage ont amené un flot de données qui se prêtent particulièrement bien à l'analyse phylogénétique. La phylogénie moléculaire a pour but de reconstruire les relations de parenté entre des séquences de nucléotides ou d'acides aminés. L'utilisation simultanée de nombreux gènes, permettant d'obtenir plusieurs milliers de positions homologues, a permis de résoudre plusieurs questions débattues de longue date.

Pour construire une telle phylogénie, il va donc falloir tenter de reconstruire l'histoire de ces séquences, avec, comme seule source d'information disponible, les séquences elles-mêmes. Une histoire du gène par le gène, en quelque sorte. Cependant, les objets analysés doivent être

suffisamment similaires pour être comparés. Si c'est le cas, on dit de ces caractères qu'ils sont homologues c'est-à-dire qu'on formule l'hypothèse selon laquelle la similitude observée est due au fait que les caractères sont issus d'un ancêtre commun et qu'ils se sont progressivement modifiés au fil des générations. Pour les séquences de protéines ou d'ADN, cette étape de comparaison est celle de l'alignement. Les Programmes d'alignement automatique sont très efficaces pour les régions de forte similitude (plus de 50 % des positions de l'alignement portent des nucléotides ou d'acides aminés identiques) mais ne le sont pas pour les séquences plus divergentes.^[7]

5.1 L'horloge moléculaire

5.1.1 Définition

Pour pouvoir reconstruire l'histoire des séquences avec les séquences elles-mêmes, il faut qu'il y ait un lien entre l'accumulation des différences entre ces séquences et l'écoulement du temps. Cette relation, c'est l'horloge moléculaire, conséquence de l'équilibre mutation/dérive décrit par la théorie neutraliste de l'évolution.^[8]

5.1.2 Mutation/substitution, polymorphisme/divergence

Avant de se lancer dans l'explication de ce lien entre temps et accumulation de différences entre séquence, il convient de mettre un nouveau point de vocabulaire.

Le phénomène évolutif faisant que la séquence d'un gène change est la mutation. A la base, la mutation est un phénomène aléatoire, indépendant de l'environnement ou des besoins de l'organisme. La mutation, c'est une erreur de réplication du matériel génétique, ou une modification chimique de ce matériel, due à l'exposition à des rayonnements ou à des agents chimiques dits mutagènes. Cet événement de mutation, qui change chez un individu un acide nucléique par un autre, crée donc un nouveau variant de la séquence, un nouvel allèle. Après l'événement de mutation, dans la population où elle a eu lieu, on passe donc d'un état monomorphe avec un seul allèle présent, à une situation polymorphe, avec deux allèles présents dans cette même population. La mutation crée donc le polymorphisme.

On va le voir par la suite, les fréquences de ces allèles vont varier au cours du temps, sous l'effet de la dérive génétique. Ce qui veut dire qu'éventuellement, le nouveau variant apparu par mutation peut passer de rare à l'origine à très fréquent par la suite. Il peut même envahir la population, c'est-à-dire devenir le seul allèle présent dans cette population. On dit alors que

l'allèle se fixe (sa fréquence ne varie plus), ce qui correspond donc à une perte du polymorphisme. En ce cas, on observe un remplacement de l'allèle ancestral par le nouvel allèle muté, c'est ce que l'on nomme un événement de substitution. Avec le temps, on est donc passé d'une population monomorphe pour l'allèle ancestral à une population monomorphe pour l'allèle muté. Il y a donc une différence nette de la séquence présente dans ces deux populations, la population ancestrale et la population récente. On ne parle plus alors de polymorphisme (allèles différents présents dans la même population), mais de divergence entre population. ^[8]

5.1.3 La théorie neutraliste de l'évolution

(L'équilibre mutation/dérive)

Ici nous essayerons de voir par quel mécanisme les fréquences des allèles varient de génération en génération. Considérons une population de N individus diploïdes. Pour une séquence quelconque, il existe donc $2N$ copies de cette séquence dans cette population. Par définition, l'apparition d'un allèle muté est un événement rare et unique. A l'origine, donc, l'allèle muté est présent en une copie unique, et sa fréquence sera donc de $1/2N$ à son apparition.

La sélection naturelle peut faire changer cette fréquence allélique au cours des générations à venir.

Si l'allèle muté est avantageux (son porteur laisse en moyenne plus de descendants à chaque génération que les non porteurs) il augmentera forcément en fréquence et arrivera à terme à fixation (sa fréquence sera égale à 1), au détriment de l'allèle ancestral, qui lui disparaîtra.

Si, par contre, cet allèle est désavantageux (synonyme : délétère) (son porteur laisse moins de descendants que les non porteurs), il sera porté par de moins en moins d'individus à chaque génération, et disparaîtra (sa fréquence chutera à 0). Le nombre de générations avant ces événements de fixation de l'un ou l'autre allèle variera selon la valeur de l'avantage (ou du désavantage) reproductif conféré par la mutation. Plus l'allèle est avantageux, plus il envahira rapidement la population.

Si l'allèle muté n'a aucune influence sur le nombre de descendants produits par son porteur (s'il ne change pas la valeur sélective) on dit alors que cet allèle muté est neutre vis-à-vis de la sélection. Et bien sa fréquence variera tout de même de génération en génération, mais plus de manière déterminée par la sélection.

Soit donc un locus avec deux allèles, **A** et **a**. **A** a un effet sur la fitness (ou avantage sélectif, soit le nombre de descendants produits) de son porteur de la forme **S** (coefficient de sélection), tandis que **a** est neutre (effet sur la fitness de 0).

Sous ces conditions, la probabilité de fixation de **A** est égale à :

P(fixation de A) = $\frac{2s}{1-e^{-4Ns}}$ Pour un coefficient de sélection **S** de l'ordre de $\frac{1}{N}$ (c'est-à-dire un relativement faible avantage sélectif).

Si **s > 0** , **A** est un allèle favorable, si **s < 0**, **A** est un allèle défavorable et si **s = 0**, **A** est neutre.

Dans ce dernier cas (**s = 0**), P (fixation de **A**) tend vers $\frac{2s}{1-e^{-4Ns}}$, soit la valeur de la fréquence de l'allèle à l'origine, à son apparition.

Cette probabilité de fixation d'un allèle neutre va nous permettre de calculer la vitesse d'évolution d'une séquence, c'est-à-dire le nombre de substitutions par unité de temps.

Soit **μ** le taux de mutation qui donne la probabilité d'apparition d'un nouveau mutant par unité de temps dans une séquence. Parmi tous les allèles qui apparaissent, une fraction **f0** est neutre, et, pour simplifier les calculs, la fraction complémentaire **1 – f0** est considérée comme létale. A partir de là, on peut calculer le taux d'évolution **λ0** de cette séquence, soit le nombre de substitutions qu'elle subit par unités de temps :

λ0 = Nombre de mutations neutres apparues par unité de temps x probabilité de fixation d'une mutation neutre.

Le premier terme du produit est obtenu en multipliant le nombre total d'allèles dans la population, **2N**, par la probabilité que l'un d'entre eux subisse une mutation neutre, **f0. μ**. Le

second terme du produit est, on l'a vu, $\frac{1}{2N}$.

$$\lambda_0 = f_0 \cdot \mu$$

On obtient donc que le taux de substitution neutre que subit une séquence est une constante, qui ne dépend pas de la taille de la population concernée, mais uniquement du taux de mutation et de la fraction de mutations neutres sur cette séquence. Autrement dit, toute séquence neutre évolue linéairement au cours du temps, le nombre de substitutions neutres qu'a subi une séquence dépend du temps écoulé. C'est cela ce que l'on appelle l'horloge moléculaire. ^[7]

5.2 Représentation d'une phylogénie moléculaire

Les phylogénies moléculaires sont représentées sous forme d'arbres phylogénétiques. Ces arbres sont a priori formés de successions de dichotomies et ou de polytomies, de successions de séparations d'une séquence ancestrale en séquences filles. Ces séparations sont dues soit à des spéciations (séparation de l'espèce ancestrale qui porte la séquence en deux espèces filles, portant chacune une version de cette séquence qui va évoluer indépendamment), soit à des duplications géniques (une séquence ancestrale se duplique dans le génome, et donne naissance à deux versions de cette séquence, qui vont évoluer indépendamment).^[7]

5.3 Vocabulaire de la phylogénie moléculaire^[7]

Avant de nous pencher sur ce qui sera le cœur de ce rapport, il est nécessaire d'introduire quelques notions que nous aurons à utiliser pour la suite.

Une phylogénie, c'est une classification basée sur l'apparentement. La classification consiste à avoir des ancêtres communs.

Il va donc falloir, à partir de la séquence elle-même, estimer le degré d'apparentement de cette séquence aux autres séquences que l'on veut classer. C'est l'interprétation de cette phylogénie, qui, dans un second temps, permettra de faire des hypothèses sur la classification des espèces qui portent ces séquences, ou sur les fonctions de ces séquences.

Les arbres phylogénétiques représentent les relations évolutives entre les objets étudiés (séquences, gènes, espèces...). Ce sont des graphes composés de nœuds et de **branches** :

- Les **nœuds** ou unités taxonomiques sont composés de feuilles
- Les **branches** représentent les relations de parentés (ancêtre /descendants) entre les unités taxonomiques sont composés de branches internes et de branches externes

L'ensemble des branchements de l'arbre est appelé **topologie de l'arbre**.

Il y a deux types d'arbres : des arbres racinés, et des arbres non racinés.

Un **arbre raciné**, c'est un arbre orienté dans le temps. En partant des séquences actuelles, celles que l'on connaît, qui permettent de construire l'arbre, et qui en constituent les feuilles, en remontant le temps, de dichotomie en dichotomie, on finit par aboutir à l'ancêtre commun à toutes ces séquences, la racine de l'arbre. Chaque événement dichotomique, qui marque la séparation d'une séquence ancestrale en deux séquences filles, est un nœud de l'arbre, le point de bifurcation des branches. Les nœuds et les feuilles de l'arbre sont donc reliés entre eux par des branches, dont la longueur peut quantifier la différenciation des séquences à chaque nœud.

Un arbre non raciné, très simplement, est constitué des mêmes éléments (feuilles, branches et nœuds), moins la racine. Un arbre non raciné n'est donc pas orienté dans le temps (on ne sait pas quel est le nœud le plus ancestral). Un tel arbre permet cependant de classer les séquences les unes par rapport aux autres (qui est le plus apparenté à qui ?).

Il existe aussi des **arbres résolus** qui sont constitués que de dichotomies (un ancêtre commun, deux descendants), il sera parfois impossible de reconstituer la succession des événements de séparation entre une partie des séquences étudiées, ce qui sera représenté par des polytomies et aboutira à un **arbre non résolu**.

Caractère dérivé partagé (ou synapomorphie) est un caractère hérité de l'ancêtre commun à toutes les espèces qui le présente. Il est informatif.

Homologie : En biologie de l'évolution, une homologie désigne un lien évolutif entre deux traits (en général anatomiques) observés chez deux espèces différentes, qui est dû au fait que toutes deux l'ont hérité d'un ancêtre commun.

Paralogie : En biologie de l'évolution, une paralogie est un lien évolutif entre deux gènes issus d'un événement de duplication.

Orthologie : En biologie de l'évolution, une orthologie est un lien évolutif entre deux gènes présents chez deux espèces différentes. Deux séquences génétiques homologues de deux espèces différentes sont orthologues si elles descendent d'une séquence unique présente dans le dernier ancêtre commun aux deux espèces.

Pour que deux gènes soient considérés comme paralogues, ils doivent être d'abord homologues, c'est-à-dire qu'ils descendent d'un même gène ancestral ; à la suite d'une duplication, les deux copies du gène divergent jusqu'à devenir deux gènes paralogues, dans une même espèce, ou dans deux espèces différentes (si la duplication est suivie par une spéciation). Si au contraire les gènes ont divergé après un phénomène de spéciation, ils sont dits orthologues.

Convergence évolutive ressemblance qui n'est pas dû à un héritage, mais à deux processus adaptatifs ayant mené au même état pour ce caractère.

Régression est une ressemblance due à une perte secondaire d'un caractère dérivé.

Par opposition aux **homologies**, **convergences** et **régressions** sont ce que l'on appelle des **homoplasies**, des ressemblances non héritées, fruit du hasard des mutations et de la sélection. Pour classer des séquences selon leur apparentement, il faudrait donc pouvoir différencier homologies et homoplasies, puisque seules les homologies sont dues à l'apparentement.

Modèles de substitution c'est un objet mathématique (d'algèbre linéaire), constitué d'une matrice de transition et d'un vecteur de composition.

Il existe de très nombreux modèles, il suffit d'introduire des valeurs de paramètres différents (par exemple, en considérant que la transition A vers G est moins probable que celle de C vers T). Une autre modification serait d'imposer une composition en nucléotides déséquilibrée. Pour illustrer cela, voici un des modèles les plus complexes utilisé couramment en Phylogénie moléculaire et que nous allons utiliser dans la suite du travail, le General Time Reversible modèle (GTR), qui inclut 6 probabilités de substitutions différentes et une composition déséquilibrée. Ce modèle n'est cependant toujours pas le plus complexe, puisque les substitutions restent réversibles avec la même probabilité (A peut être remplacé par G avec la même probabilité que G le soit par A).

La matrice de transition contient toutes les probabilités des substitutions que peut subir une position de la séquence par unité de temps. Pour une séquence nucléotidique, cette matrice sera de dimension 4x4 : chaque position peut contenir soit un A, un T, un C ou un G, et chacune de ces bases peut, par substitution, devenir un A, un T un C ou un G. Pour une séquence protéique, la matrice sera de dimension 20x20.

5.4 Les types d'arbres phylogénétiques

❖ Cladogramme

Est un type d'arbre, habituellement avec bifurcations, représentant un scénario évolutif des divergences entre espèces ou séquences.

Un Clade est une branche de cladogramme avec un ancêtre commun et tous ses descendants.

Une note est la longueur de la branche mais ne reflète pas le temps ou le taux de divergence.

Seule la topologie est informative, il n'y a pas d'échelle temporelle

❖ Phylogramme

Est un arbre montrant les relations phylogénétiques en termes d'histoire généalogique inférée ; l'identité des nœuds est spécifiée, la connexion des lignes représente le taxon ancestral, et les taxons inclus ne sont pas tous en position terminale.

Les longueurs des branches représentent les nombres d'événements évolutifs (exemple les mutations, ...). L'échelle relative est en bas et les longueurs des branches sont seulement des approximations des distances inférieures.

❖ Chronogramme

La longueur des branches représente le temps de divergence. L'hypothèse de l'horloge moléculaire suppose que le taux d'évolution ne varie pas entre les branches. Tous les objets sont alignés verticalement sur l'arbre. L'horloge moléculaire n'est pas toujours valide. Par exemple, les paralogues peuvent avoir des taux de mutation fort différents car ils ne sont pas soumis à la même pression de sélection.

5.5 Méthodes de construction des arbres phylogénétiques^[9]

Les différentes méthodes de reconstruction d'arbres utilisées en phylogénie moléculaire peuvent être regroupées en deux grandes familles de méthodes. Les méthodes dites phénétiques, basées sur l'utilisation des distances génétiques entre séquences, et les méthodes dites d'optimisation, qui n'utilisent pas ces distances.

- **Les méthodes phénétiques** ou à base de distance reposent sur le principe de la simplification des données à analyser en transformant l'alignement multiple des séquences en une matrice de distances 2 à 2 entre les séquences. C'est-à-dire une simplification où on remplace l'observation site à site des différences entre deux séquences par un simple chiffre, une distance qui est une estimation du nombre de substitutions réellement subies par les séquences. Cette simplification des données présente un défaut parce qu'elle impose la neutralité vis-à-vis de la sélection aux séquences analysées. En effet, ces méthodes supposent, au travers du calcul d'une distance génétique, que le taux de substitution a été constant entre toutes les séquences, que l'horloge moléculaire a été respectée, que ces séquences ont donc subi la même pression de sélection tout au long de leur évolution. C'est pour cette raison que cette méthode n'est pas appropriée pour notre étude. La méthode la plus connue aujourd'hui est le « neighbor joining » ou NJ publié dans les années 1970 par Saitou et Nei. L'arbre phylogénétique ne sera dès lors qu'une représentation graphique en deux dimensions de cette matrice de distances. L'avantage de ces méthodes est qu'elles sont toutes faciles à calculer, c'est-à-dire rapide à calculer, et qu'elles permettent d'obtenir un arbre unique à partir d'un alignement donné. Mais cette efficacité apparente a un coût.
- **Les Méthodes par optimisation ou statistiques** : Ici, l'arbre est plus qu'une représentation graphique d'une matrice de distance. C'est un objet à part entière dont la qualité doit être évaluée. Parmi tous les arbres possibles comptant un nombre de

feuilles égal au nombre de séquences dans l'alignement, il va falloir choisir le meilleur, c'est-à-dire celui qui va optimiser la valeur d'un paramètre de choix.

→ **En Maximum de Parcimonie (MP)**, le meilleur arbre est celui qui implique le plus petit nombre de substitutions.

→ **En Maximum de vraisemblance** (ML pour « maximum likelihood »), le meilleur sera celui qui, d'après un modèle de substitution, rendra votre alignement le plus probable.

→ **En méthode bayésienne**, enfin, le meilleur arbre sera celui qui sera le plus probable d'après votre alignement et un modèle de substitution.

Toutes ces méthodes ont deux points communs :

- 1) elles reposent sur une analyse site à site de l'ensemble des séquences alignées. Plus de simplification par un calcul de distance, il va falloir observer toutes les substitutions une à une, entre chaque paire de séquences,
- 2) comme il faut trouver le meilleur arbre parmi tous, cela suppose qu'il faille construire et explorer l'ensemble des arbres possibles.

5.6 Estimation de la robustesse des arbres Bootstrap

En phylogénie, un arbre est un estimateur des données dont on dispose :

- Estimer la variabilité de l'arbre (ou d'une partie de l'arbre = branches) en changeant les caractères ;
- Si un arbre est robuste c'est-à-dire fortement soutenu par les données alors sa variabilité sera faible ;
- Si un arbre est peu robuste alors il aura une grande variabilité.

5.6.1 Interprétation du Bootstrap

Une valeur de bootstrap de 100% un nœud vrai

Une valeur de bootstrap de 100% justifie la robustesse d'un nœud

Robustesse : Les données soutiennent fort le nœud

III. MATÉRIELS ET MÉTHODES

1. Logiciels et Outils Bio-informatiques

Dans le cadre de notre étude, nous avons utilisé un certain nombre d'outils bio-informatiques et principalement pour la génomique comparative.

D'abord nous avons travaillé concomitamment avec deux systèmes d'exploitation : Windows et Linux. Plusieurs raisons ont motivé ce choix, d'abord ces deux systèmes présentent une capacité d'exploitation différentes (par exemple il est très difficile voir incapable d'aligner les 901 séquences de notre jeu de données à partir de Windows [intel icore 7 8th génération, disque 900G]), et qu'en matière de bioinformatique, Linux présente des avantages non négligeables comparés à Windows. Nous avons utilisé deux langages de programmation (Python et R), mais aussi des outils bioinformatiques avec des interfaces graphiques comme **PAMLX**, **CodeML**, **SEAVIEW**, **MrBayes**, **MEGA11**, **Pal2nal**, **Clustalo**, **Figtree**, **CD-Hit**, **rega hiv-1 subtyping tool**. Le détail et la description des outils et des codes utilisés se trouvent en Annexes.

2. Échantillonnage et Collecte de données

Nos séquences nucléiques et les données associées ont été recueillies à partir de la base de données publique **LosAlamos**^[3], une base de données spécialisée dans la collecte, le stockage et l'étude du VIH 1 & 2. Cette collecte cible les échantillons de séquences du VIH-1 (complètes et/ou partielles) d'origine géographique Sénégalaise. La région génomique d'intérêt est **pol [2253-3554]** relativement à la séquence de référence (**HXB2**), la taille minimale des séquences à collecter est fixée à 500 nucléotides. L'ensemble des séquences a été filtré aux fins d'éliminer celles qui sont redondantes, les séquences provenant de la même source individuelle (identité de séquence à 100% synonyme de doublons) ont été identifiées et la séquence la plus ancienne sera considérée dans l'échantillon final. L'alignement de séquence a été effectué par **MUSCLE** et le Nettoyement de cet alignement avec **Gblocks**. Des phylogénies basées sur le maximum de parcimonie et les distances génétiques ont ensuite été effectuées à partir de **MEGA11** puis par R afin de comparer les deux arbres générés avec ces deux méthodes et deux outils différents. Pour comparer les arbres obtenus, nous avons réalisé plusieurs phylogénies à partir des méthodes qui présupposent le respect de l'horloge moléculaire ceux obtenus avec les autres méthodes (qui n'imposent pas l'horloge) pour identifier les séquences qui n'évoluent pas de manière neutre, de détecter les traces de sélection chez certaines des séquences. Enfin nous avons calculé le ratio $\frac{dN}{dS}$ (taux de mutation synonymes et non synonymes) en utilisant **codeml**, pour comprendre les différents profils mutationnels des séquences et comment elles ont évolué ainsi que les mutations de résistances associées.

3. Confirmation des sous-types

Les séquences avec lesquelles nous travaillons sont d'origine sénégalaise, elles ont été collectées dans les laboratoires et structures sanitaires du pays et soumises dans la base de données Los Alamos. Il est donc plus judicieux, avant de commencer à les manipuler, de valider leur classification. Cependant nous avons soumis l'ensemble de nos séquences à l'outil **REGA hiv-1 subtyping tool** [5].

Pour les séquences non confirmées, nous avons regroupé chacune d'elle avec les sous-types du groupe M de la sous-région pour réaliser une phylogénie et pouvoir ainsi confirmer leur appartenance.

4. Présentation du jeu de données

Notre jeu de données comporte 901 séquences datant de 1998 à 2018 réparties entre le groupe M(majoritairement) et le groupe O. La forme recombinante CRF02_AG prédomine de loin les données avec un pourcentage de 56,4% et représente 90,88% de formes circulantes, suivi du sous-type C avec un pourcentage de 13% et représente 4,75% des sous-types.




Figure 6 : Diagrammes de répartition des formes recombinantes et des sous-types de la région génomique d'intérêt [2253-3554] de la souche de référence HXB2 du VIH-1 prises isolément




Figure 7 : Diagramme de répartition de l'ensemble du jeu de données de la région génomique d'intérêt [2253-3554] selon le génome de référence HXB2 du VIH-1

5. Reconstruction Phylogénétique

Dans le premier cadre de notre étude nous avons établi des phylogénies pour reconstruire, par des analyses phylogénétiques, la parenté des groupes, sous-types et sous-sous-types au sein de la base de données los Alamos de séquences pol[2235-3554] générées à partir d'individus infectés par le VIH-1 au Sénégal.

5.1 Création de dataset

D'abord nous avons établi un premier mini jeu de données, à partir de l'ensemble de nos séquences téléchargées, en sélectionnant avec **CD-Hit** les séquences qui avaient un fort pourcentage d'identité (>90% et <100%) pour créer le dataset, suite à cette sélection nous avons obtenu 33 séquences nucléiques du VIH-1 de taille minimale 500 nucléotides. L'ensemble de ces séquences ont fait l'objet d'un alignement multiple avec le programme **MUSCLE**, puis ajustés manuellement à l'aide du logiciel d'édition **SEAVIEW**.

Sous **MEGA**, les relations phylogénétiques entre les séquences pol ont été estimées en utilisant successivement les méthodes des plus proches voisins (Neighbor Joining[NJ]) et Maximum de Parcimonie(MP). L'analyse bootstrap est maintenue à 1000 tours de réplcation pour la

méthode NJ. L'analyse du meilleur modèle pour la reconstruction d'arbres de nos données suggère le modèle d'évolution GTR (Generalised Time Reversible) avec un paramètre de forme de 1.08 pour la distribution gamma.

Sous R, les matrices d'alignement ont été importées dans le logiciel de construction d'arbres **MrBayes** sous R, et un arbre de jointure voisin (Neighbor Joining) initial a été construit. La robustesse des arbres de jointure voisin (Neighbor Joining) a été évaluée par une analyse bootstrap, avec 1000 tours de réplication.

Afin d'évaluer le biais potentiel induit par les substitutions associées à la résistance aux médicaments sur la reconstruction de la parenté des échantillons, les positions de codons connues pour être liées à la résistance aux antirétroviraux ont été exclues de l'alignement des séquences pol. Pour affiner les alignements de séquences, les positions avec des gaps ont été également supprimées à l'aide du programme **Gblocks**. Les positions de mutation de résistance appelées primaires (ou majeures) et secondaires (ou mineures) ont été exclues. Les mutations primaires sont connues pour entraîner une altération de la liaison médicamenteuse par elles-mêmes, alors que les mutations secondaires n'ont pas d'effet significatif sur le phénotype par elles-mêmes. L'estimation de la phylogénie, le test du modèle et les procédures de bootstrap ont été effectués sous R, comme décrit ci-dessus. La proportion de sites invariables et le paramètre de forme de distribution gamma utilisés pour la reconstruction de l'arbre étaient respectivement de 51 % et 1,08. D'abord une phylogénie basée sur le maximum de vraisemblance est mise en œuvre avec le modèle de substitution GTR, ensuite une autre méthode basée sur la distance génétique est également utilisée pour la phylogénie et enfin une méthode dite bayésienne (**MrBayes**) a été utilisée pour reconstruire l'histoire évolutive des séquences de notre jeu de données grâce à l'outil R.

5.2 Analyses basées sur la distance avec le logiciel R

Les méthodes basées sur la distance génétique sont une approche rapide et largement utilisée en inférence phylogénétique. Les approches basées sur la distance sont souvent utilisées, par exemple dans l'étude du VIH, pour identifier des groupes de séquences étroitement liées pour une analyse plus approfondie. Afin de sélectionner un sous-ensemble de séquences pol étroitement liées dans la base de données, la distance génétique par paires entre toutes les séquences a été calculée sous le modèle temporel général réversible avec des sites invariables et une distribution gamma (GTR+I+G). Le modèle GTR de substitution de nucléotides permet

à chaque substitution possible d'avoir un taux différent, avec la contrainte d'être symétrique, de sorte qu'une substitution d'un nucléotide i vers j doit être la même qu'une substitution de j vers i. Cette méthode basée sur la distance génétique consiste à :

- Générer une matrice de distance :
- Construire un arbre par jointure entre voisins
- Générer un réseau de séquences


5.3 Analyses basées sur le maximum de vraisemblance avec le logiciel R

Les approches basées sur la probabilité sont plus intensives en calculs que les analyses basées sur la distance, mais sont souvent plus flexibles et puissantes. Dans cette section, nous couvrirons comment nous pouvons utiliser la probabilité pour tester le modèle d'évolution du gène pol de l'ADN à utiliser et comment améliorer un arbre de jointure voisin initial. Les méthodes qui adaptent un modèle d'évolution moléculaire aux données de séquence sont plus fastidieuses en calculs, mais présentent généralement de meilleures performances que les méthodes basées sur la distance.

6. Analyse phylogénétique du ratio dN/dS ^[10]

Pour analyser la nature de l'adaptation et de la sélection qui peut être une sélection positive, une sélection purifiante(neutre), ou une sélection dite négative) dans différentes catégories de gènes hôtes, une méthode appelé analyse phylogénétique du ratio $\frac{dN}{dS}$ ($=\frac{Ka}{Ks}=\omega$) est utilisée pour estimer les taux de substitutions non synonymes et synonymes sous modèles évolutifs réalistes. La méthode utilise les notions de dN qui correspond au taux de substitution non-synonyme et de dS qui correspond au taux de substitution. Une substitution synonyme est une substitution qui ne modifie pas l'acide aminé codé. Une substitution non-synonyme est une substitution qui modifie l'acide aminé codé. Le ratio $\frac{dN}{dS}$ encore appelé le paramètre ω mesure la pression sélective sur la protéine. De manière simpliste, une valeur du ratio $\frac{dN}{dS}$ inférieure à 1 reflète une sélection purifiante ou sélection négative (mutations délétères sont éliminées). Le ratio $\frac{dN}{dS}$ est égal à 1 pour un gène qui évolue sous dérive génétique (ou neutralité) car la fixation ou la perte d'une mutation se fait au hasard. Les substitutions synonymes ou non-synonymes ont la même

probabilité de se fixer ou d'être perdues. Le ratio $\frac{dN}{dS}$ est supérieur à 1 pour un gène qui évolue sous sélection positive car un changement d'acide aminé de la protéine codée est alors favorable et les substitutions non-synonymes ont une plus forte probabilité de se fixer que les substitutions synonymes.



6.1. Calcul du ratio dN/dS par codeml

La première étape de notre analyse va consister à faire ce qu'on appelle une analyse par branche. Cette analyse va nous permettre de déterminer si les branches correspondantes à nos séquences codantes ont évolué sous quelque pression de sélection.

Nous avons utilisé CodeML.

Dans l'entrée « Input », nous avons indiqué le fichier correspondant à l'alignement pour "*seqfile*" et celui correspondant à l'arbre pour "*treefile*".

En sortie "Output" on a un fichier **txt** qui contient les résultats.

Dans la partie "*Seqtype*", nous avons sélectionné « 1 : codons » puisque notre alignement est constitué de séquences codantes.

Dans "*Models*", nous avons coché « *Typical codons model* » et nous avons sélectionné "Branch model" puisque nous voulons faire une analyse par branche.

Enfin nous avons exécuté.

Une fois l'analyse terminée, à la fin du fichier résultat, au niveau de l'intitulé "**w ratios as labels for TreeView**", les valeurs du ratio $\frac{dN}{dS}$ (appelé **w**) sont données pour chacune des branches de la phylogénie.

6.2 Détection de codons sous pression de sélection par codeml

Nous avons utilisé l'outil pamlX pour réaliser la majeure partie de notre analyse, l'outil permet d'effectuer une analyse par site qui permet la détection des codons sous sélection positive.

Il fonctionne comme suit :

- Il prend deux fichiers en entrée : Un fichier correspondant à l'alignement pour "seqfile" et un autre correspondant à l'arbre pour "treefile".
- En sortie "Output" on a un fichier txt qui contient les résultats
- Dans la partie "Seqtype", nous avons sélectionné "1 : codons" puisque notre alignement est constitué de séquences codantes.
- Dans "Models", nous avons coché « Custom selection », nous avons choisi « 0 : one » pour "model" et nous avons coché "2 : selection" pour réaliser une analyse des codons sous sélection positive.
- Ensuite nous avons exécuté.

IV. RÉSULTATS

1. Evolution du gène pol

Sur les 971 séquences pol téléchargées à partir de la base de données Los Alamos , les échantillons ont été déposés sur la base de données entre 1998 et 2020. Un alignement de séquence et une inspection manuelle nous a permis de retenir 33 séquences du gène pol. Les séquences partageant plus de 95 % de similarité avec une ou plusieurs autres séquences ont été sélectionnées pour disposer d'un jeu de données bien sélectionné. La variation génétique moyenne inter-patients parmi les séquences est de 5,1 % (intervalle de 0 à 12,4 %). Bien que plusieurs sous-types soient représentés dans le sous-ensemble de séquences, y compris les sous-types A, B, C, D, G, J, K, F, CRF01-AE, CRF02-AG, et CPX la grande majorité est de la forme recombinante CRF02-AG (54.1%) suivie du sous-type C (14.5%), reflétant la distribution des formes recombinantes des infections prévalentes au Sénégal dans la durée indiquée précédemment. Chaque séquence était longue de 500 paires de bases et couvrait l'intégralité du gène de la protéase et une partie du gène de la rétrotranscriptase (RT).

L'arbre ML dérivé des 33 séquences du gène pol sélectionné est présenté sur la figure 8. L'arbre est enraciné contre une séquence de sous-type 0 du VIH-1. Les valeurs de bootstrap supérieures à 50 % sont indiquées sur les branches, reflétant la fréquence à laquelle une branche donnée s'est produite dans l'échantillonnage de 1000 bootstrap.




Figure 8 : Arbre phylogénétique du gène pol du VIH-1 au Sénégal

L'arbre phylogénétique est construit à partir de la méthode de Neighbor Joining. Les distances évolutives ont été calculées à l'aide de la méthode à 3 paramètres de Tamura et sont exprimées en nombre de substitutions de bases par site. La variation du taux entre les sites a été modélisée avec une distribution gamma (paramètre de forme = 0,91). Cette analyse a porté sur 33 séquences nucléotidiques. Les positions de codon incluses étaient 1st+2nd+3rd+Non coding.

Toutes les positions ambiguës ont été supprimées pour chaque paire de séquences (option de suppression par paires). Il y avait un total de 546 positions dans l'ensemble de données final.




Figure 9 : Analyse de parcimonie maximale des séquences du gène Pol du VIH-1 d'origine sénégalaise

L'histoire évolutive a été déduite à l'aide de la méthode de parcimonie maximale. L'arbre le plus parcimonieux de longueur = 1131 est affiché. L'indice de cohérence est de 0,336870 (0,280920), l'indice de rétention est de 0,336283 (0,336283) et l'indice composite est de 0,113284 (0,094469) pour tous les sites et les sites informatifs sur la parcimonie (entre parenthèses). Le pourcentage d'arbres répliqués dans lesquels les taxons associés sont regroupés dans le test bootstrap (1000 répliqués) est indiqué à côté des branches ^[1]. L'arbre MP a été obtenu à l'aide de l'algorithme Subtree-Pruning-Regrafting (SPR) (p. 126 dans la réf. ^[2]) avec le niveau de recherche 1 dans lequel les arbres initiaux ont été obtenus par l'ajout aléatoire de séquences (10 répétitions). L'arbre est dessiné à l'échelle, avec des longueurs de branches calculées en utilisant la méthode du chemin moyen [voir pg. 132 en réf. 2] et sont dans les unités du nombre de changements sur toute la séquence. Cette analyse a porté sur 33 séquences nucléotidiques. Les positions de codon incluses étaient 1st+2nd+3rd+Non coding. Il y avait un total de 546 positions dans l'ensemble de données final. Des analyses évolutives ont été menées dans *MEGA* 11.

D'après les figures 8 et 9 on voit nettement la présence de deux groupes distincts, le groupe O qui sur lequel les arbres se sont enracinés et qui a divergé le plutôt et le groupe M formé par le reste de l'arbre. L'ensemble des séquences des sous-types du groupe M présente un profil évolutif similaire. Les sous types D, B et J sont plus proches puisqu'ils forment le même monophylétique, puis le sous-type F reste plus le proche de ce groupe, s'en suivent les sous-types C et A qui forment aussi un autre groupe monophylétique. Les CPX restent plus proche du sous-type U mais ne forment pas un groupe monophylétique. Les couronnes des deux arbres sont occupées par la forme recombinante 02_AG.

2. Résultats de l'Analyse Phylogénétique du ratio dN/dS

L'analyse par branche du ratio dN/dS donne le résultat suivant (Figure 10). L'Arbre phylogénétique représente les pressions de sélection (omega) sur chaque branche. Les valeurs bootstrap et les distances évolutives ont été omises de l'arbre pour une meilleure lisibilité des valeurs d'Oméga.




Figure 10 : Phylogénie du ratio $\frac{dN}{dS}$ de chacune des branches, construite à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise

On peut remarquer que toutes les valeurs de dN/dS pour toutes les branches sont identiques. Cette valeur de dN/dS correspond à la moyenne de l'ensemble des branches de la phylogénie qui est approximativement égale à 1 pour l'ensemble des branches, cela suggère une évolution sous sélection positive pour la phylogénie.




Figure 11 : Arbre du taux de mutation dS (taux de mutation synonyme) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise




Figure 12 : Arbre du taux de mutation dN (taux de mutaion non synonyme) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise

3. Résultat de la détection de codons sous pression de sélection

Le fichier résultat contient plusieurs informations relatives à l'évolution des séquences et des mutations présentes.

On peut voir que plusieurs codons ont évolué sous sélection positive, leur liste est donnée vers la fin du fichier de résultat sous l'intitulé "Bayes Empirical Bayes (BEB) analysis".

Pour chacun de ces codons, le numéro et la lettre de l'acide aminé correspondant sont donnés par la première séquence de l'alignement (ici la séquence 02_AG.98.AJ251057) suivie de la probabilité pour que le ratio dN/dS soit supérieur à 1 pour ce codon (la lettre w correspond au ratio dN/dS dans le fichier de résultat). Les codons pour lesquels la probabilité d'avoir évolué sous sélection positive est supérieure à 0,950 (identifiés par * ou **).

Bayes Empirical Bayes (BEB) analysis (Yang, Wong & Nielsen 2005. Mol. Biol. Evol. 22:1107-1118)

Positively selected sites (*: P>95%; **: P>99%)

(amino acids refer to 1st sequence: 02_AG.SN.1998.98SE-MP1213.AJ251057)

	Pr(w>1)	post mean +- SE for w
8 D	1.000**	2.897 +- 0.490
29 P	0.891	2.676 +- 0.744
33 K	0.988*	2.875 +- 0.527
37 N	0.867	2.614 +- 0.775
64 L	0.999**	2.896 +- 0.491
65 R	0.999**	2.896 +- 0.492
66 D	0.988*	2.875 +- 0.528
68 K	0.943	2.779 +- 0.643
79 G	0.569	1.991 +- 0.922
85 F	0.590	2.030 +- 0.921
90 T	0.970*	2.837 +- 0.580
91 L	0.966*	2.831 +- 0.592
108 G	0.924	2.740 +- 0.684
116 P	0.959*	2.816 +- 0.607
128 V	0.999**	2.896 +- 0.491
140 K	1.000**	2.897 +- 0.491
147 Y	0.974*	2.845 +- 0.569
162 G	0.887	2.662 +- 0.748
166 A	0.994**	2.885 +- 0.510
173 N	0.996**	2.890 +- 0.502
177 D	0.982*	2.862 +- 0.545

D'après ces résultats, la plupart des séquences ont évolué sous sélection positive puisqu'on trouve des codons avec une forte probabilité d'avoir un ratio dN/dS supérieur à 1. Ceci fournit des informations sur l'intensité de la sélection exercée par le traitement aux ARV sur le gène pol. Un rôle dans la résistance au traitement par les ARV utilisé a été mis en évidence pour des mutations dans certains acides aminés des protéines RT et PR codées par le gène pol.


Dans un premier temps, nous avons travaillé avec un nombre limité de séquences (33 séquences) alors que la méthode utilisée nécessite un signal fort de sélection pour pouvoir être détecté. Malgré cela, nous avons réussi à mettre en évidence une sélection positive pour certains des acides aminés pour lesquels des mutations permettant de résister au traitement par les ARV ont été décrites. Il est probable qu'un nombre plus important de séquences aurait permis d'obtenir une probabilité d'avoir un ratio dN/dS supérieur au seuil de 0,95 pour certains des autres acides aminés. Nous pouvons donc faire l'hypothèse que l'accumulation de mutations dans le gène pol qui permettent au virus de résister au traitement par les ARV est le résultat d'une évolution sous sélection positive.

On peut donc faire une hypothèse sur le rôle dans la résistance au traitement par les ARV pour des mutations dans certains acides aminés de la protéine RT et PR codée par le gène pol : 8 D , 33 K, 64 L, 65 R , 66 D ,90 T ,91 L ,116 P, 128 V ,140 K, 166 A ,173 N ,177 D .

Pour prouver cette hypothèse, une étude structurale supplémentaire serait nécessaire. Celle-ci permettrait de voir la localisation de chacun de ces acides aminés dans les structures protéiques de la RT et PR et de savoir si les mutations se trouvent à la surface ou dans des sites de fixations des ARV.

4. Relation évolutive du gène pol au Sénégal


Afin d'évaluer la relation évolutive de nos séquences pol étroitement liées dans la base de données, la distance génétique par paires entre toutes les séquences a été calculée sous le modèle temporel général réversible avec des sites invariables et une distribution gamma (GTR+I+G : I→ 0.27, +G →0.67).



Légende : selon la profondeur de l'arbre

 O	 C	 A
 G	 B	 D
 F	 CPX	 U
 02_AG		

Figure 13 : Arbre phylogénétique de l'ensemble des séquences du jeu de données (903 séquences)



Légende : selon la profondeur de l'arbre

	o	C	A
G	B	D	
F	CPX	U	02_AG

Figure 14 : Arbre phylogénétique de l'ensemble des séquences du jeu de données (903 séquences) construit à partir des séquences du gène Pol du VIH-1 d'origine sénégalaise

Rappelons qu'à priori, dans un arbre ci-dessus la longueur des branches est proportionnelle à la quantité d'événement substitutions entre les nœuds/feuilles qu'elle sépare.

Selon la profondeur de l'arbre ci-dessus on retrouve les groupes, les sous-types, les sous-sous-types et les formes recombinantes sous la forme de groupe monophylétique.

D'après ces résultats assortis de l'arbre phylogénétique, selon les longueurs des branches et la profondeur de chaque groupe dans l'arbre on voit que le groupe O forme un groupe monophylétique et constitue le groupe qui a divergé le plus tôt et qui a évolué plus vite. Il constitue un outgroup puisque les reste de nos séquences sont du groupe M. Il s'en est suivi respectivement le sous-type C, le sous-type A (représenté par le sous-sous-types A1 et A3), le sous-type G, les sous-types B et D qui forment un groupe paraphylétique, les sous-types G et U sont incrustés dans la forme recombinante CPX. La couronne de l'arbre est occupée par la forme recombinante CRF02_AG qui occupe largement la majorité de notre jeu de données.

V. DISCUSSION

Une récente étude a été menée sur « *l'origine et l'histoire évolutive du sous-type C du VIH-1 au Sénégal* » ^[6]. Dans cette étude, les auteurs ont utilisé une combinaison d'analyses phylogénétiques et une approche basée sur la coalescence bayésienne, pour étudier les relations phylogénétiques de 56 isolats de sous-type C du gène *pol* au Sénégal avec 3 025 souches de sous-type C qui ont été échantillonnées dans le monde entier. Les reconstructions évolutives de cette étude suggèrent que plusieurs virus de sous-type C avec un ancêtre commun originaires du début des années 1970 sont entrés au Sénégal. Il n'y a eu qu'une seule propagation efficace dans la population des hommes ayant des rapports sexuels avec des hommes, qui a très probablement résulté d'une seule introduction, soulignant l'importance des comportements à haut risque dans la propagation des virus. Comparée à cette étude, notre étude révèle que sur la base moléculaire toutes les séquences du groupe O se regroupent et ont divergé en premier lieu, On pourrait donc dire du point de vue de la datation le groupe O l'introduction du groupe O au Sénégal est plus ancienne que celle du sous-types C.

Nous avons évalué le potentiel génétique du gène *pol* avec lequel on a pu retracer son histoire évolutive. Étant donné que les données utilisées dans la présente étude correspondent aux séquences générées par séquençage après plusieurs suivis thérapeutiques, la grande

disponibilité de ces séquences dans la base de données **Los Alamos** peut fournir des ensembles de données utiles pour les études épidémiologiques moléculaires. La parenté des séquences de notre base de données a été reconstruite par des analyses phylogénétiques, sur la base de différentes régions génétiques au sein du gène pol. Une grande partie des clusters ont été conservés lorsque les positions des codons associées à la résistance aux médicaments ont été enlevé de l'alignement pol d'origine.

La présente étude a comparé les topologies d'arbre obtenues avec différentes séquences du gène pol du VIH-1 assez représentative pour subir des dynamiques évolutives distinctes. Les modèles de regroupement étaient identiques dans les arbres phylogénétiques, les arbres obtenus ne différant que par la longueur de leurs branches et les motifs de regroupement de séquences distantes. On constate alors que les relations de parenté décrites à travers ces arbres (Figures 8 & 9) sont globalement semblables (même topologie) : ils sont congruents. L'Analyse du ratio de mutations sur chaque branche confirme cette variabilité génétique. Par conséquent, nos résultats suggèrent que le gène pol du VIH-1 gène contient une variabilité génétique intrinsèque suffisante pour permettre la reconstruction de son histoire évolutive par des moyens phylogénétiques.

Etant donné que les séquences pol sont très étudiées car elles sont la cible des médicaments antirétroviraux. Les résultats sur la détection de codons sous pression de sélection suggèrent un certain nombre de mutations susceptibles d'être à l'origine des résistances. Ces mutations pourraient faire l'objet d'une nouvelle étude portant les séquences des protéines (protéase et reverse transcriptase [RT]) ciblées par cette résistance. Cependant on pourrait prédire un modèle de structure si bien sûr celui-ci n'existe pas déjà au niveau de la pdb (et s'il est là on l'utilise) et essayer de faire un docking avec ce modèle et les médicaments. Il s'agira de faire des alignements de séquences pour voir si les séquences obtenues au Sénégal ressemblent aux structures résolues expérimentalement et si on a une identité de séquence environ de 90% on peut ne pas faire de modèle et si on a une identité de séquence qui n'est pas assez forte on pourra utiliser les structures qui sont dans la PDB et faire un modèle de notre protéine Sénégal.

VI. CONCLUSION

Malgré sa conservation génétique, le gène pol du VIH-1 présente une variabilité suffisante pour permettre la reconstruction phylogénétique des transmissions. Des clades identiques ont été obtenues, quelle que soit la méthode phylogénétique. Les résultats de ces différentes études pourraient avoir une conséquence immédiate dans le suivi de l'épidémiologie du VIH-1. Compte tenu de la prépondérance des données du gène pol du VIH-1, ces séquences pourraient également être utilisées efficacement pour suivre la présence de clades de transmission au sein des communautés à partir desquelles elles ont été obtenues. De plus, ces résultats démontrent l'importance des informations épidémiologiques inhérentes aux données du gène pol, qui peuvent aider à estimer les taux de transmission récente du VIH-1 au sein d'une population, mais aussi à une étude médicamenteuse.

Références

- [1] Turner BG, Summers MF. Structural biology of HIV. J Mol Biol. 1999 Jan 8;285(1):1-32. doi: 10.1006/jmbi.1998.2354. PMID: 9878383.
- [2] Emi Suzuki, Haruna Kashiwase. Les nouvelles infections au VIH sont en baisse de 40 % par rapport à 1998
- [3] <https://www.hiv.lanl.gov/>
(Site consulté entre la période Janvier 2021 à Septembre 2022)
- [4] Bailes E, Gao F, Bibollet-Ruche F, Courgnaud V, Peeters M, Marx PA, Hahn BH, Sharp PM. Hybrid origin of SIV in chimpanzees. Science. 2003 Jun 13;300(5626):1713. doi: 10.1126/science.1080657. PMID: 12805540.
- [5] <http://dbpartners.stanford.edu:8080/RegaSubtyping/stanford-hiv/typingtool/>
- [6] Jung M, Leye N, Vidal N, Fargette D, Diop H, Toure Kane C, Gascuel O, Peeters M. The origin and evolutionary history of HIV-1 subtype C in Senegal. PLoS One. 2012;7(3):e33579. doi: 10.1371/journal.pone.0033579. Epub 2012 Mar 28. PMID: 22470456; PMCID: PMC3314668.
- [7] Luchetta, Maurel, Higuët, Vervoort, Kahn, and Kahn Axel. Évolution Moléculaire Cours Et Questions De Révision. Malakoff: Dunod, 2005. Print. Sciences Sup Sciences De La Vie Cours Et Questions De Révision.
- [8] Emmanuel Douzery, Frédéric Delsuc. Les Horloges d'évolution.
- [9] Hervé Philippe, Agnès Germot, Hervé Le Guyader, André Adoutte. L'arbre universel du vivant et les difficultés de la reconstruction phylogénétique.
- [10] Christopher Peacock (ed.), Parasite Genomics Protocols, Methods in Molecular Biology, vol. 1201, DOI 10.1007/978-1-4939-1438-8_4, © Springer Science+Business Media New York 2015

Webographie

Quelques sites consultés pour réaliser nos phylogénies: Ces sites ont été consulté entre Janvier 2021 et Septembre 2022

<http://evolution.genetics.washington.edu/phylip/software.html>

<http://bioweb.pasteur.fr/seqanal/phylogeny/>

<http://pbil.univ-lyon1.fr/ird/IRD.html>

<http://bioweb2.pasteur.fr/>

<http://www.ncbi.nlm.nih.gov/Taxonomy/CommonTree/wwwcmt.cgi>

[cours de phylogénie moléculaire \(umc.edu.dz\)](http://cours.de.phylogenie.molculaire(umc.edu.dz))

[Les arbres phylogénétiques : construction et interprétation - blog bioinformatique](#)

[communautaire scientifiqueblog bioinformatique communautaire scientifique \(bioinfo-fr.net\)](#)

Annexes

Outils Bioinformatiques :

Dans le cadre de notre stage nous avons appris à nous servir des outils Bioinformatiques et des bases de données suivants :

→ Jalview pour l'alignement de séquences :

Jalview est un logiciel de traitement de séquences issu de la recherche qui permet une étude originale des relations entre séquence et structure des protéines.

En particulier, grâce aux options de coloration d'alignements de séquences et de liaison avec des modèles moléculaires, Jalview offre la possibilité de visualiser les zones conservées ou variables de protéines. Les possibilités de ce logiciel sont intéressantes pour notre enseignement entre autres dans le cadre de l'étude des mécanismes de l'évolution, ou de la diversité des anticorps.

→ Seaview pour l'alignement de séquences :

SeaView est une interface utilisateur graphique multiplateforme pour l'alignement de séquences multiples et la phylogénie moléculaire. SeaView lit et écrit divers formats de fichiers (NEXUS , MSF, CLUSTAL, FASTA, PHYLIP, MASE , Newick) de séquences d'ADN et de protéines et d'arbres phylogénétiques. SeaView pilote les programmes *muscle* ou Clustal Omega pour l'alignement de séquences multiples, et permet également d'utiliser n'importe quel algorithme d'alignement externe capable de lire et d'écrire des fichiers au

format FASTA. Seaview pilote le programme **Gblocks** pour sélectionner des blocs de sites conservés de manière évolutive. SeaView calcule les arbres phylogénétiques en parcimonie, grâce à l' algorithme dnapars/protpars de PHYLIP , distance, avec des algorithmes NJ ou BioNJ sur une variété de distances évolutives, maximum de vraisemblance, programme de conduite PhyML 3.1. Document d'aide en ligne. Ancienne version 3.2 de seaview

→ **Muscle (en ligne) pour l'alignement de séquences :**

MUSCLE stands for MULTiple Sequence Comparison by Log-Expectation. **MUSCLE** is claimed to achieve both better average accuracy and better speed than ClustalW2 or T-Coffee, depending on the chosen options. **MUSCLE** enables high-throughput applications to achieve average accuracy comparable to the most accurate tools previously available, which is expected to be increasingly important in view of the continuing rapid growth in sequence data. Multiple alignments of protein sequences are important in many applications, including phylogenetic tree estimation, secondary structure prediction and critical residue identification.

→ **MEGA pour visualiser les arbres phylogénétiques produites par R et Mr Bayes**

Le contrat d'utilisateur final (EUA) **MEGA** est un accord légal entre individu ou une seule entité et les détenteurs des droits d'auteur (les auteurs et leurs institutions) pour les produits logiciels **MEGA** (y compris, mais sans s'y limiter, **MEGA-MD**, **MEGA1**, **MEGA2**, **MEGA3**, **MEGA4**, **MEGA5**, **MEGA6**, **MEGA7**, **MEGAX**, **MEGA-CC**, **MEGAX-CC** et **MEGA10**), qui peuvent inclure des composants logiciels associés, des supports, des documents imprimés et une documentation en ligne ou électronique

→ **R pour aligner et produire des arbres phylogénétiques /**

RStudio est un environnement de développement gratuit, libre et multiplateforme pour R, un langage de programmation utilisé pour le traitement de données et l'analyse statistique.

→ **Gblocks pour le nettoyage de nos alignements de séquences :**

Gblocks est un programme informatique écrit en langage ANSI C qui élimine les positions mal alignées et les régions divergentes d'un alignement de séquences d'ADN ou de protéines. Ces positions peuvent ne pas être homologues ou avoir été saturées par de multiples substitutions et il convient de les éliminer avant l'analyse phylogénétique. **Gblocks** sélectionne les blocs de la même manière que cela se fait habituellement à la main, mais en suivant un ensemble reproductible de conditions. Les blocs sélectionnés doivent répondre à

certaines exigences en ce qui concerne l'absence de grands segments de positions contiguës non conservées, l'absence ou la faible densité de positions d'écart et la conservation élevée des positions flanquantes, rendant l'alignement final plus adapté à l'analyse phylogénétique.

***Transeq* et *Backtranseq*(Emboss) :**

Outils qui permettent la transcription d'acides nucléiques en acides aminés

→ *MrBayes* : pour la production d'arbres phylogénétiques :

MrBayes est un programme d'inférence bayésienne et de choix de modèles parmi un large éventail de modèles phylogénétiques et évolutifs. **MrBayes** utilise les méthodes de la chaîne de Markov Monte Carlo (MCMC) pour estimer la distribution a posteriori des paramètres du modèle. Les fonctionnalités du programme incluent :

Une interface de ligne de commande commune aux systèmes d'exploitation Macintosh, Windows et UNIX ;

Aide étendue disponible à partir de la ligne de commande ;

→ *figtree* :

FigTree propose un visualiseur graphique d'arbres phylogénétiques. Application spécialisée, celle-ci permet d'accéder rapidement à des bases de données contenant des informations sur les arbres phylogénétiques.

Blast+ :

Outils installer en local et qui permet la création de base de données en local mais aussi l'alignement des séquences avec la séquence de référence tout en visualisant les e-value.

→ *Pal2nal*:


PAL2NAL est un programme qui convertit un alignement de séquences multiples de protéines et les séquences d'ADN (ou d'ARNm) correspondantes en un alignement de codons. L'alignement de codons résultant peut en outre être soumis au calcul des taux de substitution synonymes (dS) et non synonymes (dN) . Si l'entrée est une paire de séquences, PAL2NAL calcule automatiquement d S et d N par le programme codeml dans

→ *paml* et *codeml* :

PAML est un ensemble de programmes d'analyses phylogénétiques de séquences d'ADN ou de protéines utilisant le maximum de vraisemblance. PAML n'est pas bon pour la fabrication d'arbres. Il peut être utilisé pour estimer des paramètres et tester des hypothèses pour étudier le processus évolutif, lorsque vous avez reconstruit des arbres à l'aide d'autres programmes tels que PAUP, PHYLIP, MOLPHY, PhyML, RaxML, etc.

→ Base de données Los Alamos

Les bases de données sur le VIH contiennent des données complètes sur les séquences génétiques et les épitopes immunologiques du VIH. Le site donne également accès à un grand nombre d'outils qui peuvent être utilisés pour analyser et visualiser ces données. Ce projet a été financé en tout ou en partie par des fonds fédéraux de l'Institut national des allergies et des maladies infectieuses, des National Institutes of Health, du ministère de la Santé et des Services sociaux, en vertu de l'accord inter-agences No. AAI12007-001-00000.



Répartition géographique en Afrique du VIH-1 selon la région génomique d'intérêt de notre étude [2253-3554].