



## Master 2 Bio-Informatique

### Rapport d'alternance

Outil intégré de bioanalyse transcriptomique *bulk RNA-seq* pour l'étude des neutrophiles et des cellules épithéliales dans un modèle murin (*MMTV-Neu*) de cancer du sein : développement et exploitation fonctionnelle

**Etudiant :**

Albert NDOUR

**Maitres de Stage :**

Dr Marie-Cécile MICHALLET <sup>1</sup>

Dr Roxane POMMIER <sup>2</sup>

**Lieux de Stage :**

Centre de Recherche en Cancérologie de Lyon / Centre Léon Bérard

**Équipe de Recherche <sup>1</sup> :**

Immunosurveillance du cancer et ciblage thérapeutique  
(responsable : Dr Christophe Caux)

**Plateforme Bioinformatique <sup>2</sup> :**

Plateforme Bioinformatique Gilles Thomas  
(responsable : Anthony Ferrari)

1<sup>er</sup> juin 2025

## Résumé

Depuis plusieurs décennies, les avancées en biologie moléculaire et en techniques de séquençage ont révolutionné la compréhension du cancer du sein, qui demeure un problème majeur de santé publique. Dans la tumeur, les cellules épithéliales cancéreuses jouent un rôle central en activant des voies de signalisation intrinsèques et en exprimant diverses molécules immunomodulatrices qui évoluent au cours de la progression tumorale. Parallèlement, dans le microenvironnement tumoral, les neutrophiles ont récemment émergé comme des acteurs clés de la réponse immunitaire, mais leurs phénotypes et leurs fonctions au cours du développement du cancer restent mal décrits. Notre étude vise à identifier les gènes et les voies moléculaires spécifiques des neutrophiles et des cellules épithéliales aux stades précoces et tardifs de la tumorigénèse mammaire. Cette analyse transcriptomique comparative est essentielle pour déterminer comment les cellules épithéliales évoluent au cours de la progression tumorale et comment les neutrophiles s'adaptent en réponse à ces changements, fournissant ainsi de nouvelles pistes pour des interventions d'immunothérapies ciblées.

L'objectif principal de ce stage était de développer une interface intégrée pour la bio-analyse de données transcriptomiques RNAseq bulk. Cet outil permet aux biologistes d'identifier les gènes et les voies moléculaires discriminantes entre différentes conditions d'intérêt, en particulier dans le contexte du cancer du sein et à différents stades de la progression tumorale.

Les données utilisées proviennent d'un modèle murin de cancer du sein, **MMTV-Neu**. L'interface interactive, développée avec Shiny, intègre plusieurs types d'analyses, y compris l'analyse non-supervisée, l'analyse de gènes et signatures transcriptionnelles, la déconvolution du microenvironnement tumoral, l'analyse d'expression différentielle, et l'analyse d'enrichissement fonctionnelle. Les utilisateurs peuvent visualiser les résultats à travers divers outils graphiques tels que des volcano plots, des clusterings hiérarchiques (heatmaps) et des analyses d'enrichissement (ORA, GSEA, ssGSEA, GSVA).

Dans le cadre de ce rapport, nous avons utilisé notre interface de bioanalyse pour étudier les neutrophiles infiltrant les glandes mammaires au stade précoce et au stade tardif du développement tumoral. Cette approche nous a permis de mettre en évidence des signatures transcriptomiques stade-spécifique associées aux neutrophiles du microenvironnement tumoral. L'analyse intégrée des données de RNA-seq a révélé une activation significative de la voie de signalisation  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  dans les neutrophiles tumoraux, caractérisée par la surexpression coordonnée de médiateurs pro-inflammatoires et de facteurs anti-apoptotiques.

Le développement de cet outil a impliqué jusqu'ici l'analyse des données de souris. Les avantages et limites de l'interface sont discutés, avec des perspectives d'amélioration pour des applications futures en recherche fondamentale et translationnelle sur le cancer. Les perspectives de cet outil incluent sa généralisation que nous avons initié en intégrant la possibilité de réaliser l'analyse Bulk RNAseq aussi bien sur des données murines qu'humaines.

**Mots clés :** Cancer du sein, Neutrophiles, Bulk RNA-seq, R, Shiny, Analyse, non-supervisée, Analyse d'expression différentielle, ORA, GSEA, déconvolution immune.

# Table des matières

|          |                                                                                                                                   |           |
|----------|-----------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                                                                                               | <b>2</b>  |
| 1.1      | Contexte scientifique . . . . .                                                                                                   | 2         |
| 1.2      | Objectifs . . . . .                                                                                                               | 2         |
| <b>2</b> | <b>Matériels et Méthodes</b>                                                                                                      | <b>3</b>  |
| 2.1      | Modèle expérimental . . . . .                                                                                                     | 3         |
| 2.2      | Principaux packages utilisés pour l'analyse . . . . .                                                                             | 4         |
| 2.2.1    | tximport . . . . .                                                                                                                | 4         |
| 2.2.2    | DESeq2 . . . . .                                                                                                                  | 4         |
| 2.2.3    | ComplexHeatmap . . . . .                                                                                                          | 5         |
| 2.2.4    | org.Mm.eg.db et AnnotationDbi . . . . .                                                                                           | 5         |
| 2.2.5    | immunedeconv . . . . .                                                                                                            | 5         |
| 2.2.6    | Les packages pour les analyses d'enrichissement fonctionnel . . . . .                                                             | 6         |
| 2.3      | Conception de l'interface intégrée . . . . .                                                                                      | 7         |
| 2.3.1    | Module 1 : analyse non-supervisée . . . . .                                                                                       | 10        |
| 2.3.2    | Module 2 : analyse des gènes et signatures transcriptionnelles . . . . .                                                          | 10        |
| 2.3.3    | Module 3 : Infiltrat tumoral (déconvolution du microenvironnement tumoral) . . . . .                                              | 11        |
| 2.3.4    | Module 4 : analyse d'expression différentielle . . . . .                                                                          | 12        |
| <b>3</b> | <b>Résultats : exemple de bioanalyse</b>                                                                                          | <b>13</b> |
| 3.1      | Question scientifique . . . . .                                                                                                   | 13        |
| 3.2      | Analyse exploratoire de la variabilité globale de données transcriptomiques du modèle MMTV-Neu . . . . .                          | 14        |
| 3.3      | Spécificité transcriptionnelle des neutrophiles selon leur localisation et le stade tumoral . . . . .                             | 15        |
| 3.4      | Analyse des voies enrichies parmi les gènes du cluster D . . . . .                                                                | 17        |
| 3.4.1    | Représentation des scores d'enrichissement ssGSEA pour les voies inflammatoires et immunitaires . . . . .                         | 18        |
| 3.4.2    | Analyse de l'expression des gènes impliqués dans la signalisation $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ . . . . .           | 19        |
| 3.5      | Analyse de l'expression différentielle : Neutrophiles de la glande mammaire tumorale versus non tumorales . . . . .               | 20        |
| 3.5.1    | Analyse de sur-représentation de la voie $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ à partir des 813 gènes surexprimés . . . . . | 21        |
| 3.5.2    | Analyse GSEA (Gene Set Enrichment Analysis) de la voie $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ . . . . .                      | 22        |
| <b>4</b> | <b>Discussion et perspectives</b>                                                                                                 | <b>23</b> |
| <b>5</b> | <b>Conclusion</b>                                                                                                                 | <b>24</b> |
| <b>6</b> | <b>Annexes</b>                                                                                                                    | <b>25</b> |
| <b>7</b> | <b>Bibliographie</b>                                                                                                              | <b>26</b> |

## Table des figures

|    |                                                                                                                                                                                                       |    |
|----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1  | Modèle expérimental. . . . .                                                                                                                                                                          | 3  |
| 2  | Architecture modulaire intégrée de l'interface . . . . .                                                                                                                                              | 7  |
| 3  | Workflow de l'interface intégrée . . . . .                                                                                                                                                            | 9  |
| 4  | Vue du module dédié à l'analyse non supervisée . . . . .                                                                                                                                              | 10 |
| 5  | Vue du module dédié à l'analyse des gènes et signatures transcriptionnelles . . . . .                                                                                                                 | 11 |
| 6  | Vue du module dédié à la déconvolution de microenvironnement tumoral . . . . .                                                                                                                        | 12 |
| 7  | Vue du module dédié à l'analyse d'expression différentielle . . . . .                                                                                                                                 | 13 |
| 8  | Visualisations exploratoires basées sur les 10 % de gènes les plus variables dans l'ensemble de la cohorte (n = 71 échantillons) : (a) analyse en composantes principales (ACP), (b) Heatmap. . . . . | 14 |
| 9  | Exploration des profils transcriptomiques des neutrophiles à partir des 10 % de gènes les plus variables. . . . .                                                                                     | 16 |
| 10 | Top 10 des voies fonctionnelles enrichies parmi les gènes du cluster D . . . . .                                                                                                                      | 17 |
| 11 | Scores ssGSEA pour les quatre voies les plus enrichies identifiées dans le cluster D . . . . .                                                                                                        | 18 |
| 12 | Analyse comparative de l'expression génique dans les neutrophiles infiltrant les glandes mammaires normales et tumorales . . . . .                                                                    | 20 |
| 13 | Volcano plot des gènes différentiellement exprimés entre les neutrophiles tumoraux tardifs et le groupe de référence . . . . .                                                                        | 21 |
| 14 | Analyse de sur-représentation de la voie $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ à partir des 813 gènes surexprimés . . . . .                                                                     | 22 |
| 15 | Analyse d'enrichissement GSEA de la voie $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ dans les neutrophiles tumoraux comparés au groupe de référence . . . . .                                         | 23 |

## Liste des tableaux

|   |                                                 |    |
|---|-------------------------------------------------|----|
| 1 | Packages R utilisés et leurs versions . . . . . | 25 |
|---|-------------------------------------------------|----|

## Liste des abréviations

- ACP - *Analyse en Composantes Principales*
- C2-CGP - *Collection C2 Chemical and Genetic Perturbations* (MSigDB)
- C2-CP - *Collection C2 Canonical Pathways* (MSigDB)
- C5 - *Collection C5 Gene Ontology* (MSigDB)
- COND - *Condition*
- CTR - *Contrôle*
- DCQ - *Digital Cell Quantifier*
- DE - *Expression différentielle* (*Differential Expression*)
- DESeq2 - *Differential gene Expression analysis based on the negative binomial distribution*
- fgsea - *Fast Gene Set Enrichment Analysis*
- GSEA - *Analyse d'enrichissement de gènes* (*Gene Set Enrichment Analysis*)
- GSVA - *Analyse de variation de groupes de gènes* (*Gene Set Variation Analysis*)
- H - *Hallmark gene sets* (MSigDB)
- HER2/ERBB2 - *Récepteur du facteur de croissance épidermique humain 2* (*Human Epidermal Growth Factor Receptor 2/Erythroblastic Leukemia Viral Oncogene Homolog 2*)
- MET - *Microenvironnement tumoral* (*Tumor Microenvironment*)
- MMTV-Neu - *Modèle murin de cancer du sein* (*Mouse Mammary Tumor Virus - Neu*)
- mMCP-counter - *Mouse Microenvironment Cell Populations counter*
- MSigDB - *Molecular Signatures Database*
- N1 - *Neutrophiles associés aux tumeurs (TAN) de type N1*
- N2 - *Neutrophiles associés aux tumeurs (TAN) de type N2*
- ORA - *Analyse de sur-représentation de voies* (*Over-Representation Analysis*)
- RNA-Seq - *Séquençage d'ARN* (*RNA Sequencing*)
- seq-ImmuCC - *Sequencing-based Immune Cell Composition Counter*
- ssGSEA - *Analyse d'enrichissement de groupes de gènes par échantillon unique* (*Single Sample Gene Set Enrichment Analysis*)
- TAN - *Neutrophiles associés aux tumeurs* (*Tumor-Associated Neutrophils*)
- TPM - *Transcripts Per Million*

# 1 Introduction

## 1.1 Contexte scientifique

Le cancer du sein demeure la principale cause de mortalité par cancer chez les femmes à l'échelle mondiale, avec près de 700 000 décès estimés en 2020 (1). Grâce aux avancées en matière de dépistage précoce et de thérapies ciblées, davantage de cas sont désormais diagnostiqués, ce qui contribue à une incidence apparente en hausse, avec environ 2,3 millions de nouveaux cas recensés chaque année (2).

Au cours de la dernière décennie, un changement de paradigme s'est opéré dans la compréhension de la biologie tumorale, déplaçant l'attention des caractéristiques intrinsèques des cellules cancéreuses vers l'écosystème complexe du microenvironnement tumoral (MET) dont fait partie le système immunitaire. Parmi les populations leucocytaires présentes dans le MET, les neutrophiles émergent comme des acteurs clés de la réponse immunitaire. Cependant, des études récentes ont révélé leur remarquable hétérogénéité phénotypique et fonctionnelle (3). Cette hétérogénéité se manifeste notamment par l'identification de sous-populations aux propriétés diamétralement opposées : les neutrophiles associés aux tumeurs (TAN) de type N1, aux fonctions anti-tumorales, et les TAN de type N2, aux propriétés pro-tumorales (4).

Dans le cancer du sein spécifiquement, cette dualité fonctionnelle s'avère particulièrement pertinente. Des analyses transcriptomiques et protéomiques ont démontré que l'infiltration en neutrophiles est associée à un pronostic défavorable dans les sous-types agressifs comme le triple-négatif (5), tandis que certaines signatures de neutrophiles activés corrélaient avec une meilleure survie dans les tumeurs lumineales (6). Cette ambivalence reflète la complexité des interactions entre neutrophiles et cellules tumorales mammaires.

De plus, l'hétérogénéité des neutrophiles fait d'eux une cible thérapeutique potentiellement prometteuse mais complexe. En effet, des études récentes ont montré que les neutrophiles peuvent présenter des phénotypes distincts au cours de la progression tumorale, généralement anti-tumoraux aux stades précoces (7) et pro-tumoraux aux stades tardifs (4; 8). Cette plasticité fonctionnelle suscite un intérêt croissant pour des stratégies visant à moduler leur activité plutôt qu'à les dépler systématiquement (7). Cependant, ces mécanismes de polarisation des neutrophiles dans le contexte spécifique du cancer du sein restent encore mal caractérisés.

Pour explorer cette question, nous avons utilisé le modèle murin transgénique MMTV-Neu, particulièrement adapté à l'étude du cancer du sein. Dans ce modèle, les souris développent spontanément des tumeurs mammaires sous l'effet de l'expression de l'oncogène Neu (l'équivalent murin de HER2), contrôlé par un promoteur spécifique exprimé par les cellules épithéliales mammaires. L'évolution tumorale y est progressive, avec une distinction claire entre stades précoces et tardifs, ce qui nous permet d'observer finement les changements transcriptomiques des cellules tumorales au cours de la tumorigénèse et d'évaluer parallèlement l'évolution des neutrophiles à ces différents stades de développement.

## 1.2 Objectifs

Ce projet s'articule autour d'une question scientifique centrale : *quels sont les gènes et les voies moléculaires spécifiquement exprimés par les neutrophiles et les cellules épithéliales aux stades précoce et tardif de la tumorigénèse mammaire ?*

Face à la complexité des données recueillies (un total de 71 échantillons RNA-seq bulk) couvrant plusieurs types cellulaires et compartiments biologiques, à deux stades de tumorigénèse, la mise en place d'un outil d'aide à l'analyse s'est rapidement imposée comme une nécessité. L'objectif principal a donc été de concevoir et développer une interface intégrée dédiée à l'analyse de ces données RNA-seq bulk.

Sur le plan technique, l'objectif principal de notre mission était de créer une interface interactive d'analyse transcriptomique, capable d'intégrer et d'explorer les données RNAseq issues de différents types cellulaires (neutrophiles, cellules épithéliales) et de divers compartiments (glande mammaire, sang, moelle osseuse), à chaque stade de la tumorigenèse (précoce et tardif). L'un des objectifs à long terme est d'identifier des signatures moléculaires propres aux neutrophiles et aux cellules épithéliales, susceptibles de constituer de futures cibles thérapeutiques, notamment en immunothérapie

Pour exploiter au mieux la richesse des données, l'interface a été conçue comme un environnement d'analyse structuré en modules complémentaires. Elle comprend : des outils d'analyse non supervisée pour explorer les structures globales des données, des modules dédiés à l'étude de gènes et de signatures transcriptionnelles d'intérêt, une section d'outils de déconvolution pour estimer les populations stromales présentes, et une section pour l'analyse d'expression différentielle. Cette approche progressive permet une exploration complète des dynamiques transcriptomiques en jeu au cours de la progression tumorale.

## 2 Matériels et Méthodes

### 2.1 Modèle expérimental

Notre étude s'appuie sur le modèle murin **MMTV-Neu**, qui représente un système expérimental pertinent pour l'étude de la carcinogenèse mammaire spontanée. Ce modèle transgénique sur fond génétique Balb/c se caractérise par l'expression spécifique de l'oncogène Neu (orthologue du gène murin ErbB2) dans l'épithélium mammaire sous le contrôle du promoteur MMTV (Mouse Mammary Tumor Virus). Le protocole expérimental a impliqué deux cohortes distinctes : un groupe expérimental de souris ( $\text{NeuT}^+$ ) permettant le suivi de la progression tumorale, et un groupe de souris contrôle ( $\text{NeuT}^-$ ) issu de la même lignée mais n'exprimant pas l'oncogène, servant de référence pour distinguer les altérations liées à la tumorigenèse. Les prélèvements biologiques ont été stratégiquement échelonnés à deux stades représentatifs de la progression tumorale : une phase précoce (8–12 semaines) correspondant à une hyperplasie avec dysplasie, et une phase tardive (20–24 semaines) caractérisée par des carcinomes invasifs bien établis.(cf. Figure 1)




FIGURE 1 – Modèle expérimental.

Pour chaque souris, trois compartiments biologiques ont été analysés en parallèle : la glande mammaire (normale ou tumorale selon le génotype), le sang et la moelle osseuse. Cette approche nous a permis de caractériser les neutrophiles à différents stades et dans différents contextes



biologiques. La moelle osseuse, siège de l'hématopoïèse, contient principalement des neutrophiles immatures. Le compartiment sanguin présente des neutrophiles matures circulants, dont le phénotype diffère de ceux infiltrant les tissus. Enfin, la glande mammaire nous a permis d'étudier l'évolution des cellules épithéliales mammaires et des neutrophiles infiltrants au cours de la tumorigenèse, en comparant les profils transcriptomiques aux stades précoces et tardifs du développement tumoral. Cette analyse comparative des trois compartiments constitue un modèle intégratif pour comprendre comment les neutrophiles se différencient et s'adaptent dans le contexte du cancer du sein.

Ce design expérimental permet de caractériser la reprogrammation dynamique des neutrophiles et des cellules épithéliales au cours de la progression tumorale mammaire et identifier les signatures transcriptionnelles spécifiques de chaque type cellulaire.

## 2.2 Principaux packages utilisés pour l'analyse

### 2.2.1 tximport

L'importation et la préparation des données transcriptomiques ont été réalisées à l'aide du package R `tximport` (9). Ce package est conçu pour faciliter l'intégration des données d'abondance des transcrits dans les analyses d'expression au niveau des gènes. Nous avons exploité les fichiers produits par `Salmon`, une méthode permettant de quantifier l'abondance des transcrits à partir de lectures RNA-seq. Elle fournit pour chaque transcrit plusieurs indicateurs, notamment les TPM (Transcripts Per Million), les comptages bruts (Counts) et les longueurs des gènes considérés (Length). (10)

Pour relier les transcrits à leurs gènes d'origine, nous avons utilisé une table d'annotation biologique issue de la base de données Ensembl, ce qui a permis une correspondance précise entre chaque identifiant de transcrit et son gène parent. L'agrégation des données au niveau génique s'est faite selon la méthode `scaledTPM`, qui prend en compte la longueur effective des transcrits, un aspect essentiel pour corriger les effets des isoformes alternatives exprimées différemment selon les conditions biologiques.

### 2.2.2 DESeq2

L'analyse différentielle d'expression génique a été implémentée via le package R `DESeq2` (11), conçu pour traiter les données de comptage (Counts) RNA-seq et identifier les différences d'expression entre conditions expérimentales. Notre protocole d'analyse a intégré directement les matrices de comptage brut issues de l'étape `tximport`, structurées avec les identifiants d'échantillons en colonnes et les gènes annotés en lignes, ainsi qu'un *dataframe* de métadonnées détaillant les attributs expérimentaux de chaque échantillon (génotype, compartiment cellulaire, stade tumoral). La construction de l'objet `DESeqDataSet` a été réalisée via la fonction `DESeqDataSetFromTximport()`, avec spécification d'une formule de design (`design = ~ DEcolumn`) définissant la variable catégorielle pour les comparaisons inter-groupes. L'exécution de l'analyse différentielle a été effectuée par la fonction intégrative `DESeq()`, qui enchaîne automatiquement l'estimation des facteurs de normalisation, le calcul des dispersions géniques et l'application des tests statistiques basés sur la distribution binomiale négative.

Pour chaque comparaison, les résultats ont été extraits à l'aide de la fonction `results()`, en spécifiant explicitement un vecteur `contrast_groups` définissant les deux conditions expérimentales à comparer (par exemple : "COND" versus "CTR").

Une étape importante de post-traitement des résultats différentiels a consisté en l'application de la fonction `lfcShrink()` de `DESeq2`, utilisant la méthode bayésienne "apeglm" (12). Cette méthode permet de modérer les estimations des  $\log_2$  fold-changes, en particulier pour les gènes faiblement exprimés, afin de réduire la variance excessive et améliorer la stabilité des résultats.



Elle contribue ainsi à limiter les faux positifs sans compromettre la puissance statistique, ce qui est essentiel pour interpréter de manière fiable les variations d'expression.

En amont, notre pipeline intègre également une étape de normalisation par la méthode de la médiane des ratios, qui ajuste les comptages bruts en fonction des différences de profondeur de séquençage entre les échantillons. Les visualisations de type heatmap présentées dans ce rapport ont été réalisées à partir des TPM normalisés pour permettre la comparaison relative entre profils d'expression de gènes au sein de chaque échantillon.

### 2.2.3 ComplexHeatmap

La visualisation des profils d'expression génique à grande échelle a été réalisée à l'aide du package **ComplexHeatmap** (13), un outil de référence pour générer des heatmaps riches en informations. Les matrices d'expression utilisées pour ces visualisations correspondent aux TPM (*Transcripts Per Million*) normalisées afin de rendre comparables les intensités d'expression entre gènes et conditions. Chaque niveau d'expression est représenté visuellement par un dégradé de couleurs, facilitant l'identification des variations relatives entre les échantillons.

Des annotations contextuelles (génotype, type cellulaire, stade tumoral) ont été ajoutées sur les marges des heatmaps pour une interprétation facilitée des profils transcriptionnels. Pour révéler les structures sous-jacentes dans les données, un double clustering hiérarchique (lignes et colonnes) a été appliqué, utilisant la méthode de Ward et des distances euclidiennes. Les dendrogrammes ainsi générés permettent de regrouper les gènes et les échantillons selon la similarité de leurs profils d'expression, faisant émerger des motifs caractéristiques propres à chaque condition expérimentale.

### 2.2.4 org.Mm.eg.db et AnnotationDbi

L'annotation fonctionnelle des gènes identifiés au cours de nos analyses a été réalisée à l'aide des packages **org.Mm.eg.db** et **AnnotationDbi** (14), qui forment ensemble un cadre puissant pour relier les résultats transcriptomiques à des informations biologiques pertinentes. Le package **org.Mm.eg.db** donne accès à une base de données complète dédiée à la souris (*Mus musculus*), incluant des annotations génétiques standardisées issues notamment du système Entrez Gene du NCBI. Quant à **AnnotationDbi**, il fournit les outils pour interroger ces données de manière flexible. Dans notre pipeline, nous avons utilisé les fonctions `select()` et `mapIds()` pour convertir les identifiants Ensembl (ENSMUSG), obtenus après quantification, en symboles de gènes et identifiants Entrez plus couramment utilisés. Cette étape de conversion est essentielle pour assurer la compatibilité avec d'autres bases de données fonctionnelles et permet d'enrichir nos analyses par l'exploration de voies biologiques, de processus moléculaires et d'interactions génétiques. En contextualisant nos résultats dans les réseaux biologiques connus, nous renforçons la portée interprétative de nos observations transcriptomiques.

### 2.2.5 immunedeconv

L'analyse de déconvolution des populations immunitaires a été implémentée via le package R **immunedeconv** (15), conçu pour estimer la composition cellulaire immunitaire à partir de données transcriptomiques. Notre protocole d'analyse a intégré trois méthodes complémentaires de déconvolution, chacune offrant une perspective distincte sur le microenvironnement immunitaire. La méthode **seq-ImmuCC**, adaptation de CIBERSORT pour l'analyse des échantillons murins, utilise un algorithme de régression par vecteurs de support pour quantifier les proportions relatives de 25 populations immunitaires. L'approche **DCQ** (Digital Cell Quantification) emploie une stratégie de corrélation de signatures géniques spécifiques aux lignées immunitaires pour estimer leur abondance relative. Enfin, **mMCP-counter** (mouse Microenvironment

Cell Population-counter), adaptation murine de MCP-counter, quantifie l'infiltration absolue de populations immunitaires spécifiques dans les échantillons tissulaires. Pour chaque méthode, nous avons utilisé la fonction `deconvolute_mouse()` avec les données d'expression normalisées en TPM (Transcripts Per Million) comme entrée, et le paramètre de méthode approprié (`method = "seq-ImmuCC", "dcq" ou "mmcp_counter"`). Pour `mMCP-counter`, nous avons spécifié le génome de référence murin GRCm39 via l'argument supplémentaire `genome = "GRCm39"`.

Les résultats de chaque analyse ont été transformés en format long (`pivot_longer()`) et enrichis avec les métadonnées expérimentales pour faciliter les visualisations et analyses statistiques subséquentes.

## 2.2.6 Les packages pour les analyses d'enrichissement fonctionnel

### 2.2.6.1 MSigDB

Pour nos analyses d'enrichissement, nous nous sommes appuyés sur les collections de signatures moléculaires de la base MSigDB (20), une ressource centrale pour l'interprétation fonctionnelle des données transcriptomiques. Nous avons notamment utilisé les signatures des "hallmarks" du cancer (collection H), les voies canoniques (C2-CP), les signatures de perturbations génétiques ou chimiques (C2-CGP), ainsi que les ontologies géniques (C5). Cette base de données curatée a fourni le cadre de référence pour toutes nos analyses d'enrichissement fonctionnel décrites ci-dessous.

### 2.2.6.2 clusterProfiler

Pour analyser les implications biologiques des gènes différentiellement exprimés, nous avons utilisé le package `clusterProfiler` (16) avec une approche de sur-représentation (ORA). Notre méthode filtre d'abord les gènes différentiellement exprimés selon des seuils définis d'ajustement de p-valeur (0.05 ; 0.01 ; 0.001) et de log2 fold change (0 ; 0.58 ; 1), puis sépare les résultats en deux catégories : gènes surexprimés (UP) et sous-exprimés (DOWN). Les identifiants Ensembl sont convertis en symboles de gènes pour faciliter l'interprétation biologique. La fonction `enricher()` évalue ensuite si certaines voies biologiques sont statistiquement sur-représentées dans chaque liste de gènes, en utilisant un univers de référence constitué uniquement des gènes codant pour des protéines. Cette méthode est particulièrement efficace pour identifier rapidement les processus biologiques significativement altérés dans les deux directions d'expression, permettant une première interprétation fonctionnelle des résultats transcriptomiques.

### 2.2.6.3 fgsea

En complément de l'analyse ORA, nous avons utilisé le package `fgsea` (*fast Gene Set Enrichment Analysis*) (19) pour évaluer l'enrichissement de signatures fonctionnelles sur l'ensemble du transcriptome. Contrairement à l'approche sélective de l'ORA, notre implémentation de `fgsea` calcule d'abord une statistique de différenciation (*rank list*) basée sur la différence des moyennes d'expression entre conditions, normalisée par la somme des écarts-types. Cette méthode robuste de classement intègre à la fois l'amplitude et la variabilité des changements d'expression. L'algorithme effectue ensuite 10 000 permutations pour évaluer la significativité statistique de l'enrichissement des voies, avec des paramètres optimisés (taille minimale de 15 gènes, maximale de 1000). Cette approche nous a permis de visualiser à la fois les résultats numériques (tableau des voies significativement enrichies classées par p-valeur ajustée) et graphiques (plots d'enrichissement individuels et tableaux récapitulatifs des principales voies),

identifiant ainsi les signatures fonctionnelles positivement ou négativement enrichies dans nos conditions expérimentales.

## 2.2.6.4 GSVA et ssGSEA

Pour évaluer l'activité des voies de signalisation au niveau de chaque échantillon individuel, nous avons utilisé deux méthodes complémentaires : **GSVA** (*Gene Set Variation Analysis*) (17) et **ssGSEA** (*Single Sample Gene Set Enrichment Analysis*) (18). Ces deux approches permettent une analyse non supervisée des signatures géniques, sans nécessiter de comparaison directe entre groupes d'échantillons. Elles transforment la matrice d'expression génique en une matrice de scores d'enrichissement pour chaque combinaison échantillon-voie, bien que leurs algorithmes de calcul diffèrent. GSVA utilise une méthode de densité de Kernel pour estimer les distributions des expressions géniques, tandis que ssGSEA calcule un score distinct en évaluant si les membres d'un ensemble de gènes se retrouvent principalement en haut ou en bas d'une liste de gènes classés par expression. Ces méthodes se sont avérées particulièrement utiles pour identifier des variations subtiles entre les échantillons au sein d'une même condition expérimentale et pour visualiser l'hétérogénéité biologique dans notre jeu de données.

## 2.3 Conception de l'interface intégrée

Cette interface a été implémentée sous forme d'application web interactive via le framework **Shiny**, comme illustré en Figure 2, où l'architecture modulaire permet une navigation intuitive entre les différentes fonctionnalités analytiques, facilitant ainsi l'exploration multidimensionnelle et une progression cohérente dans l'analyse des données transcriptomiques.




FIGURE 2 – Architecture modulaire intégrée de l'interface

La conception de l'outil repose sur un pipeline interactif d'analyse transcriptomique (Fig. 3), structuré en cinq modules complémentaires permettant l'exploration approfondie des données de *bulk RNA-seq*. Le module (1) **Analyse non-supervisée** permet d'extraire les gènes les plus variables au sein d'une sous-cohorte sélectionnée, visualisant la structure globale des données via ACP et clustering hiérarchique, complétés par des enrichissements fonctionnels. Le module (2) **analyse des gènes et signatures transcriptionnelles** facilite l'interrogation de l'expression de gènes spécifiques ou de signatures prédéfinies issues des collections MSigDB, révélant leur comportement selon différentes conditions biologiques. Le module (3)

**Infiltrat tumoral** (déconvolution immunitaire) propose une estimation quantitative de l'infiltration immunitaire à l'aide de trois méthodes de déconvolution : MCPcounter, DCQ et Seq-ImmuCC, avec visualisations par clustering et analyses statistiques appropriées. Le module (4) **Expression différentielle** permet la comparaison entre groupes d'échantillons pour identifier les gènes différentiellement exprimés, avec calcul d'enrichissements et visualisations sous forme de tableaux et heatmaps. Enfin, le module (5) **GSEA** réalise une analyse d'enrichissement dirigée par classement révélant les voies biologiques activées ou réprimées entre conditions expérimentales.




FIGURE 3 – Workflow de l'interface intégrée



### 2.3.1 Module 1 : analyse non-supervisée

Ce module (Fig. 4) se compose de cinq sous-onglets analytiques complémentaires dont l'objectif est de révéler les relations intrinsèques entre échantillons et d'identifier les gènes contribuant significativement à la variabilité observée.

L'onglet *Samples* présente le tableau des échantillons sélectionnés selon les critères de filtrage définis par l'utilisateur, permettant la vérification de la cohorte d'étude avant l'exécution des analyses exploratoires. (i) L'onglet *PCA* fournit une représentation bidimensionnelle des échantillons dans l'espace réduit des composantes principales, structurée en trois parties : un panneau de paramétrage permettant la sélection des axes à visualiser et des variables de stratification, une section présentant des informations quantitatives sur la variance expliquée et les vecteurs propres, et une visualisation interactive de l'analyse en composante principale (ACP) via la bibliothèque *Plotly*. (ii) L'onglet *Heatmap* présente une représentation matricielle des profils d'expression génique avec options de clustering hiérarchique bidimensionnel, facilitant l'identification de sous-groupes d'échantillons présentant des signatures transcriptomiques (clusters) distinctes. (iii) L'onglet *Genes* permet d'identifier les gènes présentant la plus forte variabilité d'expression au sein de la cohorte, en fonction d'un seuil configurable (pourcentage des gènes les plus variables). Cette sélection facilite la mise en évidence des gènes potentiellement pertinents pour la suite de l'étude. (iv) L'onglet *ORA* (Over-Representation Analysis) permet d'identifier les voies biologiques significativement enrichies parmi les clusters de gènes les plus variables préalablement identifiés dans l'onglet *Heatmap*. Les résultats sont présentés sous forme de tableau interactif, facilitant leur exploration et interprétation.




FIGURE 4 – Vue du module dédié à l'analyse non supervisée

### 2.3.2 Module 2 : analyse des gènes et signatures transcriptionnelles

Le module d'analyse des gènes et signatures (Fig. 5) permet l'exploration des profils d'expression au niveau des gènes individuels et des signatures fonctionnelles selon deux axes analytiques complémentaires. L'analyse de l'expression génique propose deux modalités distinctes :

(i) l'exploration *Single Gene* permettant la visualisation précise de l'expression d'un gène spécifique selon diverses variables catégorielles (type cellulaire, génotype ou stade), accompagnée d'analyses statistiques comparatives ; et (ii) l'option *Multiple Genes* autorisant l'analyse comparative simultanée de plusieurs gènes pour identifier des profils d'expression co-régulés ou antagonistes. La section des signatures transcriptionnelles intègre des méthodes d'enrichissement (ssGSEA/GSVA), permettant une analyse fonctionnelle des profils transcriptionnels, avec trois fonctionnalités principales : analyse détaillée d'une signature spécifique sélectionnée parmi diverses collections prédéfinies (Hallmark, C2-CGP, C2-CP, C5), comparaison de multiples signatures pour identifier des processus biologiques coordonnés, et création de signatures personnalisées à partir de listes de gènes utilisateur. Ce module intègre des capacités d'analyse statistique comparative entre groupes expérimentaux, des visualisations interactives optimisées (boîtes à moustaches, Heatmaps), et des fonctionnalités d'exportation des données, son architecture réactive permettant la génération dynamique des résultats selon les paramètres sélectionnés.




FIGURE 5 – Vue du module dédié à l'analyse des gènes et signatures transcriptionnelles

### 2.3.3 Module 3 : Infiltrat tumoral (déconvolution du microenvironnement tumoral)

Le module de déconvolution du microenvironnement tumoral (Fig. 6) implémente trois méthodologies complémentaires pour l'estimation quantitative de la composition cellulaire du microenvironnement tumoral à partir des données d'expression globale, permettant l'inférence des proportions de sous-populations leucocytaires et stromales in situ sans analyses cytométriques additionnelles. L'interface principale présente trois approches méthodologiques distinctes : (i) *mMCP-counter* (Marker-based Molecular Cell Phenotyping) (21) basée sur l'expression spécifique de marqueurs cellulaires, avec quatre modalités de visualisation : boîtes à moustaches comparant les distributions des populations entre conditions, Heatmap illustrant le clustering des populations immunitaires, tableau des scores calculés, et accès aux listes de gènes marqueurs ; (ii) *DCQ* (Deconvolution-based Cell Quantification) (22) utilisant une approche de déconvolution mathématique des signatures cellulaires, implémentant une structure analytique



similaire avec visualisations par boîtes à moustaches, heatmap, et une présentation de la table listant les gènes définissant chaque population immunitaire; et (iii) *seq-ImmuCC* (Single-cell Expression-based Immune Cell Classification) (23) développée à partir de données transcriptomiques unicellulaires, proposant une exploration multidimensionnelle via des boîtes à moustaches avec analyses statistiques comparatives, des diagrammes à barres par échantillon, des visualisations agrégées par génotype et stade, et un accès aux données quantitatives. Le module est complété par une section *Comparaison* permettant une évaluation méthodologique croisée en juxtaposant les estimations générées par les trois approches pour une population immunitaire sélectionnée, facilitant l'identification des concordances et divergences méthodologiques et renforçant la robustesse des conclusions biologiques.




FIGURE 6 – Vue du module dédié à la déconvolution de microenvironnement tumoral

### 2.3.4 Module 4 : analyse d'expression différentielle

Le module d'analyse d'expression différentielle (DE) (Fig. 7) permet d'identifier et d'étudier les gènes dont l'expression varie entre différentes conditions expérimentales. Il couvre l'ensemble du processus, depuis la sélection des échantillons jusqu'à l'interprétation des résultats. L'onglet **Samples** présente, sous forme de tableau, les échantillons sélectionnés pour l'analyse d'expression différentielle, en tant que contrôles ou conditions d'intérêt. La représentation en *Volcano Plot* permet de visualiser l'ensemble des gènes analysés, classés selon leur niveau de régulation (up-régulés, down-régulés ou non significatifs), en fonction des seuils choisis par l'utilisateur, de  $\log_2$  fold-change (0 ; 0.58 ; 1) et de significativité statistique (p-value : 0.05 ; 0.01 ; 0.001).

L'onglet **Genes Table** affiche les résultats statistiques détaillés sous forme de tableau, incluant les valeurs d'expression normalisées, les  $\log_2$  fold-changes et les p-values ajustées, ce qui facilite l'identification des gènes d'intérêt en vue de validations fonctionnelles ou expérimentales ultérieures.

L'onglet **Heatmap** propose plusieurs visualisations complémentaires des profils d'expression des gènes différentiellement exprimés : projetés (i) sur les échantillons utilisés pour l'analyse différentielle, (ii) sur l'ensemble de la cohorte, ou (iii) spécifiquement sur la population neutro-

philique.

La partie **analyses d'enrichissement fonctionnel** intègre deux approches complémentaires d'interprétation biologique : l'onglet **ORA** (*Over-Representation Analysis*) (16), qui évalue statistiquement la sur-représentation des gènes différentiellement exprimés dans des voies biologiques définies ; et le module (5) **GSEA** (*Gene Set Enrichment Analysis*) (18), qui examine la distribution de l'ensemble des gènes de la matrice d'expression, indépendamment de leur statut « différentiellement exprimé ». Ces analyses peuvent être appliquées à diverses collections de signatures moléculaires (*Hallmark*, *C2-CGP*, *C2-CP*, *C5*) (20), avec des visualisations graphiques des voies enrichies et des représentations détaillées des profils d'enrichissement individuels.




FIGURE 7 – Vue du module dédié à l'analyse d'expression différentielle

## 3 Résultats : exemple de bioanalyse

### 3.1 Question scientifique

A partir de notre interface, nous explorons les gènes et voies moléculaires spécifiques aux neutrophiles et aux cellules épithéliales au cours des différents stades de la progression tumorale.

L'objectif était d'identifier les signatures transcriptionnelles propres à ces populations cellulaires et de comprendre leur dynamique évolutive, depuis les stades précoces jusqu'aux stades tardifs. Cette approche visait à caractériser les particularités moléculaires et fonctionnelles de ces cellules dans le contexte du cancer du sein, afin de mieux comprendre leur rôle dans la tumorigenèse.

## 3.2 Analyse exploratoire de la variabilité globale de données transcriptomiques du modèle MMTV-Neu

Dans un premier temps, une analyse exploratoire a été menée afin d'évaluer la variabilité globale des profils transcriptomiques, sans *a priori* sur les types cellulaires, à l'aide d'approches complémentaires d'analyse multidimensionnelle. Une analyse en composantes principales (ACP) ainsi qu'un clustering hiérarchique ont été réalisés sur les 10 % des gènes présentant la plus forte variance d'expression sur l'ensemble de la cohorte (Fig. 8).




FIGURE 8 – Visualisations exploratoires basées sur les 10 % de gènes les plus variables dans l'ensemble de la cohorte ( $n = 71$  échantillons) : (a) analyse en composantes principales (ACP), (b) Heatmap.

L'ACP (Fig. 8a) révèle une structuration majeure des données selon le type cellulaire. La première composante principale (PC1, 64,1% de la variance) distingue clairement les neutrophiles (issus du sang, de la moelle osseuse et de la glande mammaire) des échantillons épithéliaux et de la glande mammaire totale, reflétant des programmes transcriptionnels fondamentalement distincts. La seconde composante (PC2, 11,8% de la variance) représente essentiellement la composition tissulaire et le contexte d'infiltration neutrophilique. Elle distingue principalement les échantillons **Bulk** (en haut) des échantillons **Epi** (en bas). On observe également une séparation entre les neutrophiles infiltrant la glande mammaire (**Neutro\_MG.tum**, partie supérieure) et les neutrophiles circulants ou médullaires (**Neutro\_Blood** et **Neutro\_BM**, partie inférieure). Les neutrophiles infiltrants de la glande mammaire (**Neutro\_MG**) non tumorale présentent un profil intermédiaire, situé entre les neutrophiles non-infiltrants (**Neutro\_Blood** et **Neutro\_BM**) et les neutrophiles infiltrants la tumeur (**Neutro\_MG.tum**) suggérant une transition progressive de leur état transcriptionnel. Cette représentation bidimensionnelle met en évidence l'évolution transcriptomique associée à la progression tumorale dans notre modèle transgénique (MMTV-Neu). Cette analyse comparative multi-compartmentale (glande mammaire, sang, moelle osseuse) fournit une vision intégrée des signatures moléculaires spécifiques au contexte tissulaire et au stade de progression tumorale dans le cancer du sein.

La heatmap (Fig. 8b) et le clustering hiérarchique associé, également réalisés sur les 10% de gènes les plus variables corroborent notre analyse en composantes principales en révélant trois clusters transcriptionnels fonctionnellement distincts. Le clustering des échantillons confirme la dichotomie fondamentale entre compartiment neutrophilique et compartiment épithélial **Epi/Bulk** précédemment identifiée par l'ACP.

Le **cluster A** (668 gènes)(Fig. 8b), surexprimé dans les neutrophiles indépendamment de leur origine tissulaire (sang, moelle osseuse ou glande mammaire), représente la signature moléculaire caractéristique de ces cellules immunitaires, comprenant vraisemblablement des gènes impliqués dans les fonctions immunitaires spécifiques aux neutrophiles.

Le **cluster C** (1163 gènes)(Fig. 8b), est spécifiquement surexprimé dans les échantillons **Bulk** et épithéliaux **Epi**, relatif à des fonctions épithéliales fondamentales comme l'adhésion cellulaire et la signalisation hormonale. Le **cluster B** (323 gènes)(Fig. 8b) présente un profil d'expression modulé selon le stade de progression tumorale, avec des variations d'expression spécifiques dans les neutrophiles de la glande mammaire tumorale et non tumorale. Ce cluster B présente aussi une surexpression au niveau des tissus mammaires totaux (**Bulk** tumoraux et non tumoraux). Ce cluster particulièrement informatif capture vraisemblablement les altérations transcriptionnelles associées à l'oncogenèse et au remodelage du microenvironnement tumoral.

Le clustering hiérarchique au sein du tissu mammaire révèle également une distinction entre les échantillons épithéliaux purifiés **Epi** et les tissus mammaires totaux (**Bulk**), soulignant l'influence de l'hétérogénéité cellulaire sur les profils d'expression observés.


Ces analyses complémentaires mettent en évidence que la variabilité transcriptomique est principalement structurée par l'identité cellulaire. Elles révèlent également des adaptations moléculaires spécifiques liées aux contextes tissulaire et tumoral. En particulier, les neutrophiles infiltrant le microenvironnement tumoral présentent une signature transcriptionnelle distincte, suggérant une reprogrammation fonctionnelle de ces cellules myéloïdes sous l'influence des signaux émis par la tumeur.

### 3.3 Spécificité transcriptionnelle des neutrophiles selon leur localisation et le stade tumoral

Après avoir caractérisé les grands axes de variation transcriptomique entre les différents types cellulaires(Fig. 8), nous nous focalisons à présent sur les populations de neutrophiles, indépendamment de leur localisation et du stade tumoral.

L'analyse en composantes principales (Fig. 9a) réalisée exclusivement sur les 10% des gènes les plus variants parmi les profils transcriptionnels des neutrophiles révèle une hétérogénéité transcriptomique substantielle au sein de cette population leucocytaire. L'axe PC1 (30,6 %) sépare nettement les neutrophiles en fonction de leur origine tissulaire, distinguant les cellules provenant du sang et de la moelle osseuse (*Neutro\_Blood*, *Neutro\_BM*) de celles infiltrant la glande mammaire (*Neutro\_MG*). On observe également que l'extrémité droite de l'axe PC1 est principalement occupée par les échantillons issus de glandes mammaires tumorales (*Neutro\_MG.tum*), suggérant que cet axe reflète également, dans une certaine mesure, le stade tumoral. L'axe PC2 (21,4 %) différencie plutôt le statut de maturation des neutrophiles, séparant les neutrophiles immatures de la moelle osseuse (BM) des neutrophiles matures circulants (Blood) et tissulaires (MG). Ces résultats suggèrent que l'environnement tissulaire est le principal déterminant du programme transcriptionnel des neutrophiles, mais que la progression tumorale dans le modèle NeuT induit également des modifications systémiques. La continuité des points entre les neutrophiles du sang (*Neutro\_Blood*) et ceux de la glande mammaire





(a) Analyse en composantes principales (ACP).

(b) Clustering hiérarchique (heatmap).

FIGURE 9 – Exploration des profils transcriptomiques des neutrophiles à partir des 10% de gènes les plus variables.

(*Neutro\_MG*) suggère une transition progressive de leur état transcriptionnel. Cette continuité reflète très probablement un processus biologique progressif, impliquant le recrutement des neutrophiles vers le tissu tumoral, l'induction de modifications transcriptionnelles par le microenvironnement tumoral, ainsi que leur plasticité fonctionnelle en particulier la transition potentielle entre des phénotypes **N1** (anti-tumoraux) et **N2** (pro-tumoraux) au cours de la progression tumorale.

La heatmap (Fig. 9b) des 10% de gènes les plus variables chez les neutrophiles met en évidence quatre grands clusters de gènes (A–D). Ces résultats complètent les observations issues de l'ACP (Fig. 9a) en confirmant la spécificité transcriptionnelle des neutrophiles selon leur localisation tissulaire et leur niveau de maturation.

Le **cluster A** (173 gènes) caractérise des profils intermédiaires, situés transcriptionnellement entre les neutrophiles circulants (*Neutro\_Blood*) et ceux infiltrant la glande mammaire. Ce cluster reflète vraisemblablement un état de transition associé au recrutement tumoral des neutrophiles, comme le suggère la continuité observée sur l'ACP (Fig. 9a). Cette continuité reflète très probablement un processus biologique progressif, impliquant le recrutement des neutrophiles vers le tissu tumoral, ainsi que l'induction de modifications transcriptionnelles sous l'influence du microenvironnement tumoral.

Le **cluster B** (1092 gènes)(Fig. 9b), qui contient la majorité des gènes variables, montre une expression modulée selon le type cellulaire, le stade tumoral et le génotype. Son expression est plus accentuée dans les neutrophiles de la glande mammaire tumorale, modérée dans la moelle osseuse, et quasi absente dans le sang. Cette distribution suggère une reprogrammation spécifique et progressive des neutrophiles infiltrant le tissu tumoral, en réponse au microenvironnement tumoral.

Le **cluster C** (404 gènes)(Fig. 9b) est principalement exprimé dans les neutrophiles issus de la moelle osseuse (*Neutro\_BM*), reflétant un programme transcriptionnel propre aux neutrophiles immatures, en accord avec leur localisation dans le siège de l'hématopoïèse.

Enfin, le **cluster D** (485 gènes)(Fig. 9b) est fortement exprimé dans les neutrophiles infiltrant la glande mammaire (*Neutro\_MG*), qu'elle soit tumorale ou non, avec une intensité

accentuée au stade tardif (**Neutro\_MG.tum**). Cette signature distingue clairement ces neutrophiles de ceux des compartiments médullaire(immatures) et sanguin(matures), en accord avec leur position extrême sur l'axe PC1 de l'ACP(Fig. 9a).

Ces signatures distinctes mettent en évidence une forte hétérogénéité transcriptionnelle au sein des neutrophiles et confirment l'influence déterminante de l'environnement tissulaire et tumoral sur leur identité moléculaire.

### 3.4 Analyse des voies enrichies parmi les gènes du cluster D

Pour caractériser les fonctions biologiques associées au **cluster D** (Fig. 9b), une première étape a consisté à réaliser une analyse de sur-représentation fonctionnelle (ORA) sur les gènes de cette signature. L'enrichissement a été évalué à l'aide de la collection de gènes "HALLMARK" issus de MSigDB (20), permettant d'identifier les principales voies activées dans ce groupe.




FIGURE 10 – Top 10 des voies fonctionnelles enrichies parmi les gènes du **cluster D**, identifiées par analyse de sur-représentation (ORA) à partir de la collection de signatures moléculaires *HALLMARK*.

L'analyse de sur-représentation (ORA) (Fig. 10) a révélé un enrichissement significatif de voies biologiques impliquées dans des processus immunitaires et inflammatoires parmi les gènes du **cluster D**. Notamment, la voie de signalisation *TNF $\alpha$  via NF- $\kappa$ B* (p.adjust = 9.5e-23) se distingue comme la plus significative. D'autres voies fortement enrichies comprennent la *réponse inflammatoire*, la *signalisation IL6-JAK-STAT3* et *IL2-STAT5* (24), toutes impliquées dans l'activation et la différenciation des cellules immunitaires. De plus, des signatures associées à l'immunité innée, telles que la voie du *complément* ou la *réponse à l'interféron  $\alpha$* , ainsi que des processus liés au microenvironnement tumoral (signalisation *KRAS*, transition épithélio-mésenchymateuse, *coagulation*), sont également sur-représentées (4). Ces observations suggèrent



que le **cluster D** reflète un programme transcriptionnel fortement orienté vers l'inflammation et l'immunité innée.

### 3.4.1 Représentation des scores d'enrichissement ssGSEA pour les voies inflammatoires et immunitaires

Après avoir identifié les voies biologiques significativement enrichies au sein du **cluster D**, nous avons poursuivi l'analyse en examinant leur expression fonctionnelle au niveau des différents types de neutrophiles. Nous avons cherché à explorer le lien entre ces signatures enrichies et les différents types de neutrophiles. Pour ce faire, une analyse ssGSEA a été conduite pour les quatre voies les plus représentatives de l'enrichissement observé (Fig. 10). Cette approche permet d'évaluer le niveau d'activation de chaque voie à l'échelle individuelle pour chaque type cellulaire.




FIGURE 11 – Scores ssGSEA pour les quatre voies les plus enrichies identifiées dans le **cluster D**.

Les résultats obtenus (Fig. 11) mettent en évidence des différences marquées entre les types cellulaires et des profils d'expression similaires deux à deux par rapport à ces voies. Les neutrophiles infiltrant la glande mammaire tumorale (*Neutro\_MG.tum*) présentent une signature transcriptionnelle distincte, caractérisée par une activation significative des voies inflammatoires et immunitaires. En particulier, les voies  $TNF\alpha$  via  $NF-\kappa B$  et  $IL6$ - $JAK$ - $STAT3$  montrent des scores nettement plus élevés chez *Neutro\_MG.tum*, suggérant une activation intense de ces programmes transcriptionnels associés à la signalisation pro-inflammatoire et à l'immunosuppression(37).

Les voies du *complément* et *INFLAMMATORY\_RESPONSE* suivent une tendance similaire, indiquant une activation coordonnée des mécanismes de l'immunité innée et de la réponse inflammatoire au sein du microenvironnement tumoral (35). À l'inverse, les neutrophiles issus

du sang (*Neutro\_Blood*) et de la moelle osseuse (*Neutro\_BM*) présentent des scores plus faibles et homogènes, caractéristiques d'une moindre activation transcriptionnelle.

Ces résultats semblent confirmer l'hypothèse selon laquelle les neutrophiles associés à la tumeur (TANs) subissent une reprogrammation transcriptionnelle influencée par le microenvironnement tumoral, adoptant un profil potentiellement pro-tumoral (N2).

### 3.4.2 Analyse de l'expression des gènes impliqués dans la signalisation $TNF\alpha/NF-\kappa B$

Afin de mieux comprendre le rôle de la voie  $TNF\alpha$  via  $NF-\kappa B$  dans l'activation des neutrophiles tumoraux, nous avons approfondi l'analyse de cette signature spécifique. Cette voie se distingue par son enrichissement particulièrement significatif ( $p.adjust = 9.5e-23$ ) et un Rich Factor élevé (0.220), indiquant une forte implication de gènes du **cluster D** dans ce programme transcriptionnel.


Dans la littérature scientifique, la voie  $TNFA\_SIGNALING\_VIA\_NFkB$  est contrôlée par le facteur de transcription  $NF-\kappa B$  en réponse au  $TNF\alpha$ , un médiateur clé de l'inflammation (36). Dans les neutrophiles, cette signalisation régule l'activation cellulaire, la production de cytokines pro-inflammatoires ( $IL-1\beta$ ,  $TNF\alpha$ ,  $CXCL1$ ,  $CXCL2$ ), ainsi que leur survie prolongée en contexte tumoral ou inflammatoire (25).

Ces observations bibliographiques corroborent nos résultats d'analyse ORA (Fig. 10) qui ont également mis en évidence une sur-représentation significative de cette voie dans les neutrophiles associés aux tumeurs. Parmi les gènes enrichis de la voie de signalisation  $TNF\alpha$  via  $NF-\kappa B$ , nous avons identifié plusieurs catégories fonctionnelles importantes. Les chimiokines  $Cxcl1$  et  $Cxcl2$  sont impliquées dans le recrutement des neutrophiles et l'amplification de l'inflammation locale (37), tandis que  $Ccl2$  et  $Ccl5$  participent au recrutement d'autres populations immunitaires (26). Les cytokines pro-inflammatoires  $Tnf$  et  $Il1a$  figurent également parmi les gènes enrichis comme médiateurs majeurs de la réponse inflammatoire.

La survie prolongée des neutrophiles, caractéristique essentielle des TANs, est représentée dans nos résultats par l'enrichissement des gènes anti-apoptotiques  $Bcl2a1a/b/d$  et de l'enzyme antioxydante  $Sod2$  (27). Les régulateurs de la voie  $NF-\kappa B$ ,  $Nfkb1a$  et  $Tnfai3$  (A20), sont également enrichis et servent d'indicateurs de l'activation et du rétrocontrôle de cette cascade. Enfin, les molécules d'activation et d'adhésion  $Cd83$ ,  $Cd69$  et  $Sdc4$ , ainsi que les facteurs de transcription  $Atf3$  et  $Nr4a1$ , complètent cette signature enrichie et reflètent les interactions cellulaires et la réponse au stress dans le microenvironnement tumoral (34).

Sur cette base, nous avons sélectionné plusieurs gènes candidats afin de caractériser plus finement le phénotype des neutrophiles infiltrant la glande mammaire. Nous avons particulièrement ciblé deux catégories fonctionnelles clés, représentées sous forme de boxplots : les cytokines et régulateurs de la voie  $TNF/NF-\kappa B$  ( $Tnf$ ,  $Il1a$ ,  $Nfkb1a$ ,  $Tnfai3$ ), ainsi que les gènes anti-apoptotiques et de survie ( $Bcl2a1a$ ,  $Bcl2a1b$ ,  $Bcl2a1d$ ,  $Sod2$ ).

L'analyse de l'expression des cytokines et chimiokines pro-inflammatoires (Fig. 12a) révèle une activation transcriptionnelle marquée des neutrophiles infiltrant les glandes mammaires tumorales. En particulier, les chimiokines  $Cxcl1$  et  $Cxcl2$ , connues pour leur rôle central dans le recrutement des neutrophiles via le récepteur CXCR2 (37), présentent une surexpression significative dans les neutrophiles tumoraux (*Neutro\_MG.tum*), suggérant une amplification de la signalisation pro-inflammatoire dans le microenvironnement tumoral. De même, le facteur de nécrose tumorale  $Tnf$ , cytokine pivot de la cascade inflammatoire, est fortement exprimé dans les neutrophiles associés à la tumeur, renforçant l'hypothèse d'une activation de la voie  $TNF/NF-\kappa B$  dans ces cellules (38). En revanche, l'expression de  $Il1b$  ne montre pas de différence statistiquement significative entre les deux contextes tissulaires, suggérant une régulation plus contextuelle ou post-transcriptionnelle de cette cytokine (39). Dans l'ensemble, ces ré-



(a) Cytokines et chimiokines pro-inflammatoires

(b) Gènes de survie anti-apoptotiques

FIGURE 12 – Analyse comparative de l'expression génique dans les neutrophiles infiltrant les glandes mammaires normales (*Neutro\_MG*) et tumorales (*Neutro\_MG.tum*) : (a) cytokines et chimiokines pro-inflammatoires, (b) gènes de survie anti-apoptotiques.

sultats indiquent une reprogrammation des neutrophiles vers un phénotype pro-inflammatoire dans le tissu tumoral, susceptible de moduler les interactions cellulaires et de contribuer à la progression tumorale.

L'analyse de l'expression des gènes de survie anti-apoptotiques (Fig. 12b) met en évidence une induction significative dans les neutrophiles infiltrant les glandes mammaires tumorales. Les trois isoformes du gène *Bcl2a1* (*Bcl2a1a*, *Bcl2a1b*, *Bcl2a1d*), membres de la famille Bcl-2 connus pour leur fonction anti-apoptotique (40), montrent une surexpression marquée dans les neutrophiles tumoraux (*Neutro\_MG.tum*) par rapport à ceux provenant de tissus non tumoraux. De même, *Sod2*, gène codant pour la superoxyde dismutase mitochondriale impliquée dans la détoxification des espèces réactives de l'oxygène (41), est également significativement induit dans le contexte tumoral. Cette activation coordonnée de gènes anti-apoptotiques favorisant la survie suggère que les neutrophiles résistent mieux au stress oxydatif et persistent plus longtemps dans le microenvironnement tumoral. Cette sélection de gènes nous a permis d'établir une signature moléculaire caractéristique des neutrophiles associés aux tumeurs dans notre modèle MMTV-Neu. L'activation conjointe des voies pro-inflammatoires et anti-apoptotiques suggère une reprogrammation fonctionnelle favorisant à la fois l'amplification de la réponse inflammatoire locale et la persistance prolongée des neutrophiles dans le microenvironnement tumoral (26).

### 3.5 Analyse de l'expression différentielle : Neutrophiles de la glande mammaire tumorale versus non tumorales

L'analyse différentielle d'expression a été réalisée à l'aide du package DESeq2, en comparant les échantillons de neutrophiles infiltrant la glande mammaire tumorale en stade tardif (NeuT\_Late\_Neutro\_MG.tum) avec un groupe de référence. Ce groupe de référence était constitué de neutrophiles issus de glandes mammaires non tumorales dans deux conditions : les neutrophiles contrôles (CTR\_Early\_Neutro\_MG et CTR\_Late\_Neutro\_MG) et les neutrophiles isolés de glandes mammaires exprimant l'oncogène NeuT (NeuT\_Early\_Neutro\_MG) en stade précoce. L'inclusion des neutrophiles NeuT\_Early\_Neutro\_MG dans le groupe de référence se justifie par leur profil transcriptomique encore très similaire aux neutrophiles contrôles,

comme le démontrent les analyses non supervisées (Fig. 8), indiquant qu'ils n'ont pas encore acquis les caractéristiques des neutrophiles associés aux tumeurs établies.

Le seuil de significativité a été fixé à une valeur ajustée de  $p < 0.05$  avec un seuil de  $\log_2$  Fold Change ( $\log_2 FC$ ) fixé à 0. Cette analyse a permis d'identifier **1 281 gènes différentiellement exprimés**, parmi lesquels **813 gènes sont sur-exprimés** et **468 sont sous-exprimés** dans les neutrophiles tumoraux tardifs par rapport au groupe de référence (Fig. 13).




FIGURE 13 – Volcano plot des gènes différentiellement exprimés entre les neutrophiles tumoraux tardifs et le groupe de référence

L'ensemble de ces données transcriptomiques démontre que les neutrophiles subissent une profonde transformation dans le contexte tumoral, acquérant un phénotype distinct de celui observé dans les tissus sains, et potentiellement impliqué dans la promotion tumorale (3).

### 3.5.1 Analyse de sur-représentation de la voie $TNF\alpha/NF-\kappa B$ à partir des 813 gènes surexprimés

L'analyse par sur-représentation (ORA)(Fig. 14) réalisée sur les 813 gènes surexprimés dans les neutrophiles infiltrant les tumeurs mammaires avancées révèle un enrichissement significatif de la voie **HALLMARK\_TNFA\_SIGNALING\_VIA\_NFKB** ( $p_{\text{adjust}} = 4,77 \times 10^{-8}$ ).

Cette voie présente un facteur d'enrichissement (richFactor) de 0,127, avec 31 gènes différentiellement exprimés appartenant à cette voie canonique qui comprend 245 gènes au total sur les 21 147 de l'univers de référence.

Il est intéressant de noter que cette même voie était également fortement enrichie dans notre analyse du **cluster D** lors de l'analyse exploratoire (Fig. 10), avec un enrichissement significatif ( $p_{\text{adjust}} = 9,5e-23$ ) et un Rich Factor plus élevé (0,220). Cette concordance entre les deux analyses indépendantes renforce la robustesse de nos résultats et souligne l'importance centrale de cette voie de signalisation dans la reprogrammation des neutrophiles tumoraux.

Parmi les gènes surexprimés figurent plusieurs qui étaient également identifiés dans l'analyse du **cluster D**, notamment : des cytokines pro-inflammatoires (*Tnf*, *Il1a*), des chimiokines (*Cxcl1*, *Cxcl10*, *Ccl4*), des régulateurs anti-apoptotiques (*Bcl2a1a/b/d*, *Cflar*), des acteurs directs de la signalisation  $NF-\kappa B$  (*Nfkb1*, *Tank*), ainsi que des facteurs de transcription et de réponse immunitaire (*Ifi2*, *Ifi3*, *Id2*, *Nr4a2*, *Nr4a3*, *Tgfb1*, *Cd69*). Cette signature transcrip-




FIGURE 14 – Analyse de sur-représentation de la voie  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  à partir des 813 gènes surexprimés

tionnelle cohérente témoigne d’une activation avérée des voies pro-inflammatoires dans les neutrophiles du microenvironnement tumoral.

L’activation de cette voie  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  dans les neutrophiles infiltrant les tumeurs corrobore les données de la littérature sur l’implication de  $\text{NF-}\kappa\text{B}$  dans la polarisation des neutrophiles vers un phénotype pro-tumoral (26; 31). Ce rôle central de  $\text{NF-}\kappa\text{B}$  dans les réponses inflammatoires des neutrophiles a également été décrit dans divers contextes pathologiques (28; 30), soulignant la conservation de ce mécanisme fondamental de régulation inflammatoire.

En conclusion, nos analyses transcriptomiques convergent vers l’identification de la voie  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  comme un axe majeur de la reprogrammation des neutrophiles dans le microenvironnement tumoral mammaire, favorisant à la fois leur survie prolongée et leur fonction pro-inflammatoire.

### 3.5.2 Analyse GSEA (Gene Set Enrichment Analysis) de la voie $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$

L’analyse GSEA (Gene Set Enrichment Analysis) réalisée pour la signature la  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  (Fig. 15) confirme l’activation transcriptionnelle significative de cette voie inflammatoire chez les neutrophiles infiltrant la glande mammaire tumorale au stade tardif. Le profil de la courbe d’enrichissement montre un score maximal positionné en tête de classement, avec un score d’enrichissement normalisé (NES) de 1,6 (p.adjust = 0,0007), pour un ensemble de 238 gènes. Cette distribution non aléatoire indique que les gènes de cette voie sont fortement surexprimés dans les neutrophiles tumoraux comparativement au groupe de référence. La densité importante des gènes de la signature parmi les premiers rangs du classement par expression différentielle, associée à un score d’enrichissement dépassant clairement les seuils de significativité statistique, démontre une activation robuste et coordonnée de la signalisation  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  dans le contexte tumoral. Ces résultats, obtenus par une méthode prenant en compte l’intégralité du transcriptome sans sélection préalable de gènes différentiellement exprimés, renforcent considérablement nos observations précédentes et confirment le rôle primordial de cette voie





FIGURE 15 – Analyse d’enrichissement GSEA de la voie  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  dans les neutrophiles tumoraux comparés au groupe de référence

dans la reprogrammation des neutrophiles associés aux tumeurs mammaires.

L’ensemble des résultats issus des analyses DESeq2, ORA et GSEA convergent vers une conclusion cohérente : les neutrophiles infiltrant la glande mammaire tumorale au stade tardif présentent une activation significative de la voie de signalisation  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$ . Cette reprogrammation transcriptionnelle se manifeste par la surexpression coordonnée de multiples effecteurs de cette cascade, incluant des cytokines pro-inflammatoires, des chimiokines, des régulateurs anti-apoptotiques et des facteurs de transcription spécifiques. La concordance des résultats obtenus par deux approches méthodologiques complémentaires : l’analyse non supervisée (comprenant l’analyse exploratoire, l’expression génique et les signatures transcriptomiques) et l’analyse supervisée (comprenant l’identification de gènes différentiellement exprimés (DESeq2), l’analyse de sur-représentation fonctionnelle (ORA) et l’analyse d’enrichissement de signatures géniques (GSEA)) onsolide la solidité de cette conclusion. Cette activation de la voie  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  apparaît comme un mécanisme central dans l’adaptation fonctionnelle des neutrophiles au microenvironnement tumoral, favorisant à la fois leur survie prolongée et leur phénotype pro-inflammatoire, deux caractéristiques potentiellement impliquées dans la progression tumorale.

## 4 Discussion et perspectives

L’analyse transcriptomique est aujourd’hui incontournable pour comprendre les mécanismes moléculaires associées à la progression tumorale. Dans ce contexte, notre interface Shiny dédiée à l’analyse de données bulk RNA-seq a permis d’identifier une signature moléculaire significative dans les neutrophiles associés aux tumeurs mammaires.

Notre application représente un véritable atout pour les biologistes en proposant une solution simple, automatisée et interactive, qui vient répondre à un besoin concret. Elle reprend et formalise des analyses qui, jusqu’ici, étaient réalisées manuellement par l’équipe bioinformatique de la plateforme Gilles Thomas.

Grâce à cet outil, nous avons pu mettre en évidence que la signature inflammatoire  $\text{TNF}\alpha/\text{NF-}\kappa\text{B}$  joue un rôle prépondérant dans la reprogrammation des neutrophiles au sein du microenvironnement tumoral. Cette voie de signalisation pourrait contribuer à la progression tumorale via plusieurs mécanismes complémentaires : production de médiateurs inflammatoires, sécrétion de chimiokines pro-tumorales, modulation de l’immunité anti-tumorale, promotion de l’angiogénèse et soutien aux processus métastatiques (35). L’activation de cette voie semble ainsi favoriser un phénotype de neutrophile pro-tumoral, caractérisé par une survie prolongée et des

fonctions immunomodulatrices spécifiques.

L'application se distingue par son accessibilité, son *workflow* analytique intégré et ses visualisations interactives, permettant l'identification de mécanismes transcriptionnels via la réalisation successive d'analyses non supervisées et supervisées. Les perspectives d'évolution de l'outil développé dans le cadre de cette alternance comprennent, entre autres, la généralisation de l'interface (développement en cours) afin de permettre l'analyse d'autres jeux de données, qu'ils soient d'origine murine ou humaine, ainsi que la mise en place d'une version web collaborative destinée à faciliter le partage, la reproductibilité et la réutilisation des analyses entre équipes de recherche.

À terme, cet outil pourrait contribuer significativement à l'identification de biomarqueurs, à la médecine de précision, au repositionnement médicamenteux et à la modélisation de la progression tumorale. Son perfectionnement continu, guidé par les besoins de la plateforme Gilles Thomas et les avancées technologiques en bio-informatique, pourrait en faire un instrument clé dans la recherche oncologique fondamentale et clinique, renforçant ainsi le continuum entre découverte fondamentale et application thérapeutique.

## 5 Conclusion

Au cours de cette alternance, nous avons conçu et développé avec succès une interface interactive, basée sur le framework Shiny, dédiée à l'analyse transcriptomique de données bulk RNA-seq. Cette interface, pensée pour et avec les biologistes, propose une navigation intuitive à travers différents modules d'analyse, allant de la visualisation des données (volcano plots, heatmaps, boxplots, tableaux interactifs...) jusqu'à l'exploration fonctionnelle via des méthodes d'enrichissement fonctionnel complémentaires (ORA, GSEA, ssGSEA, GSVA).

Le développement de cette application a exigé une compréhension poussée des concepts d'analyses non-supervisée et différentielle, des approches d'enrichissement fonctionnel, ainsi qu'une maîtrise du langage R et du framework Shiny pour le développement d'interfaces web dynamiques. En automatisant des analyses auparavant réalisées manuellement par la plateforme bioinformatique Gilles Thomas, l'outil permet désormais aux biologistes de réaliser leurs analyses de manière autonome, répétable et plus réactive.

Cette interface s'inscrit dans une démarche d'accessibilité des outils bioinformatiques, en donnant aux chercheurs la possibilité de formuler, tester et affiner leurs hypothèses directement à partir de leurs données, sans dépendre systématiquement d'une expertise technique externe. L'extension en cours de l'outil aux données humaines ouvre par ailleurs la voie à son application en recherche clinique et translationnelle, où l'agilité dans l'analyse est un véritable enjeu.

En somme, cet outil constitue une contribution concrète à l'interface entre biologie et bioinformatique. En facilitant l'analyse et l'interprétation de données transcriptomiques complexes, il offre aux équipes de recherche une solution à la fois puissante et accessible. À l'avenir, son évolution guidée par les retours utilisateurs pourrait en faire un levier essentiel pour l'étude des cellules au sein du microenvironnement tumoral et l'identification de nouvelles pistes thérapeutiques dans le cancer du sein et au-delà.

## 6 Annexes

TABLE 1 – Packages R utilisés et leurs versions

| Package         | Version |
|-----------------|---------|
| shiny           | v1.9.1  |
| bslib           | v0.8.0  |
| shinydashboard  | v0.7.2  |
| shinycssloaders | v1.1.0  |
| shinyWidgets    | v0.8.7  |
| DT              | v0.33   |
| dplyr           | v1.1.4  |
| tidyverse       | v2.0.0  |
| stringr         | v1.5.1  |
| plyr            | v1.8.9  |
| magrittr        | v2.0.3  |
| readr           | v2.1.5  |
| ggplot2         | v3.5.1  |
| plotly          | v4.10.4 |
| patchwork       | v1.3.0  |
| ggrepel         | v0.9.6  |
| scales          | v1.3.0  |
| pheatmap        | v1.0.12 |
| RColorBrewer    | v1.1.3  |
| gridExtra       | v2.3    |
| DESeq2          | v1.44.0 |
| tximport        | v1.32.0 |
| ComplexHeatmap  | v2.20.0 |
| circlize        | v0.4.16 |
| org.Mm.eg.db    | v3.19.1 |
| AnnotationDbi   | v1.66.0 |
| EnhancedVolcano | v1.22.0 |
| clusterProfiler | v4.12.6 |
| ExperimentHub   | v2.12.0 |
| GSEABase        | v1.66.0 |
| GSVA            | v1.52.3 |
| fgsea           | v1.30.0 |
| immunedeconv    | v2.1.0  |
| msigdb          | v7.5.1  |
| msigdb          | v1.12.0 |
| parallel        | v4.4.1  |
| BiocParallel    | v1.38.0 |
| stats           | v4.4.1  |
| factoextra      | v1.0.7  |
| matrixStats     | v1.5.0  |

## 7 Bibliographie

### Références

- [1] Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global Cancer Statistics 2020 : GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA : A Cancer Journal for Clinicians*, 71(3), 209–249.
- [2] World Health Organization. (2021). Breast cancer. <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>
- [3] Shaul, M. E., & Fridlender, Z. G. (2020). Tumor-associated neutrophils in patients with cancer. *Nature Reviews Clinical Oncology*, 17(7), 428–437.
- [4] Fridlender, Z. G., Sun, J., Kim, S., Kapoor, V., Cheng, G., Ling, L., Worthen, G. S., and Albelda, S. M. (2009). Polarization of tumor-associated neutrophil phenotype by TGF- $\beta$  : “N1” versus “N2” TAN. *Cancer Cell*, 16(3), 183–194.
- [5] Gentles, A. J., et al. (2015). The prognostic landscape of genes and infiltrating immune cells across human cancers. *Nature Medicine*, 21(8), 938–945.
- [6] Gershkovitz, M., et al. (2018). TRPM2 mediates neutrophil killing of disseminated tumor cells. *Cancer Research*, 78(10), 2680–2690.
- [7] Lecot, P., et al. (2019). Neutrophil Heterogeneity in Cancer : From Biology to Therapies. *Frontiers in Immunology*, 10, 2155.
- [8] Shaul, M. E., & Fridlender, Z. G. (2017). Neutrophils as active regulators of the immune system in the tumor microenvironment. *Journal of Leukocyte Biology*, 102(2), 343–349.
- [9] Soneson, C., Love, M. I., & Robinson, M. D. (2015). Differential analyses for RNA-seq : transcript-level estimates improve gene-level inferences. *F1000Research*, 4, 1521. 10.12688/f1000research.7563.2
- [10] Patro, R., et al. (2017). Salmon provides fast and bias-aware quantification of transcript expression. *Nature Methods*, 14(4), 417–419. 10.1038/nmeth.4197
- [11] Love, M. I., Huber, W., & Anders, S. (2014). Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, 15(12), 550. 10.1186/s13059-014-0550-8
- [12] Zhu, A., Ibrahim, J. G., & Love, M. I. (2018). Heavy-tailed prior distributions for sequence count data : removing the noise and preserving large differences. *Bioinformatics*, 35(12), 2084–2092. 10.1093/bioinformatics/bty895
- [13] Gu, Z., Eils, R., & Schlesner, M. (2016). Complex heatmaps reveal patterns and correlations in multidimensional genomic data. *Bioinformatics*, 32(18), 2847–2849. 10.1093/bioinformatics/btw313
- [14] Carlson, M. (2019). org.Mm.eg.db : Genome wide annotation for Mouse. R package version 3.8.2.

- [15] Sturm, G., Finotello, F., Petitprez, F., Zhang, J. D., Baumbach, J., Fridman, W. H., List, M., and Aneichyk, T. (2019). Comprehensive evaluation of transcriptome-based cell-type quantification methods for immuno-oncology. *Bioinformatics*, **35**(14), i436–i445. <https://doi.org/10.1093/bioinformatics/btz363>
- [16] Yu, G., et al. (2012). clusterProfiler : an R package for comparing biological themes among gene clusters. *OMICS*, **16**(5), 284–287. 10.1089/omi.2011.0118
- [17] Hänzelmann, S., Castelo, R., & Guinney, J. (2013). GSEA : gene set variation analysis for microarray and RNA-seq data. *BMC Bioinformatics*, **14**, 7. 10.1186/1471-2105-14-7
- [18] Subramanian, A., et al. (2005). Gene set enrichment analysis : a knowledge-based approach for interpreting genome-wide expression profiles. *PNAS*, **102**(43), 15545–15550. 10.1073/pnas.0506580102
- [19] Korotkevich, G., et al. (2021). Fast gene set enrichment analysis. *bioRxiv*. 10.1101/060012
- [20] Liberzon, A., et al. (2011). Molecular signatures database (MSigDB) 3.0. *Bioinformatics*, **27**(12), 1739–1740. 10.1093/bioinformatics/btr260
- [21] Petitprez, F., de Reyniès, A., Keung, E.Z., Chen, T.W-W., Sun, C-M., Calderaro, J., Jeng, Y-M., Hsiao, L-P., Lacroix, L., Bougoüin, A., et al. (2020). Mouse Microenvironment Cell Population counter (mMCP-counter) : a method for estimating immune cell and stromal cell abundances in murine samples. *bioRxiv*.
- [22] Altboum, Z., Steuerman, Y., David, E., Barnett-Itzhaki, Z., Valadarsky, L., Keren-Shaul, H., Meninger, T., Mendelson, E., Mandelboim, M., Gat-Viks, I., et al. (2014). Digital cell quantification identifies global immune cell dynamics during influenza infection. *Molecular systems biology*, **10**(2), 720.
- [23] Chen, Z., Quan, L., Huang, A., Zhao, Q., Yuan, Y., Yuan, X., Shen, Q., Shang, J., Ben, Y., Qin, F.X-F., et al. (2018). seq-ImmuCC : Cell-Centric View of Tissue Transcriptome Measuring Cellular Compositions of Immune Microenvironment. *Frontiers in immunology*, **9**, 1286.
- [24] Lawrence, T., et al. (2022). Neutrophil JAK/STAT signaling promotes breast cancer metastasis. *Nature Communications*.
- [25] Gonzalez, D., et al. (2017). Neutrophil functions in tumour development and progression : a focus on the TNF family and neutrophil NETosis. *British Journal of Cancer*.
- [26] Coffelt, S. B., et al. (2016). Neutrophils in cancer : neutral no more. *Nature Reviews Cancer*.
- [27] Geering, B., & Simon, H. U. (2013). Prolonged survival of neutrophils in inflammatory conditions through interaction with BCL2A1. *Blood*.
- [28] Litvak, V., et al. (2009). Function of C/EBPdelta in a regulatory circuit that discriminates between transient and persistent TLR4-induced signals. *Nature Immunology*, **10**(4), 437–443.
- [29] Mootha, V. K., et al. (2003). PGC-1alpha-responsive genes involved in oxidative phosphorylation are coordinately downregulated in human diabetes. *Nature Genetics*, **34**(3), 267–273.
- [30] Goswami, S., et al. (2015). Modulation of glucose metabolism by CD8<sup>+</sup> T cells in response to antigen. *The Journal of Immunology*, **194**(5), 2236–2244.



- [31] Mishalian, I., et al. (2017). Tumor-associated neutrophils (TAN) develop pro-tumorigenic properties during tumor progression. *Cancer Immunology, Immunotherapy*, 66(8), 1079–1087.
- [32] Tecchio, C., et al. (2016). Neutrophil-derived cytokines : facts beyond expression. *Frontiers in Immunology*, 7, 556.
- [33] Wu, L., et al. (2019). Tumor-associated neutrophils in cancer : going pro. *Cancers*, 11(4), 564.
- [34] Jaillon, S., et al. (2020). Neutrophil diversity and plasticity in tumour progression and therapy. *Nature Reviews Cancer*.
- [35] Mantovani, A., et al. (2011). Neutrophils in the activation and regulation of innate and adaptive immunity. *Nature Reviews Immunology*, 11(8), 519–531.
- [36] Hayden, M. S., & Ghosh, S. (2008). NF- $\kappa$ B and the immune response. *Oncogene*.
- [37] Fridlender, Z. G., et al. (2012). Transcriptomic analysis comparing tumor-associated neutrophils with granulocytic myeloid-derived suppressor cells and normal neutrophils. *PLoS One*.
- [38] Hoesel, B., and Schmid, J. A. (2013). The complexity of NF- $\kappa$ B signaling in inflammation and cancer. *Molecular Cancer*, 12(1), 86.
- [39] Lopez-Castejon, G., and Brough, D. (2011). Understanding the mechanism of IL-1 $\beta$  secretion. *Cytokine & Growth Factor Reviews*, 22(4), 189–195.
- [40] Vogler, M. (2012). BCL2A1 : the underdog in the BCL2 family. *Cell Death & Differentiation*, 19(1), 67–74.
- [41] Miao, L., and St Clair, D. K. (2009). Regulation of superoxide dismutase genes : implications in disease. *Free Radical Biology and Medicine*, 47(4), 344–356.