

Analyse Génétique avec JAGS



Estimation des Paramètres Démographiques et
Mutationnels

NDOUR ALBERT

January 3, 2026

Introduction

- 🧬 **Objectif de l'étude** : Estimation de la taille d'une population, l'âge d'une mutation, et le taux de recombinaison chez l'humain.
- 📊 **Approche** : Utilisation d'un modèle bayésien implémenté avec JAGS pour inférer les paramètres d'intérêt.

Préparation des données




Données utilisées : Informations sur les SNPs du chromosome 1.

```
##fileformat=VCFv4.1
##reference=GRCh37
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT NA18853
1 10583 rs58108140 G A 100 PASS . GT 0|0
1 10611 rs189107123 C G 100 PASS . GT 0|0
1 13302 rs180734498 C T 100 PASS . GT 0|0
1 13327 rs144762171 G C 100 PASS . GT 0|0
1 13980 rs151276478 T C 100 PASS . GT 0|0
1 30923 rs140337953 G T 100 PASS . GT 0|0
1 51476 rs187298206 T C 100 PASS . GT 0|0
1 51479 rs116400033 T A 100 PASS . GT 0|0
1 51914 rs190452223 T G 100 PASS . GT 0|0
1 51935 rs181754315 C T 100 PASS . GT 0|0
1 51954 rs185832753 G C 100 PASS . GT 0|0
1 52058 rs62637813 G C 100 PASS . GT 0|0
1 52144 rs190291950 T A 100 PASS . GT 0|0
1 52238 rs150021059 T G 100 PASS . GT 0|1
1 54353 rs140052487 C A 100 PASS . GT 1|0
1 54421 rs146477069 A G 100 PASS . GT 0|0
1 54490 rs141149254 G A 100 PASS . GT 0|0
```

Préparation des données

- **Sélection** : 1/5 du chromosome pour l'analyse.
- **Fenêtres** : Création de fenêtres de 10,000 bases.
- **Filtrage** : Fenêtres avec moins de 50 positions polymorphes exclues.


Préparation des données et Distribution des SNPs



- **Distribution asymétrique** : Médiane (7) < Moyenne (9.22)
- **Forte variabilité** : Écart-type (8.57) $\approx$ moyenne : grande hétérogénéité dans la densité des SNPs

Méthodologie

Modèle d'évolution de la séquence ADN dans le temps



Légende:

N: Taille de la population u: Taux de mutation r: Taux de recombinaison h: Sites hétérozygotes
 Z: Indicateur de recombinaison (0: pas de recombinaison, 1: recombinaison)
 T: Temps effectif W: Temps de coalescence

Modèle JAGS




Figure: DAG du modèle JAGS

Modèle JAGS

- Paramètres clés : N , u , r

$$N \sim \text{Unif}(1000, 100000)$$

$$u \sim \text{Unif}(10^{-8}, 10^{-7})$$

$$r \sim \text{Unif}(10^{-9}, 10^{-7})$$

$$Z_i \sim \text{Bern}(\min(1, 4Nr\ell))$$

$$W_i \sim \text{Exp}(1/(2N))$$

$$T_i = \begin{cases} W_i & \text{si } Z_{i-1} = 1 \\ T_{i-1} & \text{sinon} \end{cases}$$

$$h_i \sim \text{Bin}(\min(1, 2T_i u), \ell)$$

où ℓ est la longueur de la fenêtre (10,000 bases).

Configuration JAGS

- 3 chaînes.
- 1000 itérations de burn-in.
- 5000 itérations d'échantillonnage.

Résultats - Estimations des paramètres


Paramètre	Moyenne	IC 95%	PSRF	ESS
N	10,650	[3,146, 21,760]	5.10	98
u	3.535e-08	[1.225e-08, 8.418e-08]	4.51	111
r	5.044e-08	[5.401e-09, 9.747e-08]	1.00	1500

Table: Estimations des paramètres et diagnostics de convergence




Résultats - Interprétation des paramètres

- Estimations obtenues, problèmes de convergence pour N et u .
- Taille de population estimée autour de 10,000 individus.
- Taux de mutation et de recombinaison de l'ordre de 10^{-8} .




Résultats - Visualisation



Résultats - Diagnostics de convergence



Résultats - Distribution de paramètres



Discussion

- Problèmes de convergence pour N et u .
- Utilisation d'une partie du chromosome seulement(1/5).

Conclusion

- Augmenter le nombre d'itération pour estimer N , u , et r .
- Défis méthodologiques dans l'estimation bayésienne de paramètres démographiques.
- Importance de la validation et de l'amélioration des modèles.

Références

-  Li, H. & Durbin, R. (2011). Inference of human population history from individual whole-genome sequences. *Nature*, 475(7357), 493-496.
-  Plummer, M. (2003). JAGS: A program for analysis of Bayesian graphical models using Gibbs sampling. In *Proceedings of the 3rd international workshop on distributed statistical computing* (Vol. 124, No. 125.10, pp. 1-10).
-  Gelman, A., et al. (2014). *Bayesian data analysis* (Vol. 2). CRC press.
-  McVean, G. A. T. & Cardin, N. J. Approximating the coalescent with recombination. *Phil. Trans. R. Soc. B* 360, 1387–1393 (2005).
-  Nachman, M. W. & Crowell, S. L. Estimate of the mutation rate per nucleotide in humans. *Genetics* 156, 297–304 (2000)