

Développement d'une interface intégrée pour l'analyse exploratoire de données RNA-Seq bulk

Albert NDOUR

Alternance M2 Bioinformatique (2024 – 2025)

Lieu de Stage : Centre de Recherche en Cancérologie de Lyon / Centre Léon Bérard

Encadrantes : Dr Marie-Cécile MICHALLET, Dr Roxane POMMIER


Équipe de Recherche : Immunosurveillance du cancer et ciblage thérapeutique (CISTAR)/Resp : Dr C. CAUX

Plateforme Bioinformatique : Plateforme Bioinformatique Gilles Thomas/Resp : A. FERRARI

Le cancer du sein

Première cause de mortalité par cancer chez la femme (monde : 2,3 millions de nouveaux cas et 700 000 décès)

Principal facteur de risque : l'âge (augmente après la ménopause)



Le cancer du sein et immunothérapie

L'efficacité de l'immunothérapie varie fortement selon le sous-type de cancer du sein

Immunothérapies (thérapies anti-cancéreuses impliquant le système immunitaire)

 **Réussite**


**Cancers triple négatifs
(basaux ou basal-like)**

 **Echec**

**Cancers HER2+
Cancers luminal A/B**

Le microenvironnement tumoral

L'efficacité de l'immunothérapie varie fortement selon le sous-type de cancer du sein



Les neutrophiles : acteurs clés du microenvironnement tumoral



Type N1 aux fonctions anti-tumorales
Stade précoce ?



Type N2 aux fonctions pro-tumorales
Stade tardif

Problématique


Etudier l'évolution des neutrophiles au cours de la progression tumorale mammaire (stades précoce et tardif)

Données :


Bulk RNASeq générées à partir d'un modèle murin de cancer du sein (MMTV-Neu)

Génération des données RNASeq bulk



Transgenic mouse model



Génération des données RNASeq bulk



Transgenic mouse model




GENOTYPE

Génération des données RNASeq bulk



Transgenic mouse model



NeuT+




Control



GENOTYPE



TISSU



Génération des données RNASeq bulk




Transgenic mouse model




GENOTYPE

TISSUE



TYPE CELLULAIRE



Schématisation des données RNASeq bulk



GENOTYPE

STAGE


TISSUE

CELL TYPE

REPLICATES



Schématisation des données RNASeq bulk



Choix de la technologie



Fonctions / Scripts



UI & Server

Choix de la technologie



Fonctions / Scripts



UI & Server

Principaux Packages utilisés (R)



MSigDB
Molecular Signatures
Database



NEUTROPHILS IN BREAST CANCER TUMORIGENESIS

Uncovering the dynamic roles of neutrophils in the tumor microenvironment through comprehensive transcriptomic analysis

Despite effective therapies, breast cancer remains the leading cause of cancer death in women. Our research focuses on how neutrophils influence cancer progression and potential therapeutic targets.



Neutrophil Role in Cancer

Key Insights

Identification of neutrophil-specific genes and molecular pathways during mammary tumorigenesis.



Transcriptomic Analysis

71 Samples

Comprehensive RNA-Seq data from multiple cell types across different stages of tumor development.



Therapeutic Targets

Precision Medicine

Identifying tumor-specific molecular characteristics for targeted immunotherapies.

Visualisation de l'interface – page d'accueil

 MMTV-NEU RNASEQ EXPLORER

 HOME

 UNSUPERVISED

 GENES / SIGNATURES

 IMMUNE DECONVOLUTION

 DIFFERENTIAL EXPRESSION ▾

 DOCUMENTATION

NEUTROPHILS IN BREAST CANCER TUMORIGENESIS

Uncovering the dynamic roles of neutrophils in the tumor microenvironment through comprehensive transcriptomic analysis

Despite effective therapies, breast cancer remains the leading cause of cancer death in women. Our research focuses on how neutrophils influence cancer progression and potential therapeutic targets.



Neutrophil Role in Cancer

Key Insights

Identification of neutrophil-specific genes and molecular pathways during mammary tumorigenesis.



Transcriptomic Analysis

71 Samples

Comprehensive RNA-Seq data from multiple cell types across different stages of tumor development.



Therapeutic Targets

Precision Medicine

Identifying tumor-specific molecular characteristics for targeted immunotherapies.

Conception modulaire de l'interface

		PARAMETRES A SELECTIONNER	ANALYSES EFFECTUEES
ANALYSE EXPLORATOIRE	ANALYSE NON-SUPERVISEE	Sélection des échantillons d'intérêt → cohorte entière / sous-cohorte Sélection des gènes les plus variants → top 10% / 5% / 1%	Analyse en Composante Principale (ACP) → % de variance expliquée par les axes → projection des variables biologiques d'intérêt (genotype / stage / cell type) Clustering hiérarchique → clustering hiérarchique des gènes sélectionnés → sélection du nombre approprié de clusters de gènes et d'échantillons Listes de gènes / Enrichissement de pathways → liste des gènes dans chaque cluster identifié → test d'enrichissement de pathways (ORA) (parmi 5 collections MSigDB)
	GENE / SIGNATURE	Sélection de gène(s) d'intérêt → parmi tous les gènes de la matrice d'expression Sélection de pathway(s) d'intérêt → parmi 5 collections MSigDB Sélection de pathway personnalisé → parmi tous les gènes de la matrice d'expression (attribution d'un statut UP/DOWN pour chaque gène)	Analyse de comparaison de moyennes → sélection de la variable biologique d'intérêt (genotype / stage / cell type) → représentation graphique par boxplot → tests statistiques de comparaison de moyennes (Kruskal-Wallis / Dunn's post-hoc)
	INFILTRAT TUMORAL	Sélection des échantillons d'intérêt → cohorte entière / sous-cohorte Sélection de la méthode d'estimation → MCPcounter → DCQ → Seq-ImmuneCC Sélection du type cellulaire d'intérêt → parmi ceux communs à plusieurs méthodes	Clustering hiérarchique → visualisation de clusters d'échantillons Comparaison de moyennes → sélection des variables biologiques d'intérêt (genotype / stage / cell type) → représentation graphique par boxplot → tests statistiques de comparaison de moyennes (Kruskal-Wallis / Dunn's post-hoc) Comparaison des méthodes → représentation graphique par boxplot → tests statistiques Kruskal-Wallis
ANALYSE SUPERVISEE	EXPRESSION DIFFERENTIELLE	Sélection des échantillons d'intérêt → statut « <i>CONDITION</i> » et « <i>CONTRÔLE</i> » → sélection par échantillon ou par groupe biologique Sélection de seuils de significativité → <i>p</i>-value corrigée (FDR) : 0.05 / 0.01 / 0.001 → log2FoldChange : 0 / 0.58 / 1	Table récapitulative → nombre d'échantillons (condition et contrôle) → nombre de gènes différentiellement exprimés (surexprimés et sous-exprimés) Volcano plot → pour tous les gènes de la matrice d'expression → représentation des gènes significatifs en fonction des seuils sélectionnés (<i>p</i>-value corrigée / I2FC) Clustering hiérarchique → clustering hiérarchique des gènes sélectionnés dans les autres cohortes / sous-cohortes Listes de gènes / Enrichissement de pathways → liste des gènes surexprimés et sous-exprimés (valeurs de <i>p</i>-values corrigées / I2FCs) → test d'enrichissement de pathways (ORA) (parmi 5 collections MSigDB)
	GSEA	Sélection des échantillons d'intérêt → statut « <i>CONDITION</i> » et « <i>CONTRÔLE</i> » → sélection par échantillon ou par groupe biologique Sélection de pathway(s) d'intérêt → parmi 5 collections MSigDB	Graphique d'enrichissement → plots des <i>top10</i> et <i>bottom10</i> pathways enrichis Table récapitulative → liste de tous les pathways testés (<i>p</i>-values / NES) Comparaison de moyennes → représentation graphique par boxplot → tests statistiques (Kruskal-Wallis / Dunn's post-hoc)

1


2

3

4

5

Conception modulaire de l'interface



Conception modulaire de l'interface – analyse non-supervisée

1

ANALYSE NON-
SUPERVISEE

PARAMETRES A SELECTIONNER

Sélection des échantillons d'intérêt

→ cohorte entière / sous-cohorte

Sélection des gènes les plus variants

→ top 10% / 5% / 1%

ANALYSES EFFECTUEES

Analyse en Composante Principale (ACP)

→ % de variance expliquée par les axes
→ projection des variables biologiques d'intérêt
(*genotype / stage / cell type*)

Clustering hiérarchique

→ clustering hiérarchique des gènes sélectionnés
→ sélection du nombre approprié de clusters
de gènes et d'échantillons

Listes de gènes / Enrichissement de pathways

→ liste des gènes dans chaque cluster identifié
→ test d'enrichissement de pathways (ORA)
(parmi 5 collections MSigDB)

Analyse non-supervisée

1

MMTV-NEU RNASEQ EXPLORER

HOME UNSUPERVISED GENES / SIGNATURES IMMUNE DECONVOLUTION DIFFERENTIAL EXPRESSION DOCUMENTATION

UNSUPERVISED ANALYSIS

Bulk RNASeq Transcriptomics

Analysis Parameters

Data Selection

Cell Type
Neutro_Blood, Neutro_BM, Neutr

Stage
Early, Late

Genotype
CTR, NeuT

Analysis Settings


Most Variable Genes (%)
10

Run Analysis

Samples PCA Heatmap Genes ORA Hallmark Heatmap


Analyse non-supervisée : Visualisation par ACP

1



Analyse non-supervisée : Visualisation par clustering hiérarchique

1



Analyse non-supervisée : Table des gènes

1

MMTV-NEU RNASEQ EXPLORER [HOME](#) [UNSUPERVISED](#) [GENES / SIGNATURES](#) [IMMUNE DECONVOLUTION](#) [DIFFERENTIAL EXPRESSION](#) [DOCUMENTATION](#)

UNSUPERVISED ANALYSIS

Bulk RNASeq Transcriptomics

Analysis Parameters

Data Selection

Cell Type
Neutro_Blood, Neutro_BM, Neutr

Stage
Early, Late

Genotype
CTR, NeuT

Analysis Settings

Most Variable Genes (%)
10

Run Analysis

Samples PCA Heatmap **Genes** ORA Hallmark Heatmap

Top Variant Genes

Export CSV

Show 10 entries Search:


Gene	Variance	Mean	Cluster
All	All	All	All
Hba-a2	24.1002	6.3987	A
mt-Atp6	22.8498	4.7999	B
Hba-a1	21.9789	5.2495	A
Hbb-bs	20.8425	5.8507	A
Hbb-bt	18.5216	4.0110	A
mt-Co3	17.1748	5.6470	B
mt-Co2	16.2810	5.9122	B
H3c15	13.1203	3.6014	C
Cd74	12.9967	4.5030	D
H2-Ab1	12.0986	3.7165	D

Showing 1 to 10 of 2,154 entries


Previous 1 2 3 4 5 ... 216 Next

Analyse non-supervisée : Visualisation de l'ORA

1



Conception modulaire de l'interface



		PARAMETRES A SLECTIONNER	ANALYSES EFFECTUEES
ANALYSE EXPLORATOIRE	ANALYSE NON-SUPERVISEE	Sélection des échantillons d'intérêt → cohorte entière / sous-cohorte Sélection des gènes les plus variants → top 10% / 5% / 1%	Analyse en Composante Principale (ACP) → % de variance expliquée par les axes → projection des variables biologiques d'intérêt (genotype / stage / cell type) Clustering hiérarchique → clustering hiérarchique des gènes sélectionnés → sélection du nombre approprié de clusters de gènes et d'échantillons Listes de gènes / Enrichissement de pathways → liste des gènes dans chaque cluster identifié → test d'enrichissement de pathways (ORA) (parmi 5 collections MSigDB)
	GENE / SIGNATURE	Sélection de gène(s) d'intérêt → parmi tous les gènes de la matrice d'expression Sélection de pathway(s) d'intérêt → parmi 5 collections MSigDB Sélection de pathway personnalisé → parmi tous les gènes de la matrice d'expression (attribution d'un statut UP/DOWN pour chaque gène)	Analyse de comparaison de moyennes → sélection de la variable biologique d'intérêt (genotype / stage / cell type) → représentation graphique par boxplot → tests statistiques de comparaison de moyennes (Kruskal-Wallis / Dunn's post-hoc)
	INFILTRAT TUMORAL	Sélection des échantillons d'intérêt → cohorte entière / sous-cohorte Sélection de la méthode d'estimation → MCPcounter → DCQ → SeqImmunCC Sélection du type cellulaire d'intérêt → parmi ceux communs à plusieurs méthodes	Clustering hiérarchique → visualisation de clusters d'échantillons Comparaison de moyennes → sélection des variables biologiques d'intérêt (genotype / stage / cell type) → représentation graphique par boxplot → tests statistiques de comparaison de moyennes (Kruskal-Wallis / Dunn's post-hoc) Comparaison des méthodes → représentation graphique par boxplot → tests statistiques Kruskal-Wallis
ANALYSE SUPERVISEE	EXPRESSION DIFFERENTIELLE	Sélection des échantillons d'intérêt → statut « CONDITION » et « CONTRÔLE » → sélection par échantillon ou par groupe biologique Sélection de seuils de significativité → p-value corrigée (FDR) : 0.05 / 0.01 / 0.001 → log2FoldChange : 0 / 0.58 / 1	Table récapitulative → nombre d'échantillons (condition et contrôle) → nombre de gènes différentiellement exprimés (surexprimés et sous-exprimés) Volcano plot → pour tous les gènes de la matrice d'expression → représentation des gènes significatifs en fonction des seuils sélectionnés (p-value corrigée / 2FC) Clustering hiérarchique → clustering hiérarchique des gènes sélectionnés dans les autres cohortes / sous-cohortes Listes de gènes / Enrichissement de pathways → liste des gènes surexprimés et sous-exprimés (valeurs de p-values corrigées / 2FCs) → test d'enrichissement de pathways (ORA) (parmi 5 collections MSigDB)
	GSEA	Sélection des échantillons d'intérêt → statut « CONDITION » et « CONTRÔLE » → sélection par échantillon ou par groupe biologique Sélection de pathway(s) d'intérêt → parmi 5 collections MSigDB	Graphique d'enrichissement → plots des top10 et bottom10 pathways enrichis Table récapitulative → liste de tous les pathways testés (p-values / NES) Comparaison de moyennes → représentation graphique par boxplot → tests statistiques (Kruskal-Wallis / Dunn's post-hoc)

1

2

3

4

5

Sélection des échantillons d'intérêt

→ cohorte entière / sous-cohorte

Sélection de la méthode d'estimation

→ MCPcounter
→ DCQ
→ Seq-ImmunCC

Sélection du type cellulaire d'intérêt

→ parmi ceux communs à plusieurs méthodes

Clustering hiérarchique

→ visualisation de clusters d'échantillons

Comparaison de moyennes


→ sélection des variables biologiques d'intérêt
(*genotype / stage / cell type*)
→ représentation graphique par boxplot
→ tests statistiques de comparaison de moyennes
(Kruskall-Wallis / Dunn's post-hoc)

Comparaison des méthodes

→ représentation graphique par boxplot
→ tests statistiques Kruskal-Wallis


Infiltrat tumoral : Visualisation par barplot

3



Infiltrat tumoral : Comparaison des trois méthodes

3



Documentation de l'application

MMTV-NEU RNASEQ EXPLORER

HOME

UNSUPERVISED

GENES / SIGNATURES

IMMUNE DECONVOLUTION

DIFFERENTIAL EXPRESSION

DOCUMENTATION

Documentation

About

Non-supervised Analysis

Supervised Analysis

Immune Deconvolution

Bio-info team

Bioinformatics & Immunology Research Team

Bioinformatician-Developer

Albert NDOUR

Bioinformatics Student

Centre de recherche en cancérologie de Lyon

07 49 59 21 38

Albert.NDOUR@lyon.unicancer.fr

Bioinformatician

Roxane M. POMMIER

PhD in Bioinformatics

Computational Biologist

Gilles Thomas Bioinformatics Platform

Centre Léon Bérard, Cheney B, 4th floor

+33 (0)4 26 55 67 68

roxane.pommier@lyon.unicancer.fr

Principal Investigator

Marie-Cécile MICHALLET

PhD in Immunology

DR2 CNRS - Group Leader

CISTAR (Cancer Immune Surveillance and Therapeutic tARgeting) Team

Centre de recherche en cancérologie de Lyon (CRCL), Centre Léon Bérard

04 78 78 28 53

Démonstration de l'interface

Conclusion

De l'analyse manuelle à une interface interactive des données


[illegible]

Plusieurs scripts

interactive



Facile d'utilisation



Prêt à la publication

Perspectives

PREPARE DATA

FEATURES SELECTION

DE

SAVE PARAMETERS

?

EXPRESSION DATA

METADATA

LOAD EXPRESSION DATA

Expression data (RDS file)

Browse...

No file selected

Expected format for expression data

STUDIED SPECIES

SPECIES :

☐ Human (GRCh38)

☒ Mouse (GRCm38)

FILTERING OPTIONS



Keep only coding genes

Filtering out non-coding genes can reduce noise in your data and focus on biologically relevant genes.

“Merci pour votre attention!”

Plateforme Bioinformatique Gilles Thomas

**Roxane POMMIER
Anthony FERRARI
Maude Ardin**

Equipe du Dr Christophe CAUX

**Marie-Cécile MICHALLET
Antoine DEBIESSE
Manuela PEREIRA ABRANTES**

