

Nom et Prénom(s) : Albert NDOUR
Tél. : 07 49 59 21 38
Email : albert.ndour@etu.unice.fr

MEMOIRE DE MASTER 2 BIOINFORMATIQUE

VARIATIONS GENETIQUES ET HISTOIRE EVOLUTIVE DU GENE POL DU VIH-1 AU SENEGAL.

Encadrement :

Dr Mame Ndew MBAYE : mamndew@gmail.com

Seydina Issa DIOP Doctarant en bioinformatique et en génomique des populations à l'Université de Zurich(Suisse) : diop.seydina@laposte.net

Mame Salane THIAM Doctorante en Bioinformatique à l'Université Cheikh Anta DIOP de Dakar (UCAD): salanethiam@gmail.com

RESUME :

OBJECTIF :

Évaluer le potentiel génétique du gène Pol et son dynamisme moléculaire pour établir son profil génétique et mieux comprendre son histoire évolutive

CONCEVOIR :

La parenté des virus dans une grande base de données (**Los Alamos**) de séquences **pol** générées à partir d'individus infectés par le VIH-1 au Sénégal a été reconstruite par des analyses phylogénétiques.

METHODE :

Dans le cadre de notre étude, les séquences nucléiques et les données associées ont été recueillies à partir de la base de données publique **LosAlamos**. Cette collecte cible les échantillons de séquences du VIH-1 (complètes et/ou partielles) d'origine géographique Sénégalaise. La région génomique d'intérêt est **pol [2253-3554]** relativement à la séquence de référence (**HXB2**), la taille minimale des séquences à collecter est fixée à 500 nucléotides. L'ensemble des séquences a été filtré aux fins d'éliminer celles qui sont redondantes, les séquences provenant de la même source individuelle (identité de séquence à 100% synonyme de doublons) ont été identifiées et la séquence la plus ancienne sera considérée dans l'échantillon final. L'alignement de séquence a été effectué par **MUSCLE** et le Nettoiement de cet alignement avec **Gblocks**. Des phylogénies basées sur le maximum de parcimonie et les

distances génétiques ont ensuite été effectuées à partir de **MEGA**11 puis par R afin de comparer les deux arbres générés avec ces deux méthodes et deux outils différents. Pour comparer les arbres obtenus, nous avons réalisé plusieurs phylogénies à partir des méthodes qui présupposent le respect de l'horloge moléculaire ceux obtenus avec les autres méthodes (qui n'imposent pas l'horloge) pour identifier les séquences qui n'évoluent pas de manière neutre, de détecter les traces de sélection chez certaines des séquences. Enfin nous avons calculé le ratio $\frac{dN}{dS}$ (taux de mutation synonymes et non synonymes) en utilisant **codeml**, pour comprendre les différents profils mutationnels des séquences et comment elles ont évolué ainsi que les mutations de résistances associées.

RESULTATS :

Sur les 971 séquences pol téléchargées à partir de la base de données Los Alamos, 2020. Un alignement de séquence et une inspection manuelle nous a permis de retenir 33 séquences du gène pol. Les séquences partageant plus de 95 % de similarité avec une ou plusieurs autres séquences ont été sélectionnées pour disposer d'un jeu de données bien sélectionné. La variation génétique moyenne inter-patients parmi les séquences est de 5,1 % (intervalle de 0 à 12,4 %). Bien que plusieurs sous-types soient représentés dans le sous-ensemble de séquences, y compris les sous-types A, B, C, D, G, J, K, F, CRF01-AE, CRF02-AG, et CPX la grande majorité est de la forme recombinante CRF02-AG (54.1%) suivie du sous-type C (14.5%), reflétant la distribution des formes recombinantes des infections prévalentes au Sénégal dans la durée indiquée précédemment. Des topologies identiques ont été obtenu avec les différents arbres produits avec différentes méthodes et avec des valeurs bootstrap bien soutenues. Ceci renseigne sur les liens épidémiologiques entre les différents sous-types et leur relation évolutive. L'Analyse Phylogénétique du ratio $\frac{dN}{dS}$ a permis de détecter un certain nombre de mutations susceptibles d'être responsables de résistances antirétrovirales.